

ΒΑΘΙΑ ΕΡΕΥΝΗΤΙΚΗ ΑΝΑΛΥΣΗ

DynNav

Dynamic Navigation & Rerouting in Unknown Environments

Tutorial · Ερευνητική Μονογραφία · Τεχνική Αναφορά · Εξήγηση για Αρχάριο

26 Contributions · 72 Tests · ROS 2 Humble · TurtleBot3 Burger · Python 3.10+

Panagiota Grosdoui

Ηλεκτρολόγων Μηχανικών & Μηχανικών Υπολογιστών · ΔΠΘ

github.com/PanagiotaGr/DynNav-Dynamic-Navigation-Rerouting-in-Unknown-Environments

Πώς να Διαβάσεις Αυτό το Κείμενο

Αυτό το κείμενο είναι γραμμένο ταυτόχρονα για τέσσερις αναγνώστες:

- Τον πλήρη αρχάριο — κάποιον που δεν ξέρει τίποτα από ρομποτική ή AI
- Τον φοιτητή που ξέρει προγραμματισμό αλλά όχι control theory
- Τον PhD student ή ερευνητή που θέλει να αξιολογήσει το τεχνικό βάθος
- Τον καθηγητή ή PI robotics lab που αποφασίζει αν αυτή η δουλειά έχει δυναμικό

Για κάθε ένα από τα 26 contributions, θα βρεις 10 ενότητες:

① Εξήγηση για αρχάριο	Τι πρόβλημα, γιατί υπάρχει, γιατί είναι δύσκολο — χωρίς ορολογία
② Αναλογία & διαίσθηση	Everyday παράδειγμα που κάνει την ιδέα αμέσως κατανοητή
③ Τι έκανα ακριβώς	Βήμα-βήμα υλοποίηση, input/output, ροή δεδομένων
④ Βαθιά τεχνική ανάλυση	Αλγόριθμος, pseudocode, μαθηματική φορμοποίηση, πολυπλοκότητα
⑤ Ερευνητική αξία	Research question, novelty, σχέση με βιβλιογραφία
⑥ Αποτελέσματα	Τι βγήκε, τι σημαίνουν οι αριθμοί, τι λείπει
⑦ Αυστηρή κριτική	Αδυναμίες, κρυφές παραδοχές, σενάρια αποτυχίας
⑧ Πώς γίνεται δημοσίευση	Paper τίτλος, venue, missing experiments, ablations
⑨ Ανοιχτά ερωτήματα	Τι καινούργιο ανοίγει, PhD directions
⑩ 2-λεπτά εξήγηση	Αν είχα 2 λεπτά να εξηγήσω σε οποιονδήποτε...

Μέρος Α — Τι Είναι Τελικά το DynNav;

Το πρόβλημα σε μια πρόταση

Ένα ρομπότ μπαίνει σε κτίριο που δεν έχει ξαναδεί. Δεν έχει χάρτη. Οι αισθητήρες του κάνουν λάθη. Εμφανίζονται ξαφνικά εμπόδια. Κάποιος μπορεί να προσπαθεί να το εξαπατήσει. Πώς φτάνει ασφαλώς στον στόχο του;

Το DynNav δεν είναι ένα πρόγραμμα — είναι ένα ολόκληρο ερευνητικό framework. 26 modules που λύνουν μαζί το πρόβλημα της αυτόνομης πλοήγησης σε άγνωστο, δυναμικό, και ενδεχομένως εχθρικό περιβάλλον.

Γιατί είναι δύσκολο — τα 3 ψέματα που λένε τα textbooks

- «Ο χάρτης είναι γνωστός» → ΛΑΘΟΣ. Στην πραγματικότητα ο χάρτης χτίζεται καθώς κινείσαι
- «Οι αισθητήρες είναι τέλειοι» → ΛΑΘΟΣ. LiDAR, οδομετρία, GPS έχουν θόρυβο και drift
- «Το περιβάλλον είναι στατικό» → ΛΑΘΟΣ. Άνθρωποι, πόρτες, κιβώτια — όλα αλλάζουν

Η στοίβα — πώς τα 26 modules συνδέονται

Υπόγειο — Αίσθηση	C02 EKF/UKF · C15 DVS · C23 3DGS · C24 NeRF — χτίζει εικόνα κόσμου
Ισόγειο — Ανάλυση ρίσκου	C03 CVaR · C12 Diffusion — ποσοτικοποιεί κίνδυνο
1ος — Σχεδιασμός	C01 A* · C04 Returnable · C06 Energy · C07 NBV · C13 World Model
2ος — Ασφάλεια	C05 FSM · C18 STL+CBF ← το πιο ισχυρό
3ος — Εκτέλεση	C10 Ethics · C19 LLM Planner
4ος — Παρακολούθηση	C08 IDS · C14 Causal · C20 Explainer · C25 Attacks
5ος — Μάθηση	C11 VLM · C17 Topo · C21 PPO · C22 Curriculum
Ταράτσα — Στόλος	C09 Coordination · C16 Federated · C26 BFT

Μέρος Β — Τα 26 Contributions Αναλυτικά

Contribution 01 Learned A* Heuristics — Έξυπνος Αλγόριθμος Εύρεσης Μονοπατιού

Κατηγορία: Σχεδιασμός / Μάθηση

① Εξήγηση για Αρχάριο — Από το Μηδέν

Τι πρόβλημα λύνει;

Ο αλγόριθμος A* βρίσκει τη βέλτιστη διαδρομή από σημείο A σε σημείο B σε ένα χάρτη. Χρησιμοποιεί μια «εκτίμηση» (heuristic) για να ψάχνει πιο έξυπνα. Εδώ εκπαιδεύουμε νευρωνικό δίκτυο να κάνει καλύτερες εκτιμήσεις από εμπειρία.

Γιατί υπάρχει αυτό το πρόβλημα;

Χωρίς έξυπνη εκτίμηση, ο A* εξετάζει χιλιάδες περιττά σημεία. Σε μεγάλα κτίρια αυτό είναι πολύ αργό για real-time replanning σε milliseconds.

Γιατί είναι δύσκολο;

Οποιαδήποτε εκτίμηση που «υπερεκτιμά» την απόσταση καταστρέφει τη βελτιστότητα του A*. Οπότε δεν μπορείς να χρησιμοποιήσεις οποιοδήποτε νευρωνικό — πρέπει να εγγυηθείς $\tilde{h}(s) \leq h^*(s)$ πάντα.

② Αναλογία & Διαίσθηση

Ταξίτζης 20 χρόνων στην πόλη: Όταν λες «Αεροδρόμιο», ήδη ξέρει κατά προσέγγιση ποια κατεύθυνση — δεν εξετάζει κάθε δρόμο ξεχωριστά. Το neural heuristic δίνει αυτή την εσωτερικευμένη χωρική γνώση στο ρομπότ.

③ Τι Έκανα Ακριβώς — Βήμα-Βήμα

- Έτρεξα optimal A* σε πολλά training environments → συλλέχθηκαν ζεύγη (state s , true cost $h^*(s)$)
- Εκπαίδευσα MLP regressor: minimize $\text{MSE}(h_\theta(s), h^*(s))$
- Inference: $\tilde{h}(s) = \min(h_\theta(s), \text{manhattan}(s, \text{goal}))$ — clipping εγγυάται admissibility
- Τρέχω standard A* με $\tilde{h}$ ως heuristic
- Eval script: `contributions/01_learned_astar/experiments/eval_astar_learned.py`

Ροή Δεδομένων

Input: (θέση ρομπότ, στόχος, τοπικά εμπόδια) → MLP → $h_\theta(s)$ → min με Manhattan → $\tilde{h}(s)$ → A priority queue → βέλτιστη διαδρομή*

④ Βαθιά Τεχνική Ανάλυση

Βασικά Components

- State encoder: κωδικοποιεί σχετική θέση στόχου, τοπικό occupancy window (NxN grid), κατεύθυνση
- MLP regressor: 2-3 hidden layers, ReLU activations, MSE loss
- Admissibility clipper: $\tilde{h} = \min(h_{\theta}, h_{naive})$ — αποδεδαιγμένα $\leq h^*(s)$
- Standard A*: αναλλοίωτος — μόνο η heuristic function αντικαταστάθηκε
- Evaluation harness: μετράει node expansions, path length, runtime

Pseudocode / Αλγόριθμος

```
ΕΚΠΑΙΔΕΥΣΗ:
για κάθε env σε D_train:
    τρέξε optimal A*(env) → συλλέξε {(s_i, h*(s_i))}
    minimize L(θ) = (1/N) Σ (h_θ(s_i) - h*(s_i))^2

INFERENCE:
function h_clipped(s, goal):
    h_neural = MLP_θ(encode(s, goal))
    h_safe = manhattan(s, goal)
    return min(h_neural, h_safe) # admissibility εγγυημένη

τρέξε A* με heuristic = h_clipped
```

Μαθηματική Φορμοποίηση

Admissibility: $\tilde{h}(s) = \min(h_{\theta}(s), h_{naive}(s)) \leq h_{naive}(s) \leq h^*(s) \quad \checkmark$
 Loss: $L(\theta) = (1/N) \sum_{i=1}^N (h_{\theta}(s_i) - h^*(s_i))^2$
 A* expansion: $f(n) = g(n) + \tilde{h}(n) \rightarrow$ expand lowest-f first
 Optimality: preserved αν και μόνο αν $\tilde{h}(s) \leq h^*(s) \quad \forall s$

Πολυπλοκότητα & Παραδοχές

Χρονική πολυπλοκότητα: A*: $O(b^d)$ worst case. Training: $O(N \cdot |MLP|)$. Inference per node: $O(|MLP|) \approx O(1)$.

- Training και test environments έχουν την ίδια στατιστική δομή (rooms, corridors)
- Manhattan distance είναι πάντα lower bound (ισχύει για grid worlds)
- MLP έχει αρκετή εκφραστικότητα για να προσεγγίσει $h^*(s)$

⑤ Ερευνητική Αξία

Ερευνητικό Ερώτημα

Μπορεί ένα νευρωνικά μαθημένο heuristic να μειώσει τα node expansions του A* κατά $\geq 30\%$ διατηρώντας παράλληλα τη βελτιστότητα, σε unseen environments της ίδιας δομικής κλάσης;

Novelty — Τι Καινούργιο Κάνω

Η ιδέα υπάρχει στη βιβλιογραφία. Η novelty: (1) admissibility clipping σε navigation context, (2) structured feature encoding που καταγράφει τόσο τοπική όσο και καθολική γεωμετρία, (3) systematic evaluation σε diverse map types.

Σχετική Βιβλιογραφία

Yonetani et al. (2021) Neural A* — differentiable A*. Bejjani et al. (2021) learned heuristics. Takahashi (1989) motion planning heuristics. Το min-clipping trick είναι γνωστό αλλά δεν έχει αξιολογηθεί rigorous σε mobile navigation.

⑥ Αποτελέσματα & Τι Σημαίνουν

~35% μείωση node expansions σε benchmark maps. Optimality διατηρείται σε όλες τις δοκιμές. Runtime improvement συσχετίζεται με πολυπλοκότητα χάρτη.

Metrics

- Node expansions (count κελιών στο closed list)
- Path length ratio: learned/optimal A* (πρέπει να είναι 1.0)
- Wall-clock planning time (ms)
- Generalization gap: seen vs unseen map types

Τι Λείπει Ακόμα

Δεν υπάρχει σύγκριση με Neural A* (Yonetani 2021) ή Differentiable A*. Δεν αξιολογήθηκε σε robot benchmark datasets (MatterPort3D, Gibson). Δεν υπάρχει statistical significance testing.

⑦ Αυστηρή Κριτική — Reviewer Mode

Αδυναμίες

- Το min-clipping για admissibility είναι γνωστό trick — δεν είναι από μόνο του research contribution
- 35% βελτίωση χρειάζεται confidence intervals — όχι μόνο mean
- Καμία σύγκριση με RRT*, Dijkstra, Differentiable A*
- Consistency (monotonicity) δεν εγγυάται — μπορεί να επιβραδύνει A* σε ειδικές περιπτώσεις

Κρυφές Παραδοχές

- Training distribution = test distribution (δεν αναλύθηκε domain shift)
- Manhattan είναι πάντα valid lower bound
- MLP αξιολογείται σε real-time (δεν profiled σε embedded hardware)

Σενάρια Αποτυχίας

- Environments δομικά πολύ διαφορετικά από training (π.χ. outdoor vs indoor)
- Μεγάλα, ανοιχτά περιβάλλοντα όπου Manhattan distance είναι πολύ χαλαρή
- Dense obstacle fields που μπερδεύουν τα spatial features

⑧ Πώς Γίνεται Δημοσίευση

Τίτλος Paper	Admissible Neural Heuristics for Learning-Augmented A* Navigation in Structured Indoor Environments
Venue	ICRA Workshop on Learning for Planning / RA-L

Missing Experiments

- Σύγκριση με Neural A* (Yonetani 2021) σε identical benchmark maps
- Evaluation σε MatterPort3D και Gibson robot navigation datasets
- Statistical testing: t-test σε node expansions across 100+ map instances
- Online learning variant: update heuristic καθώς ο ρομπότ εξερευνά

Ablations που Χρειάζονται

- Με vs χωρίς clipping — επηρεάζει πρακτικά την ποιότητα;
- Raw features vs structured encoding — πόσο σημαντικό είναι το feature design;
- Transfer: train σε ένα map type, test σε άλλο — πώς υποβαθμίζεται η επίδοση;
- MLP size: 1 vs 2 vs 3 hidden layers — accuracy/speed tradeoff

9 Ανοιχτά Ερευνητικά Ερωτήματα

1. Μπορεί να μαθαίνεται online καθώς το ρομπότ εξερευνεί άγνωστο χώρο;
2. Μπορεί meta-learning (MAML) να παράγει heuristic που adapts σε K steps σε νέο env;
3. Μπορεί consistency (όχι μόνο admissibility) να επιβληθεί ως training constraint;

10 Αν Είχα 2 Λεπτά να το Εξηγήσω σε Οποιονδήποτε...

Ο αλγόριθμος A* βρίσκει διαδρομές σαν να λύνει λαβύρινθο — αλλά μπορεί να σπαταλάει χρόνο σε αδιέξοδα. Εκπαίδευσα ένα μικρό νευρωνικό δίκτυο να εκτιμά καλύτερα ποια κατεύθυνση οδηγεί στον στόχο, βασισμένο σε εμπειρία από εκατοντάδες παρόμοιους χάρτες. Αποτέλεσμα: 35% λιγότερα κελιά εξετάζονται, ίδια ποιότητα διαδρομής. Μια μικρή μαθηματική προφύλαξη (clipping) εγγυάται ότι η βελτιστότητα δεν χάνεται ποτέ.

Βαθμολογία

Διάσταση	Βαθμός	Σχόλιο
Πρωτοτυπία	5/10	Γνωστή μέθοδος
Τεχνικό Βάθος	7/10	Prototype επίπεδο
Δημοσιευσιμότητα	6/10	Χρειάζεται experiments
PhD Δυναμικό	6/10	Υποστηρικτικό υλικό

Contribution 02 Uncertainty Estimation — EKF & UKF

Κατηγορία: Αίσθηση / Εκτίμηση Κατάστασης

① Εξήγηση για Αρχάριο — Από το Μηδέν

Τι πρόβλημα λύνει;

Κανένας αισθητήρας δεν είναι τέλειος. Το LiDAR έχει θόρυβο. Οι τροχοί γλιστράνε. Αντί να πούμε «είμαι ΕΔΩ», λέμε «είμαι ΠΙΘΑΝΩΣ εδώ, με αβεβαιότητα $\pm 10\text{εκ.}$ ». Ο EKF είναι ο μαθηματικός τρόπος να γίνει αυτό.

Γιατί υπάρχει αυτό το πρόβλημα;

Αν το ρομπότ πιστεύει τυφλά ότι οι μετρήσεις είναι σωστές, θα λαμβάνει λανθασμένες αποφάσεις. Η αβεβαιότητα πρέπει να μετράται και να τροφοδοτεί τους downstream αλγορίθμους.

Γιατί είναι δύσκολο;

Η κατάσταση (θέση, κατεύθυνση) εξελίσσεται μη-γραμμικά (unicycle kinematics). Ο linear Kalman Filter δεν αρκεί — χρειάζεται linearization (EKF) ή sigma-points (UKF).

② Αναλογία & Διαίσθηση

Ντετέκτιβ με αβέβαιες μαρτυρίες: δεν λέει «ο ύποπτος είναι σίγουρα εκεί». Λέει «με 85% πιθανότητα ήταν μεταξύ A και B, βασισμένος σε 3 αναξιόπιστους μάρτυρες». Ο EKF συνδυάζει «πού πρέπει να είμαι βάσει κίνησης» + «τι λένε οι αισθητήρες» — σταθμισμένα από αξιοπιστία.

③ Τι Έκανα Ακριβώς — Βήμα-Βήμα

- Υλοποίησα EKF για unicycle model: state = $[x, y, \theta]$
- Process model: μη-γραμμικά unicycle kinematics + Gaussian noise $w_t \sim N(0, Q)$
- Measurement model: LiDAR range/bearing + odometry + noise $v_t \sim N(0, R)$
- EKF predict: linearization μέσω Jacobian $F_t = \partial f / \partial s$, propagate covariance
- EKF update: Kalman gain K_t , update mean και covariance
- UKF alternative: sigma-point propagation (χωρίς Jacobian)
- Output: belief $(\mu_t, \Sigma_t) \rightarrow$ τροφοδοτεί C03 (risk planner) και C08 (IDS)

Ροή Δεδομένων

Odometry control + LiDAR readings $\rightarrow$ EKF predict step $\rightarrow$ EKF update step $\rightarrow$ belief $(\mu_t, \Sigma_t) \rightarrow$ risk planner / safety shield / IDS

④ Βαθιά Τεχνική Ανάλυση

Βασικά Components

- State vector: $[x, y, \theta]^T$ — 2D θέση και κατεύθυνση
- EKF predict: $\hat{\mu} = f(\mu_{t-1}, a_t)$, $\hat{P} = F_t P_{t-1} F_t^T + Q$
- EKF update: $K = \hat{P} H^T (H \hat{P} H^T + R)^{-1}$, $\mu_t = \hat{\mu} + K(z_t - h(\hat{\mu}))$, $P_t = (I - KH)\hat{P}$
- UKF sigma points: $2n+1$ deterministic samples που αναπαριστούν τη Gaussian

- Uncertainty scalar: $\text{tr}(\Sigma_t)$ — καταναλώνεται ως risk amplifier από C03

Pseudocode / Αλγόριθμος

```

EKF PREDICT:
   $\mu_t = f(\mu_{t-1}, a_t)$  // nonlinear propagation
   $F_t = \partial f / \partial s |_{\mu_{t-1}}$  // Jacobian linearization
   $P_t = F_t P_{t-1} F_t^T + Q$  // covariance propagation

EKF UPDATE:
   $H_t = \partial h / \partial s |_{\mu_t}$  // observation Jacobian
   $K_t = P_t H_t^T (H_t P_t H_t^T + R)^{-1}$  // Kalman gain
   $\mu_t = \mu_t + K_t (z_t - h(\mu_t))$  // correct mean
   $P_t = (I - K_t H_t) P_t$  // reduce uncertainty

UKF (εναλλακτικά):
   $\chi_0 = \mu$ ,  $\chi_i = \mu + (\text{sqrt}((n+\lambda)P))_i$  για  $i=1..n$ 
  propagate όλα τα sigma points μέσω  $f \rightarrow$  compute weighted mean/cov

```

Μαθηματική Φορμοποίησηση

```

State-space:  $s_{t+1} = f(s_t, a_t) + w_t$ ,  $z_t = h(s_t) + v_t$ 
Noise:  $w_t \sim N(0, Q)$ ,  $v_t \sim N(0, R)$ 
Innovation:  $v_k = z_k - h(\mu_k) \sim N(0, S_k)$  υπό φυσιολογικές συνθήκες
NEES:  $(s_t - \mu_t)^T P_t^{-1} (s_t - \mu_t) \sim \chi^2(n)$  αν filter consistent
EKF optimal αν  $f, h$  γραμμικές. Για nonlinear: approximation μέσω linearization

```

Πολυπλοκότητα & Παραδοχές

Χρονική πολυπλοκότητα: EKF: $O(n^2)$ ανά βήμα ($n=3$: negligible). UKF: $O(n^3)$ λόγω matrix sqrt. Και τα δύο real-time.

- Gaussian noise — EKF/UKF αποτυγχάνουν αν noise είναι bimodal ή heavy-tailed
- Q και R γνωστά — στην πράξη πρέπει να tuned (δεν τεκμηριώθηκε systematic calibration)
- Χωρίς loop closure — EKF diverges σε μακρές διαδρομές χωρίς εξωτερική διόρθωση
- Unimodal belief — αποτυγχάνει σε συμμετρικά περιβάλλοντα (bimodal uncertainty)

⑤ Ερευνητική Αξία

Ερευνητικό Ερώτημα

Πώς η ποιότητα της belief-state uncertainty estimation επηρεάζει τη downstream risk-aware planning και formal safety verification;

Novelty — Τι Καινούργιο Κάνω

EKF/UKF είναι textbook μέθοδοι (Thrun 2005). Η novelty: systems integration — η αβεβαιότητα Σ ως first-class signal που τρέφει ταυτόχρονα planning (C03), safety (C18), και security (C08). Αυτή η unified αντιμετώπιση δεν είναι στα standard navigation papers.

Σχετική Βιβλιογραφία

Thrun, Burgard, Fox — Probabilistic Robotics (2005). Wan & Merwe (2000) UKF. Montemerlo et al. (2002) FastSLAM. Julier & Uhlmann (1997) original UKF.

⑥ Αποτελέσματα & Τι Σημαίνουν

Σωστή belief propagation validated in simulation. RMSE εκτίμησης θέσης μετρήθηκε vs ground truth. Covariance trace χρησιμοποιείται επιτυχώς από risk planner.

Metrics

- RMSE εκτίμησης θέσης (m)
- Covariance trace $\text{tr}(\Sigma_t)$ over time
- NEES score — filter consistency test
- Innovation bound violations — flags anomalies (→ C08 IDS)

Τι Λείπει Ακόμα

Δεν υπάρχει σύγκριση EKF vs UKF σε high-curvature trajectories. Δεν αξιολογήθηκε με πραγματικό TurtleBot3. Q,R tuning δεν τεκμηριώθηκε. Δεν αναλύθηκε filter divergence σε long-duration runs.

⑦ Αυστηρή Κριτική — Reviewer Mode

Αδυναμίες

- EKF/UKF είναι 50+ χρόνων μέθοδοι — δεν υπάρχει αλγοριθμική novelty
- Gaussian assumption αποτυγχάνει κοντά σε symmetric junctions (particle filter καλύτερο)
- Manual Q,R tuning χωρίς systematic calibration — reproducibility concern
- Χωρίς loop closure → divergence σε extended operation

Κρυφές Παραδοχές

- Unimodal position distribution (false near symmetric environments)
- Noise stationarity (false during acceleration ή terrain changes)
- Process model f ακριβώς γνωστό (wheel diameter αλλάζει με φθορά)

Σενάρια Αποτυχίας

- Long corridors χωρίς landmarks → EKF diverges
- Symmetric environments → multimodal belief, EKF κολλάει στο λάθος mode
- Sensor dropout → pure prediction diverges
- Adversarial noise (C08 scenario) → EKF ενσωματώνει corrupted measurements

⑧ Πώς Γίνεται Δημοσίευση

Τίτλος Paper	Belief-State Uncertainty Infrastructure for Risk-Aware and Formally-Safe Robot Navigation
Venue	Όχι standalone — Section 3 ενός system paper (ICRA/RA-L)

Missing Experiments

- EKF vs UKF vs particle filter σε high-curvature trajectories
- Real TurtleBot3: fuse wheel odometry + RPLiDAR, validate vs OptiTrack

- Long-duration sessions (30+ λεπτά): NEES consistency analysis
- Q/R sensitivity: πώς επηρεάζει η miscalibration το downstream planning;

Ablations που Χρειάζονται

- EKF vs UKF: πότε τα sigma points κάνουν διαφορά;
- Επίδραση ποιότητας belief στο CVaR planning (C03)
- EKF vs particle filter σε symmetric environment

9) Ανοιχτά Ερευνητικά Ερωτήματα

4. Μπορεί Q και R να calibrated αυτόματα χωρίς ground truth (EM algorithm);
5. Μπορεί το Σ_t να χρησιμοποιηθεί απευθείας ως CBF safety constraint (C18);
6. Ποιο είναι το minimum sensor quality για να ισχύουν τα formal safety guarantees;

10) Αν Είχα 2 Λεπτά να το Εξηγήσω σε Οποιονδήποτε...

Κανένας αισθητήρας δεν είναι τέλειος — το LiDAR κάνει λάθη, οι τροχοί γλιστράνε. Αντί να αγνοούμε αυτό, χρησιμοποιούμε τον Kalman Filter: ένα μαθηματικό εργαλείο που συνδυάζει «πού πρέπει να είμαι βάσει κίνησης» με «τι λένε οι αισθητήρες», σταθμισμένα από το πόσο αξιόπιστο είναι καθένα. Αποτέλεσμα: μια κατανομή πιθανότητας για τη θέση — όχι μόνο ένα σημείο αλλά «πιθανώς εδώ, με αβεβαιότητα $\pm X$ εκ.». Αυτή η αβεβαιότητα τροφοδοτεί κάθε άλλο module του DynNav.

Βαθμολογία

Διάσταση	Βαθμός	Σχόλιο
Πρωτοτυπία	4/10	Γνωστή μέθοδος
Τεχνικό Βάθος	7/10	Prototype επίπεδο
Δημοσιευσιμότητα	3/10	Concept μόνο
PhD Δυναμικό	5/10	Υποστηρικτικό υλικό

Contribution 03 Belief-Space Risk-Aware Planning — CVaR A*

Κατηγορία: Risk-Sensitive Planning

① Εξήγηση για Αρχάριο — Από το Μηδέν

Τι πρόβλημα λύνει;

Η συντομότερη διαδρομή δεν είναι πάντα η καλύτερη. Αν περάσεις 2εκ. από αιχμηρή γωνία, μια μικρή αστοχία αισθητήρα φτάνει για σύγκρουση. Αυτό το module βρίσκει διαδρομές που ισορροπούν απόσταση ΚΑΙ ρίσκο.

Γιατί υπάρχει αυτό το πρόβλημα;

Ο κλασικός A* βελτιστοποιεί μόνο απόσταση. Σε πραγματικά περιβάλλοντα με noise αισθητήρων και αβέβαιους χάρτες, μια λίγο πιο μακριά αλλά ασφαλής διαδρομή είναι πολύ προτιμότερη.

Γιατί είναι δύσκολο;

Πώς να ορίσεις «ρίσκο» μαθηματικά; Η μέση πιθανότητα σύγκρουσης αγνοεί τα rare catastrophic events. CVaR (Conditional Value at Risk) — μέτρο από finance — λύνει αυτό: εστιάζει στα χειρότερα σενάρια.

② Αναλογία & Διαίσθηση

Ασφαλιστής: δεν τιμολογεί με βάση τον μέσο κίνδυνο — τιμολογεί για tail risk (σπάνια αλλά καταστροφικά events). Ο ορεινός πεζοπόρος: επιλέγει την ελαφρώς μακρύτερη αλλά ασφαλή διαδρομή αντί για τη μικρότερη στην άκρη του γκρεμού.

③ Τι Έκανα Ακριβώς — Βήμα-Βήμα

- Τροποποίησα την A* cost function για να συμπεριλαμβάνει CVaR risk term ανά κελί
- Risk maps από: EKF uncertainty (C02) ή diffusion occupancy samples (C12)
- $CVaR_\alpha(X) = E[X|X \geq VaR_\alpha(X)]$ — mean of the worst (1- α) fraction
- Parameter λ ελέγχει safety-efficiency tradeoff — systematic sweep
- Ablation: risk-agnostic A* vs risk-aware A* σε 30+ simulated environments

Ροή Δεδομένων

Occupancy belief + N samples → CVaR per cell → risk cost map → modified A* → ασφαλής βέλτιστη διαδρομή

④ Βαθιά Τεχνική Ανάλυση

Βασικά Components

- Risk map builder: per-cell CVaR από belief state ή diffusion samples
- CVaR estimator: sort N samples, average top (1- α)·N fraction
- Modified A*: standard algorithm με risk-augmented edge costs
- Pareto analyzer: sweeps $\lambda \in [0, \infty)$, records (path_length, risk_along_path)
- Plug-in interface: οποιαδήποτε probabilistic occupancy source → ίδιος planner

Pseudocode / Αλγόριθμος

```
KATAΣΚΕΥΗ RISK MAP:
για κάθε κελί c:
    samples = [occupancy_sample(c) για _ σε range(N)]
    sorted_s = sort(samples)
    CVaR[c] = mean(sorted_s[ceil(α*N):]) // worst (1-α) samples

RISK-AUGMENTED A*:
f(n) = g(n) + λ * CVaR[n] + h(n)
open_list ταξινομημένη κατά f(n) → standard A* expansion
```

Μαθηματική Φορμοποίησηση

```
CVaR_α(X) = E[X | X ≥ VaR_α(X)] = (1/(1-α)) ∫_α^1 VaR_u(X) du
Empirical: CVaR_α = (1/|T|) Σ_{i∈T} x_(i) όπου T = top (1-α) · N indices
Augmented cost: f(s) = g(s) + λ · CVaR_α(p_col(s)) + h(s)
Planning: π* = argmin_{π: s→g} Σ_{s∈π} [c(s) + λ · CVaR_α(p_col(s))]
λ=0: pure A* | λ→∞: maximum risk aversion
```

Πολυπλοκότητα & Παραδοχές

Χρονική πολυπλοκότητα: Ίδιο με A*: $O(b^d)$. CVaR computation: $O(N \log N)$ per cell update.

- Risk = collision probability από static occupancy (αγνοεί dynamic obstacles)
- CVaR sample set representative of true occupancy distribution
- Ίδιο λ optimal σε όλα τα environments (unrealistic)
- Per-cell risks ανεξάρτητα (αγνοεί χωρικές correlations)

⑤ Ερευνητική Αξία

Ερευνητικό Ερώτημα

Ποιο είναι το θεμελιώδες Pareto tradeoff μεταξύ path efficiency και CVaR tail-risk στη probabilistic πλοήγηση; Πώς εξαρτάται από τη δομή του environment και την ποιότητα του belief;

Novelty — Τι Καινούργιο Κάνω

Η modular αρχιτεκτονική: οποιοδήποτε probabilistic occupancy estimator (EKF, diffusion, NeRF) συνδέεται στον ίδιο risk-augmented planner. Αυτό το clean plug-in interface δεν εμφανίζεται στα standard CVaR navigation papers.

Σχετική Βιβλιογραφία

Majumdar & Pavone (2020) — CVaR motion planning. Ono & Williams (2008) — chance-constrained planning. Van den Berg et al. (2011) — LQG-MP.

⑥ Αποτελέσματα & Τι Σημαίνουν

Καθαρή Pareto καμπύλη: αύξηση λ → αύξηση path length, μείωση risk. Risk-aware planner αποφεύγει στενούς διαδρόμους. Qualitative demonstrations.

Metrics

- Path length (m)
- CVaR collision probability along path

- Κελιά με occupancy > 0.5 within 1 robot radius
- Pareto efficiency: area under risk-length curve

Τι Λείπει Ακόμα

Δεν υπάρχει σύγκριση με chance-constrained ή robust MPC planners. Δεν αξιολογήθηκε σε dynamic environments. Δεν υπάρχει hardware validation. Δεν δίνεται principled method για επιλογή λ .

⑦ Αυστηρή Κριτική — Reviewer Mode

Αδυναμίες

- CVaR planning για robotics είναι established (Majumdar & Pavone 2020) — χρειάζεται ισχυρότερη differentiation
- Fixed λ : δεν adapts στο environment ή task criticality
- Static risk map: δεν αντιδρά σε moving obstacles
- Per-cell CVaR αγνοεί χωρικές correlations μεταξύ γειτονικών κελιών

Κρυφές Παραδοχές

- Risk = occupancy probability (misses dynamic και intentional hazards)
- Ίδιο λ optimal σε όλα τα environments
- N samples sufficient για CVaR estimation (variance δεν αναλύθηκε)

Σενάρια Αποτυχίας

- High λ : robot αρνείται να κινηθεί αν όλες οι διαδρομές περνούν από risky κελιά
- Dynamic obstacles: risk map γίνεται stale
- Overconfident belief: EKF underestimates $\sigma \rightarrow$ CVaR underestimates true risk

⑧ Πώς Γίνεται Δημοσίευση

Τίτλος Paper	Modular CVaR-Augmented A* for Risk-Sensitive Navigation Under Probabilistic Occupancy Uncertainty
Venue	IROS / RA-L

Missing Experiments

- Σύγκριση CVaR A* vs chance-constrained A* vs risk-neutral A* σε identical maps
- Dynamic environments: update risk map mid-execution, measure collision reduction
- Hardware: TurtleBot3 σε known-hazard environment
- λ selection study: ποιο λ minimizes total cost (path length + collisions);

Ablations που Χρειάζονται

- CVaR _{α} sensitivity: $\alpha=0.95$ vs 0.8 vs 0.5
- Static vs dynamically updated risk map
- EKF-derived vs diffusion-derived risk map
- Risk map resolution: coarse vs fine

9) Ανοιχτά Ερευνητικά Ερωτήματα

7. Μπορεί λ να μαθαίνεται από human preferences (inverse reward learning);
8. Μπορεί CVaR να υπολογίζεται closed-form για Gaussian beliefs;
9. Πώς compound τα risks κατά μήκος μιας διαδρομής — ανεξάρτητα ή correlated;

10) Αν Είχα 2 Λεπτά να το Εξηγήσω σε Οποιονδήποτε...

Η συντομότερη διαδρομή δεν είναι πάντα η καλύτερη. Αν περνάς 2εκ. από εμπόδιο, μια μικρή αστοχία αισθητήρα = σύγκρουση. Αυτό το module μαθαίνει τον planner να σκέφτεται σαν ασφαλιστής: ελαχιστοποιεί τον κίνδυνο στα ΧΕΙΡΟΤΕΡΑ σενάρια (CVaR), όχι τον μέσο. Ένα slider λ ελέγχει πόσο «φοβικός» είναι ο ρομπότ: χαμηλό λ = γρήγορος αλλά ριψοκίνδυνος, υψηλό λ = αργός αλλά ασφαλής.

Βαθμολογία

Διάσταση	Βαθμός	Σχόλιο
Πρωτοτυπία	6/10	Incremental
Τεχνικό Βάθος	8/10	Πλήρης μαθ. ανάλυση
Δημοσιευσιμότητα	7/10	Χρειάζεται experiments
PhD Δυναμικό	7/10	Υποστηρικτικό υλικό

Contribution 04 Irreversibility & Returnability — Αποφυγή Αδιεξόδων

Κατηγορία: Ασφάλεια / Εξερεύνηση

① Εξήγηση για Αρχάριο — Από το Μηδέν

Τι πρόβλημα λύνει;

Πριν πάει κάπου, το ρομπότ ρωτάει: «Αν πάω εκεί, θα μπορώ να επιστρέψω;» Αν η απάντηση είναι ΟΧΙ, αποφεύγει αυτή την κατεύθυνση.

Γιατί υπάρχει αυτό το πρόβλημα;

Σε άγνωστο περιβάλλον, το ρομπότ μπορεί να μπει σε διάδρομο χωρίς έξοδο. Αν μείνει εκεί, η αποστολή αποτυγχάνει. Η πρόληψη είναι πολύ καλύτερη από την ανάκαμψη.

Γιατί είναι δύσκολο;

Ο έλεγχος «μπορώ να επιστρέψω;» απαιτεί backward reachability analysis — ουσιαστικά ένα δεύτερο planning πρόβλημα. BFS approximation είναι tractable αλλά χάνει formal guarantees.

② Αναλογία & Διαίσθηση

Σκακιστής: δεν κοιτάει μόνο την επόμενη κίνηση — βεβαιώνεται ότι δεν θα «παγιδευτεί» σε αδύναμη θέση πολλές κινήσεις αργότερα. Ορεινός πεζοπόρος: πριν κατεβεί σε χαράδρα ρωτάει «αν αλλάξει ο καιρός, μπορώ να ανέβω πίσω;»

③ Τι Έκανα Ακριβώς — Βήμα-Βήμα

- Ορισμός safe set S_{safe} : χώρος φόρτισης, είσοδος, recovery zone
- Backward BFS από S_{safe} στον current occupancy grid
- Υπολογισμός $d_G(s, S_{\text{safe}})$ για κάθε κελί σε $O(W \cdot H)$
- Returnability: $\text{Ret}_H(s) = 1$ αν $d_G(s, S_{\text{safe}}) \leq H$ αλλιώς 0
- Modified A* cost: $f(s) = g(s) + \lambda \cdot \text{CVaR}(s) + \gamma \cdot (1 - \text{Ret}_H(s)) + h(s)$
- Δύο modes: soft (ποινή γ) και hard (αποκλεισμός non-returnable κελιών)

Ροή Δεδομένων

$\text{Current map} + S_{\text{safe}} \rightarrow \text{backward BFS} \rightarrow d_G(s, S_{\text{safe}}) \forall s \rightarrow \text{Ret}_H(s) \rightarrow \text{modified A* cost} \rightarrow \text{returnability-safe path}$

④ Βαθιά Τεχνική Ανάλυση

Βασικά Components

- Backward BFS: $O(W \cdot H)$ sweep από S_{safe} , labels all reachable distances
- Returnability predicate: $\text{Ret}_H(s) = 1[d_G(s, S_{\text{safe}}) \leq H]$
- Cost augmentation: $c_{\text{irrev}}(s) = \gamma \cdot (1 - \text{Ret}_H(s))$ added to A* edge cost
- Hard-constraint mode: remove non-returnable cells από A* open list

Pseudocode / Αλγόριθμος

```
BACKWARD BFS ΑΠΟ S_safe:
  dist = {s: ∞ για κάθε s}
  dist[S_safe] = 0; queue = deque([S_safe])
  while queue:
    s = queue.popleft()
    για κάθε γείτονα n του s:
      αν occ[n] < 0.5 και dist[n] == ∞:
        dist[n] = dist[s] + 1
        queue.append(n)

RETURNABILITY CHECK:
  Ret_H(s) = 1 αν dist[s] ≤ H αλλιώς 0
```

Μαθηματική Φορμοποίησηση

```
Returnability: Ret_H(s) = 1[d_G(s, S_safe) ≤ H]
d_G: graph shortest path στον current occupancy grid
Irrev. penalty: c_irrev(s) = γ · (1 - Ret_H(s)) ∈ {0, γ}
BRT(S_safe): {s : ∃ path από s σε S_safe} ← true backward reachable set
BFS approximation: BRT ∩ {s : d_G(s, S_safe) ≤ H} — συντηρητικό
```

Πολυπλοκότητα & Παραδοχές

Χρονική πολυπλοκότητα: BFS: $O(W \cdot H)$. Per-action lookup: $O(1)$. Memory: $O(W \cdot H)$ για distance map.

- Safe set S_safe είναι static και αρχικά reachable
- BFS horizon H αρκετό για να καλύψει relevant returnability constraints
- Current occupancy map αρκετά ακριβής για BFS
- Robot μπορεί να αντιστρέψει (non-holonomic constraints δεν λαμβάνονται υπόψη)

⑤ Ερευνητική Αξία

Ερευνητικό Ερώτημα

Μπορεί proactive BFS-horizon returnability checking να μειώσει αποδεδειγμένα το rate of irreversible state entry σε unknown environments;

Novelty — Τι Καινούργιο Κάνω

Σύνδεση navigation με safe exploration theory (Moldovan & Abbeel 2012) μέσω BFS-horizon approximation. Η integration με CVaR planning (C03) και world-model pre-screening (C13) δημιουργεί multi-layer irreversibility defense.

Σχετική Βιβλιογραφία

Moldovan & Abbeel (2012) — safe exploration in MDPs. Gillula & Tomlin (2011) — HJ reachability. Schmerling et al. — backward reachability.

⑥ Αποτελέσματα & Τι Σημαίνουν

Qualitative demonstration: robot αποφεύγει dead-end corridors. Rate irreversible state entry μειώθηκε vs baseline A^* . Path length overhead μετρήθηκε.

Metrics

- Irreversible state entries per episode
- Mission completion rate
- Path length overhead του returnability constraint
- Horizon H sensitivity

Τι Λείπει Ακόμα

Δεν υπάρχει formal proof ότι BFS horizon $\approx$ backward reachability. Δεν συγκρίθηκε με exact HJ reachability. Δεν αναλύθηκε BFS error rate υπό uncertain maps.

⑦ Αυστηρή Κριτική — Reviewer Mode

Αδυναμίες

- BFS horizon είναι approximation — formal backward reachability δεν υπολογίζεται
- H πρέπει να tuned — δεν δίνεται principled method
- Non-holonomic robots: BFS path μπορεί να μην είναι kinematically feasible
- Υπό uncertain maps: returnable states μπορεί να flagged λανθασμένα

Κρυφές Παραδοχές

- S_{safe} πάντα reachable στην αρχή του episode
- Robot dynamics επιτρέπουν reversal
- Occupancy map αρκετά ακριβής για BFS (μπορεί να λανθάνει σε unexplored areas)

Σενάρια Αποτυχίας

- Dynamic obstacles κλείνουν return path μετά που το ρομπότ περάσει
- H πολύ μικρό: BFS misses returnable states, overly conservative
- Non-holonomic robot: BFS path δεν εκτελείται kinematically

⑧ Πώς Γίνεται Δημοσίευση

Τίτλος Paper	Returnability-Constrained Navigation: Safe Exploration via Backward Reachability Approximation
Venue	ICRA Safety Workshop / RA-L

Missing Experiments

- Σύγκριση με exact HJ reachability σε identical scenarios
- Monte Carlo: πόσο συχνά BFS-H misclassifies returnable states;
- Real robot: TurtleBot3 σε maze environment — παγιδεύεται;
- H sensitivity sweep

Ablations που Χρειάζονται

- Soft vs hard returnability constraint
- H sensitivity σε διαφορετικές topologies
- Με vs χωρίς occupancy uncertainty inflation στο BFS map

9) Ανοιχτά Ερευνητικά Ερωτήματα

10. Μπορεί probabilistic returnability ($P(\text{returnable}) \geq p$) να υπολογίζεται tractably;
11. Μπορεί returnability να συνδυαστεί με CBF (C18) για formal continuous-time guarantees;
12. Πώς να επιλέγεται S_{safe} dynamically καθώς το ρομπότ εξερευνά;

10) Αν Είχα 2 Λεπτά να το Εξηγήσω σε Οποιονδήποτε...

Πριν το ρομπότ πάει κάπου, κάνει μια απλή αλλά κρίσιμη ερώτηση: «Αν πάω εκεί, θα μπορώ να γυρίσω στη βάση;» Αν η απάντηση είναι ΟΧΙ, αποφεύγει αυτή την κατεύθυνση ή της βάζει επιπλέον κόστος. Αυτό αποτρέπει το ρομπότ από το να παγιδεύεται σε αδιέξοδα — ένα πρόβλημα που ο κλασικός A^* δεν λαμβάνει καθόλου υπόψη.

Βαθμολογία

Διάσταση	Βαθμός	Σχόλιο
Πρωτοτυπία	7/10	Incremental
Τεχνικό Βάθος	7/10	Prototype επίπεδο
Δημοσιευσιμότητα	6/10	Χρειάζεται experiments
PhD Δυναμικό	7/10	Υποστηρικτικό υλικό

Contribution 05 Safe-Mode FSM — Αυτόματη Ασφαλής Λειτουργία

Κατηγορία: Ασφάλεια / Συμπεριφορά

① Εξήγηση για Αρχάριο — Από το Μηδέν

Τι πρόβλημα λύνει;

Τρεις καταστάσεις: ΚΑΝΟΝΙΚΗ (γρήγορο, κανονικό), ΑΣΦΑΛΗΣ (αργό, μεγάλα margins), ΕΚΤΑΚΤΗ ΑΝΑΓΚΗ (σταμάτα). Αλλάζει αυτόματα ανάλογα με το ρίσκο — χωρίς χειροκίνητη παρέμβαση.

Γιατί υπάρχει αυτό το πρόβλημα;

Μια σταθερή πολιτική κίνησης είναι είτε too slow παντού είτε too risky σε επικίνδυνες καταστάσεις. Χρειάζεται adaptive behavior που ανταποκρίνεται στο τρέχον επίπεδο κινδύνου.

Γιατί είναι δύσκολο;

Η μεταπήδηση πρέπει να αποφεύγει rapid oscillation (chatter). Υστέρηση (hysteresis) λύνει αυτό αλλά εισάγει 6 hyperparameters χωρίς principled tuning method.

② Αναλογία & Διαίσθηση

Αυτοκίνητο σε σχολική ζώνη: αυτόματα μειώνει ταχύτητα όταν πλησιάζει. Θερμοστάτης με υστέρηση: ανάβει στους 18°C, σβήνει στους 21°C — δεν εναλλάσσεται συνεχώς. Νοσοκόμα σε ΜΕΘ: αλλάζει αυτόματα συμπεριφορά ανάλογα με τον χώρο.

③ Τι Έκανα Ακριβώς — Βήμα-Βήμα

- Ορισμός τριών modes: NORMAL, SAFE, EMERGENCY
- NORMAL: $v_max = v_n$, inflation = r_n (κανονική λειτουργία)
- SAFE: $v_max = \alpha \cdot v_n$ ($\alpha < 1$), inflation = $\beta \cdot r_n$ ($\beta > 1$), conservative planner
- EMERGENCY: $v_max = 0$, alert operator, halt
- Risk signal: CVaR score από C03 ή IDS alarm από C08
- Hysteresis: T_hold consecutive low-risk steps → SAFE→NORMAL
- Mode transitions: NORMAL→SAFE αν $risk > \tau_hi$ | SAFE→NORMAL αν $risk < \tau_lo$ για T_hold

Ροή Δεδομένων

CVaR risk score → threshold comparisons + hysteresis timer → mode FSM → velocity cap + inflation radius + planner selection → modified action

④ Βαθιά Τεχνική Ανάλυση

Βασικά Components

- Mode FSM: states {NORMAL, SAFE, EMERGENCY}, transitions defined by thresholds
- Hysteresis timer: counts consecutive low-risk steps before mode drop

- Per-mode actuators: velocity cap $\alpha \cdot v_max$, inflation $\beta \cdot r_nominal$
- Integration: EMERGENCY triggers C08 alert, C14 log event

Pseudocode / Αλγόριθμος

```
MODE FSM (ανά timestep):
  αν risk >  $\tau\_critical$ :          mode = EMERGENCY; send_alert()
  αλλιώς αν risk >  $\tau\_hi$ :          mode = SAFE; timer = 0
  αλλιώς αν mode == SAFE:
    αν risk <  $\tau\_lo$ : timer += 1 // counting toward NORMAL
    αλλιώς:          timer = 0
    αν timer >=  $T\_hold$ : mode = NORMAL

ACTION MODIFICATION:
  αν mode == SAFE:    v_cmd = min(v_cmd,  $\alpha \cdot v\_max$ ); inflation =  $\beta \cdot r\_n$ 
  αν mode == EMERGENCY: v_cmd = 0
```

Μαθηματική Φορμοποίησηση

Hysteresis: αποτρέπει Zeno behavior (άπειρες μεταπηδήσεις σε πεπερασμένο χρόνο)

Deadband: $risk \in [\tau_lo, \tau_hi] \rightarrow$ δεν προκαλεί mode switch

SAFE dwell time: $E[T_SAFE]$ εξαρτάται από risk distribution και τ parameters

Switching frequency bound: max 1 SAFE→NORMAL ανά T_hold steps

Πολυπλοκότητα & Παραδοχές

Χρονική πολυπλοκότητα: $O(1)$ ανά timestep — threshold comparison και timer increment μόνο.

- Risk signal από C03 αρκετά calibrated (inherited assumption)
- 6 hyperparameters (τ_hi , τ_lo , τ_crit , T_hold , α , β) σωστά tuned
- EMERGENCY απαιτεί manual reset (impractical for fully autonomous systems)
- Single scalar risk αρκεί (αγνοεί directional ή contextual danger)

⑤ Ερευνητική Αξία

Ερευνητικό Ερώτημα

Αποτρέπει risk-triggered hysteretic mode switching τις safety constraint παραβιάσεις συγκριτικά με fixed-parameter navigation, με bounded efficiency overhead;

Novelty — Τι Καινούργιο Κάνω

Το FSM δεν είναι novel. Η full-stack integration είναι: risk signal από CVaR (C03), connection σε formal safety (C18), causal attribution on alarm events (C14). Ο συντονισμός είναι η συνεισφορά.

Σχετική Βιβλιογραφία

Standard supervisory control theory. Bohren & Cousins (2010) SMACH for ROS. Tedrake (2010) LQR-trees.

⑥ Αποτελέσματα & Τι Σημαίνουν

Mode transitions correctly triggered. Velocity reduction in SAFE mode measurably reduces collision rate. Hysteresis prevents oscillation.

Metrics

- Mode transition rate per episode
- Time fraction σε κάθε mode
- Collision rate per mode
- Path time overhead: safe-mode vs no safe-mode

Τι Λείπει Ακόμα

Δεν υπάρχει formal proof ότι mode switching μειώνει collision probability. Δεν υπάρχει hyperparameter sensitivity analysis. Δεν υπάρχει σύγκριση με continuous risk-response.

⑦ Αυστηρή Κριτική — Reviewer Mode

Αδυναμίες

- FSM με hysteresis είναι 1970s engineering — όχι research contribution από μόνο του
- 6 hyperparameters χωρίς principled tuning method
- EMERGENCY με manual reset — impractical
- Single scalar risk misses directional danger

Κρυφές Παραδοχές

- Risk signal calibrated (from C03 — inherited assumption)
- Single scalar captures all safety dimensions
- Human operator available for EMERGENCY recovery

Σενάρια Αποτυχίας

- Very fast obstacles: safe mode switch δεν προλαβαίνει
- False IDS alarms (C08) triggering unnecessary SAFE mode
- Parameters tuned για ένα environment, αποτυγχάνουν σε άλλο

⑧ Πώς Γίνεται Δημοσίευση

Τίτλος Paper	Risk-Aware Behavioral Mode Switching: A Hybrid Automaton Approach (ως μέρος system paper)
Venue	Όχι standalone. Μέρος system paper — ICRA/RA-L

Missing Experiments

- Formal analysis: μειώνει mode switching τα E[collision rate] vs fixed safe policy;
- Hyperparameter sweep: όλα τα 6 params, robustness report
- Continuous vs discrete risk response comparison
- Hardware: TurtleBot3 σε cluttered environment

Ablations που Χρειάζονται

- Με vs χωρίς hysteresis: αποτρέπει πράγματι chatter;
- 3 modes vs 2 modes vs continuous risk scaling
- T_hold sensitivity

⑨ Ανοιχτά Ερευνητικά Ερωτήματα

13. Μπορεί continuous risk-to-behavior mapping να αντικαταστήσει το discrete FSM;
14. Μπορεί EMERGENCY recovery να γίνει αυτόματο — ποιες ελάχιστες ασφαλείς κινήσεις;
15. Μπορούν πολλαπλά ρομπότ να χρησιμοποιούν coordinated mode switching (fleet-level safe mode);

⑩ Αν Είχα 2 Λεπτά να το Εξηγήσω σε Οποιονδήποτε...

Όταν το ρομπότ νιώθει κίνδυνο — εμπόδια κοντά, μεγάλη αβεβαιότητα — αυτόματα επιβραδύνει και γίνεται πιο προσεκτικό. Όταν ο κίνδυνος υποχωρεί, επιστρέφει σε κανονική λειτουργία. Μια σκόπιμη καθυστέρηση (hysteresis) αποτρέπει ανάδελτα συμπεριφορά. Σκέψου το σαν cruise control για ασφάλεια: διατηρεί κατάλληλη συμπεριφορά χωρίς να χρειάζονται explicit κανόνες για κάθε κατάσταση.

Βαθμολογία

Διάσταση	Βαθμός	Σχόλιο
Πρωτοτυπία	4/10	Γνωστή μέθοδος
Τεχνικό Βάθος	6/10	Prototype επίπεδο
Δημοσιευσιμότητα	4/10	Concept μόνο
PhD Δυναμικό	5/10	Υποστηρικτικό υλικό

Contribution 06 Energy & Connectivity-Aware Planning

Κατηγορία: Σχεδιασμός / Πόροι

① Εξήγηση για Αρχάριο — Από το Μηδέν

Τι πρόβλημα λύνει;

Η μπαταρία έχει όριο και το WiFi δεν φτάνει παντού. Αυτό το module βρίσκει διαδρομές που (α) φτάνουν στον στόχο χωρίς να αδειάσει η μπαταρία και (β) διατηρούν αποδεκτό σήμα WiFi όλη τη διαδρομή.

Γιατί υπάρχει αυτό το πρόβλημα;

Ρομπότ που μένει μεσοδρόμια χωρίς μπαταρία ή χάνει επικοινωνία δεν είναι χρήσιμο — και μπορεί να είναι επικίνδυνο. Πρακτικός περιορισμός για οποιοδήποτε real deployment.

Γιατί είναι δύσκολο;

Constrained shortest path είναι NP-hard γενικά. Χρειάζεται έξυπνη approximation (resource-extended A* ή Lagrangian relaxation) που κλιμακώνεται linearly με το budget.

② Αναλογία & Διαίσθηση

Road trip με μικρό ρεζερβουάρ: δεν παίρνεις τον πιο γρήγορο δρόμο — σχεδιάζεις γύρω από πρατήρια καυσίμων. Αν χρειάζεσαι και WiFi για δουλειά, αποφεύγεις και τούνελ. Ο planner έχει τώρα τρεις στόχους: γρήγορο, γεμάτο ρεζερβουάρ, με σήμα.

③ Τι Έκανα Ακριβώς — Βήμα-Βήμα

- Energy cost model: $e_cost(edge) = P_motor \times distance \times terrain_factor \times \kappa$
- Connectivity map: $q(s) \in [0,1]$ — WiFi signal quality per cell
- Resource-extended A*: state = (θέση, cumulative_energy)
- Pruning: discards nodes όπου $E_cum + h_E > B$ (energy budget B)
- Lagrangian relaxation: $\lambda_E \cdot e_cost + \lambda_Q \cdot (Q_min - q(s))^+$ added to cost
- Charging detour: αν δεν υπάρχει feasible direct path, plan via charging station

Ροή Δεδομένων

Battery B + connectivity map $q(s)$ + terrain map $\rightarrow$ resource-extended A $\rightarrow$ feasible path respecting both constraints*

④ Βαθιά Τεχνική Ανάλυση

Βασικά Components

- Energy map: terrain_factor $\kappa(terrain) \in [1,5]$ per cell
- Connectivity map: $q(s)$ από WiFi RSSI measurements ή model
- Resource-extended state space: (position, energy_band) — discretized tracking
- Charging station router: δύο A* calls με waypoint στο charging station

Pseudocode / Αλγόριθμος


```

RESOURCE-EXTENDED A*:
    state = (θέση, cumulative_energy)
    f(s, E_s) = g(s) + λ_E * E_s + λ_Q * (Q_min - q(s))^+ + h(s)
    prune αν E_s + h_E(s) > B // infeasible

CHARGING DETOUR FALLBACK:
    c* = nearest_charging_station(current_pos)
    path = A*(start, c*) + charge() + A*(c*, goal)

```

Μαθηματική Φορμοποίηση

```

Constrained: min Σ c(e) s.t. Σ e_cost(e) ≤ B, min_{s∈π} q(s) ≥ Q_min
Lagrangian: L(λ_E, λ_Q) = min_π Σ [c(e) + λ_E · e(e) + λ_Q · (Q_min - q(e))^+]
Energy:      E(π) = Σ_{e∈π} P_motor · |e| · κ(terrain(e))
State space: |S| × (B/ε) όπου ε = energy discretization step

```

Πολυπλοκότητα & Παραδοχές

Χρονική πολυπλοκότητα: $O(W \cdot H \cdot B/\epsilon)$ για resource-extended A* — tractable για μικρό B/ε ratio.

- Energy model $P_{\text{motor}} \cdot \text{distance} \cdot \kappa$ ακριβής (δεν validated σε real robot)
- WiFi map available a priori (στην πράξη πρέπει να μαθαίνεται online)
- Charging station locations γνωστές και static
- Battery capacity B σταθερή (χωρίς degradation model)

⑤ Ερευνητική Αξία

Ερευνητικό Ερώτημα

Ποιο είναι το optimal path υπό joint energy-budget και connectivity constraints, και πώς διαφέρει από το unconstrained optimum σε length, risk, και communication quality;

Novelty — Τι Καινούργιο Κάνω

Joint energy + connectivity constraint σε mobile robot navigation είναι underexplored. Οι περισσότερες δουλειές χειρίζονται battery HTol communication ξεχωριστά.

Σχετική Βιβλιογραφία

Desrochers & Soumis (1988) — resource-constrained shortest path. Mei et al. (2004) energy-efficient locomotion. Rooker & Birk (2007) communication-aware planning.

⑥ Αποτελέσματα & Τι Σημαίνουν

Mission completion rate within budget μετρήθηκε. Visible routing around dead zones. Efficiency overhead quantified.

Metrics

- Mission completion rate within budget B
- Mean residual energy at goal
- Mean $q(s)$ along path (connectivity quality)
- Path length overhead vs unconstrained A*

Τι Λείπει Ακόμα

Δεν υπάρχουν real TurtleBot3 energy measurements. WiFi signal prediction accuracy δεν αξιολογήθηκε. Δεν υπάρχει σύγκριση με multi-objective A* baselines.

⑦ Αυστηρή Κριτική — Reviewer Mode

Αδυναμίες

- Energy model απλοϊκό — αγνοεί acceleration, payload, battery degradation
- WiFi map assumed known a priori — στην πράξη πρέπει να μαθαίνεται
- λ tuning χωρίς principled method
- Charging stations assumed always accessible

Κρυφές Παραδοχές

- Energy model ακριβής
- WiFi signal map accurate και stationary
- Charging stations always reachable

Σενάρια Αποτυχίας

- Νέος τύπος terrain μη-γνωστός στο κ model
- WiFi interference κατά τη διάρκεια πλοήγησης
- Δεν υπάρχει charging station εντός reachable range

⑧ Πώς Γίνεται Δημοσίευση

Τίτλος Paper	Joint Energy-Connectivity Constrained Path Planning for Long-Duration Autonomous Navigation
Venue	IROS / RoboCup Symposium

Missing Experiments

- Real TurtleBot3 energy measurements για validation του model
- Online WiFi signal mapping: build q(s) during navigation
- Stress test: 2 ώρες autonomous navigation, mission completion rate
- Greedy (charge when low) vs proactive (charge early) strategy comparison

Ablations που Χρειάζονται

- Simple linear vs measured quadratic energy model
- Με vs χωρίς charging detour — when is proactive worth it;
- Energy-only vs energy+connectivity vs energy+connectivity+CVaR

⑨ Ανοιχτά Ερευνητικά Ερωτήματα

16. Μπορεί energy consumption να μαθαίνεται online από το ίδιο το ρομπότ;
17. Πώς να ισορροπούνται speed vs range (αργότερα = λιγότερη ενέργεια ανά μέτρο);
18. Μπορεί fleet energy management να συντονίζεται σε πολλαπλά ρομπότ;

⑩ Αν Είχα 2 Λεπτά να το Εξηγήσω σε Οποιονδήποτε...

Πραγματικά ρομπότ έχουν μπαταρία και χρειάζονται WiFi. Αυτό το module διδάσκει τον planner να παρακολουθεί δύο επιπλέον πόρους ενώ σχεδιάζει διαδρομές: την υπολειπόμενη ενέργεια και την ποιότητα σήματος. Αν δεν υπάρχει άμεση διαδρομή εντός του energy budget, σχεδιάζει αυτόματα παρακαμπτήρια μέσω σταθμού φόρτισης. Σκέψου το σαν GPS που ξέρει πόση βενζίνη έχεις και πού έχεις σήμα κινητού.

Βαθμολογία

Διάσταση	Βαθμός	Σχόλιο
Πρωτοτυπία	6/10	Incremental
Τεχνικό Βάθος	7/10	Prototype επίπεδο
Δημοσιευσιμότητα	6/10	Χρειάζεται experiments
PhD Δυναμικό	6/10	Υποστηρικτικό υλικό

Contribution 07 Next-Best-View Exploration — Έξυπνη Εξερεύνηση

Κατηγορία: [Active Mapping](#) / Εξερεύνηση

① Εξήγηση για Αρχάριο — Από το Μηδέν

Τι πρόβλημα λύνει;

Αντί να πηγαίνει στο κοντινότερο άγνωστο σημείο, το ρομπότ επιλέγει πού να πάει με βάση το πόση νέα πληροφορία θα αποκτήσει ανά μέτρο κίνησης. Μεγιστοποιεί γνώση ανά βήμα.

Γιατί υπάρχει αυτό το πρόβλημα;

Η frontier exploration (πήγαινε στο κοντινότερο άγνωστο σημείο) είναι suboptimal. Μερικές θέσεις αποκαλύπτουν πολύ περισσότερο χώρο από άλλες — εξαρτάται από γωνία, απόσταση, εκτόμπωση αισθητήρα.

Γιατί είναι δύσκολο;

Υπολογισμός IG (information gain) για κάθε candidate viewpoint απαιτεί simulation του sensor model — ακριβό. Greedy (myopic) selection αγνοεί multi-step synergies. Balancing IG vs travel cost είναι multi-objective πρόβλημα.

② Αναλογία & Διαισθηση

Δημοσιογράφος που ερευνά: δεν συνεντεύζεται με τον κοντινότερο — συνεντεύζεται με αυτόν που ξέρει τα περισσότερα ανά μετακίνηση. Ιατρικός scanner: ο τεχνικός τοποθετεί τον scanner στη γωνία που αποκαλύπτει το περισσότερο για τον άγνωστο ιστό.

③ Τι Έκανα Ακριβώς — Βήμα-Βήμα

- Διατήρηση probabilistic occupancy grid με per-cell entropy $H(m_c)$
- Generate candidate viewpoints: frontier cells + random sampling
- IG estimation μέσω ray-casting simulation από κάθε viewpoint
- NBV score: $IG(v) / d(\text{robot}, v)$ — πληροφορία ανά μέτρο μετακίνησης
- Πλοήγηση σε $v^* = \text{argmax}(\text{score})$
- Integration: feeds candidates σε risk-aware A^* (C03)

Ροή Δεδομένων

Occupancy belief → per-cell entropy map → candidate viewpoints → ray-cast IG estimation → IG/cost score → v^* → safe navigation → map update → repeat

④ Βαθιά Τεχνική Ανάλυση

Βασικά Components

- Binary Bayes filter: updates $p_c \in [0, 1]$ από LiDAR log-odds
- Entropy map: $H(m_c) = -p_c \log p_c - (1-p_c) \log(1-p_c)$ per cell
- IG estimator: ray-casting simulation του sensor model από candidate v

- NBV scorer: $IG(v) / (\alpha \cdot d(v) + \beta)$ — information per travel cost
- Frontier detector: κελιά adjacent σε known και unknown space

Pseudocode / Αλγόριθμος

```
OCCUPANCY UPDATE (ανά LiDAR scan):
    log_odds[c] += sensor_model(z, c) // για κάθε κελί c κατά μήκος ray
    p[c] = sigmoid(log_odds[c])

NBV SELECTION:
    H_total =  $\sum_c (-p[c] \cdot \log(p[c]) - (1-p[c]) \cdot \log(1-p[c]))$ 
    για κάθε v σε candidates:
        simulated_rays = raytrace(v, range, fov)
         $IG[v] = \sum_{\{c \text{ in rays}\}} E[H(m_c) - H(m_c|z_v)]$ 
        score[v] =  $IG[v] / \text{distance}(\text{robot}, v)$ 
    v_star = argmax(score)
    navigate_to(v_star)
```

Μαθηματική Φορμοποίησηση

```
Map entropy:  $H(m) = \sum_c [-p_c \log p_c - (1-p_c) \log(1-p_c)]$ 
IG:  $IG(v) = H(m) - E_{\{z_v\}}[H(m|z_v)]$ 
Bayes update:  $\log\_odds(m_c|z_{\{1:t\}}) = \sum_t \log\_odds(m_c|z_t) - (t-1) \cdot \text{prior}$ 
NBV:  $v^* = \text{argmax}_{\{v \in V\}} IG(v) / (\alpha \cdot d(\text{robot}, v) + \beta)$ 
```

Πολυπλοκότητα & Παραδοχές

Χρονική πολυπλοκότητα: IG computation: $O(|V| \cdot N_{\text{rays}} \cdot N_{\text{cells}} / \text{ray})$. Για 50 candidates, 360 rays, 20 cells/ray: ~360K ops ανά selection step.

- Greedy (myopic) selection approximately optimal (γνωστό ότι είναι suboptimal γενικά)
- Ray-casting IG approximates true expected entropy reduction
- Candidates reachable χωρίς kinodynamic issues
- IG και travel cost μόνα τους αρκούν (αγνοεί safety στον selection)

⑤ Ερευνητική Αξία

Ερευνητικό Ερώτημα

Μειώνει information-gain-weighted viewpoint selection το total navigation distance για target map coverage level, vs frontier-based και random exploration;

Novelty — Τι Καινούργιο Κάνω

Integration NBV με risk-aware planning (C03): IG candidates φιλτράρονται μέσω CVaR cost — μόνο safe viewpoints επιλέγονται. Standard NBV implementations αγνοούν risk.

Σχετική Βιβλιογραφία

Bourgault et al. (2002) — information-based exploration. Charrow et al. (2015) — active exploration. Yamauchi (1997) — frontier. FUEL (Zhou 2021), GBPlanner (Dang 2020).

⑥ Αποτελέσματα & Τι Σημαίνουν

Coverage rate over time: NBV reaches 90% map coverage ταχύτερα από frontier-based. IG estimation within 15% of true entropy reduction.

Metrics

- Map coverage % over time
- Total path length to target coverage
- IG estimation error vs actual entropy reduction
- Computation time per NBV selection

Τι Λείπει Ακόμα

Δεν υπάρχει σύγκριση με FUEL, GBPlanner, AEP. Δεν υπάρχει 3D extension. Δεν αναλύθηκε greedy suboptimality gap.

⑦ Αυστηρή Κριτική — Reviewer Mode

Αδυναμίες

- Greedy γνωστό ως suboptimal — MCTS ή multi-step planning καλύτερο
- IG/cost αγνοεί observations κατά τη διάρκεια μετακίνησης (μόνο destination)
- Δεν υπάρχει convergence guarantee — μπορεί το ρομπότ να κολλάει σε cycles;
- Δεν αναλύθηκε πώς integrates με safety constraints

Κρυφές Παραδοχές

- Greedy $\approx$ optimal σε typical environments (fails σε bottleneck layouts)
- Travel cost = Euclidean distance (αγνοεί actual path length)
- Sensor model correct για IG simulation

Σενάρια Αποτυχίας

- Cyclic environments: NBV επιλέγει τα ίδια viewpoints ξανά και ξανά
- Πολλές symmetric unexplored regions: degenerate tie-breaking
- High-clutter maps: IG computation πολύ αργό

⑧ Πώς Γίνεται Δημοσίευση

Τίτλος Paper	Information-Theoretic Active Exploration with Risk-Aware Viewpoint Selection
Venue	ICRA / IROS — Exploration Track

Missing Experiments

- Σύγκριση με FUEL, GBPlanner, AEP σε identical 2D και 3D environments
- Path-integrated IG: account for observations during travel
- Real robot: TurtleBot3 mapping real room
- Multi-step vs greedy: MCTS vs greedy NBV σε bottleneck maps

Ablations που Χρειάζονται

- Greedy vs multi-step (MCTS) σε ίδια environments
- IG/cost vs pure IG vs pure distance-to-frontier
- Ray-casting approximation vs exact sensor model simulation
- Candidate set size $|V|$ vs coverage quality και compute time

⑨ Ανοιχτά Ερευνητικά Ερωτήματα

- 19. Μπορεί NBV να φορμοποιηθεί ως POMDP με multi-step lookahead;
- 20. Πώς να συνδυαστεί IG και CVaR risk (C03) jointly;
- 21. Μπορεί IG estimation να μαθαίνεται από data αντί να υπολογίζεται analytically;

⑩ Αν Είχα 2 Λεπτά να το Εξηγήσω σε Οποιονδήποτε...

Αντί να πηγαίνει απλώς στο κοντινότερο άγνωστο γωνία, το ρομπότ αποφασίζει πού θα μάθει τα περισσότερα ανά βήμα κίνησης. Για κάθε υποψήφια θέση εξερεύνησης εκτιμάει πόση αβεβαιότητα του χάρτη θα εξαλείψει (information gain) και διαιρεί με την απόσταση. Πηγαίνει πάντα στο πιο «αξιόλογο» σημείο. Αποτέλεσμα: χαρτογραφεί τον άγνωστο χώρο πολύ πιο γρήγορα.

Βαθμολογία

Διάσταση	Βαθμός	Σχόλιο
Πρωτοτυπία	7/10	Incremental
Τεχνικό Βάθος	7/10	Prototype επίπεδο
Δημοσιευσιμότητα	7/10	Χρειάζεται experiments
PhD Δυναμικό	7/10	Υποστηρικτικό υλικό

Contribution 08 Security IDS — Ανίχνευση Εισβολής Αισθητήρων

Κατηγορία: Κυβερνοασφάλεια

① Εξήγηση για Αρχάριο — Από το Μηδέν

Τι πρόβλημα λύνει;

Κάποιος μπορεί να εξαπατά τους αισθητήρες του ρομπότ — ψεύτικα obstacles στο LiDAR, λανθασμένη θέση GPS. Αυτό το module ανιχνεύει αν κάτι «ύποπτο» συμβαίνει, συγκρίνοντας τι λένε οι αισθητήρες με τι θα έπρεπε να λένε.

Γιατί υπάρχει αυτό το πρόβλημα;

Καθώς τα ρομπότ συνδέονται σε δίκτυα (IoT, 5G), κληρονομούν τις ευπάθειες των networked systems. Επιθέσεις σε αισθητήρες = λανθασμένες αποφάσεις = επικίνδυνη κίνηση.

Γιατί είναι δύσκολο;

Πώς να ξεχωρίσεις «αισθητήρας με φυσιολογικό θόρυβο» από «αισθητήρας υπό επίθεση»; False alarms κοστίζουν (άσκοπες ακινητοποιήσεις). Missed detections κοστίζουν (επικίνδυνη κίνηση).

② Αναλογία & Διαίσθηση

Fraud detection τράπεζας: κάθε συναλλαγή βαθμολογείται για πόσο «ύποπτη» είναι. Φυσιολογική variation (πελάτης ταξιδεύει) δεν σηκώνει alarm. Ύποπτο pattern (ταυτόχρονα 3 χώρες) = alarm. Ο EKF innovation sequence παίζει τον ίδιο ρόλο.

③ Τι Έκανα Ακριβώς — Βήμα-Βήμα

- Εξαγωγή innovation sequence: $v_k = z_k - H \cdot \hat{s}_{k|k-1}$ από EKF (C02)
- Chi-squared test: $\chi^2_k = v_k^T S_k^{-1} v_k \sim \chi^2(m)$ υπό φυσιολογικές συνθήκες
- False-alarm rate α : threshold $\tau = \chi^2_{1-\alpha}(m)$
- CUSUM detector: $g_k = \max(0, g_{k-1} + \chi^2_k - \kappa)$ για gradual drift
- Alarm $\rightarrow$ trigger Safe-Mode (C05) + log event + notify SCM (C14)
- ROS2 nodes σε cybersecurity_ros2/ directory

Ροή Δεδομένων

EKF innovation $v_k \rightarrow$ chi-squared statistic $\rightarrow$ threshold + CUSUM $\rightarrow$ alarm $\rightarrow$ Safe-Mode + event log + causal attribution

④ Βαθιά Τεχνική Ανάλυση

Βασικά Components

- Innovation extractor: $v_k = z_k - h(\mu_{k|k-1})$, $S_k = H \cdot P_{k|k-1} \cdot H^T + R$
- Chi-squared tester: $\chi^2_k = v_k^T S_k^{-1} v_k \sim \chi^2(m)$ under H_0
- CUSUM: cumulative sum detector για sustained anomalies
- Alarm handler: trigger C05 safe mode, log to C14 causal module

Pseudocode / Αλγόριθμος


```

INNOVATION EXTRACTION:
    nu_k = z_k - h(mu_hat)           // measured minus predicted
    S_k = H @ P_pred @ H.T + R       // innovation covariance

CHI-SQUARED TEST:
    stat_k = nu_k.T @ inv(S_k) @ nu_k
    alarm_chi2 = (stat_k > threshold_chi2)

CUSUM DETECTOR:
    g_k = max(0, g_{k-1} + stat_k - kappa)
    alarm_cusum = (g_k > h_cusum)

ALARM HANDLING:
    αν alarm_chi2 ή alarm_cusum:
        trigger_safe_mode() // C05
        log_event(timestamp, stat_k, g_k)
        notify_causal_scm() // C14

```

Μαθηματική Φορμοποίησηση

Υπό H_0 (χωρίς επίθεση): $v_k \sim N(0, S_k) \rightarrow \chi^2_k \sim \chi^2(m)$
 FAR control: $P(\chi^2(m) > \tau) = \alpha \rightarrow \tau = \chi^2_{\{1-\alpha\}}(m)$
 CUSUM ARL: $E[T_{\text{detect}}]$ υπό attack magnitude δ
 Sensitivity: CUSUM ανιχνεύει μ -shift σε $E[\chi^2_k]$ από m σε $m+\delta$

Πολυπλοκότητα & Παραδοχές

Χρονική πολυπλοκότητα: $O(m^2)$ ανά timestep για $S_{k^{-1}}$ ($m \leq 6$). Real-time capable.

- EKF σωστά calibrated (Q, R) — miscalibration inflates/deflates χ^2_k
- Attacker naive (δεν γνωρίζει το detection scheme)
- Sensor noise Gaussian (heavier tails $\rightarrow$ more false alarms)
- Single-sensor attack model

⑤ Ερευνητική Αξία

Ερευνητικό Ερώτημα

Μπορεί statistical monitoring των EKF innovations να ανιχνεύσει sensor spoofing με controlled false-alarm rates, ενώ παραμένει robust σε φυσιολογική variation;

Novelty — Τι Καινούργιο Κάνω

Integration IDS $\rightarrow$ navigation Safe-Mode (C05) $\rightarrow$ causal failure attribution (C14) δημιουργεί security pipeline σπάνιο σε mobile robotics. Το detection μόνο είναι standard· η σύνδεση με recovery και root-cause είναι η novelty.

Σχετική Βιβλιογραφία

Mehra & Peschon (1971) — innovation fault detection. Mo et al. (2010) — false data injection. Shoukry & Tabuada (2015) — state estimation under attack.

⑥ Αποτελέσματα & Τι Σημαίνουν

Detection rates για LiDAR spoofing και odometry corruption μετρήθηκαν. False alarm rates calibrated. Integration με C05 επαληθεύτηκε.

Metrics

- True Positive Rate (TPR/detection rate)
- False Positive Rate (FPR/false alarm rate)
- Detection latency (steps from attack onset)
- CUSUM ARL_0 (no attack) και ARL_1 (under attack)

Τι Λείπει Ακόμα

Δεν αξιολογήθηκε έναντι adaptive attackers. Δεν υπάρχει hardware evaluation. Δεν υπάρχει σύγκριση με model-free anomaly detection (autoencoders).

⑦ Αυστηρή Κριτική — Reviewer Mode

Αδυναμίες

- Stealthy attacks crafted to match expected innovation distribution: missed
- κ και η σε CUSUM χρειάζονται tuning χωρίς principled method
- EKF misconvergence υπό επίθεση: chicken-and-egg πρόβλημα
- Replay attacks με historically valid data: undetected

Κρυφές Παραδοχές

- Attacker δεν γνωρίζει το detection scheme
- EKF correctly initialized πριν onset attack
- Single-point sensor failure model

Σενάρια Αποτυχίας

- Stealthy attacks που mimicking $N(0, S_k)$ distribution
- Gradual degradation κάτω από CUSUM threshold
- Multi-sensor coordinated attacks consistent με motion model

⑧ Πώς Γίνεται Δημοσίευση

Τίτλος Paper	Integrity Monitoring for Autonomous Navigation: Innovation-Based Sensor Attack Detection
Venue	ICRA Security Workshop / IEEE Transactions on Control Systems

Missing Experiments

- Real TurtleBot3: physical LiDAR interference experiments
- Σύγκριση με autoencoder-based anomaly detection
- Adaptive attacker analysis
- Replay attack detection

Ablations που Χρειάζονται

- Chi-squared alone vs CUSUM alone vs combined

- Επίδραση EKF miscalibration σε detection performance
- Alert threshold sensitivity: TPR vs FPR tradeoff curve

9 Ανοιχτά Ερευνητικά Ερωτήματα

22. Μπορεί IDS να συνδυαστεί με cryptographic sensor authentication;
23. Πώς να αυτοματοποιηθεί recovery από confirmed attacks;
24. Μπορεί detection threshold να adapts online σε changing noise conditions;

10 Αν Είχα 2 Λεπτά να το Εξηγήσω σε Οποιονδήποτε...

Τα ρομπότ σε δίκτυα μπορεί να δεχτούν επιθέσεις — κάποιος στέλνει ψεύτικες μετρήσεις αισθητήρων. Αυτό το module είναι το σύστημα ασφαλείας: παρακολουθεί αν αυτό που λένε οι αισθητήρες συμφωνεί με αυτό που το μοντέλο κίνησης προβλέπει ότι θα έλεγαν. Όταν διαφωνούν περισσότερο από τον τυχαίο θόρυβο, σηκώνει alarm, επιβραδύνει το ρομπότ, και καταγράφει το συμβάν για ανάλυση.

Βαθμολογία

Διάσταση	Βαθμός	Σχόλιο
Πρωτοτυπία	7/10	Incremental
Τεχνικό Βάθος	8/10	Πλήρης μαθ. ανάλυση
Δημοσιευσιμότητα	7/10	Χρειάζεται experiments
PhD Δυναμικό	8/10	Ισχυρό κεφάλαιο διδακτορικού

Contribution 09 Multi-Robot Coordination — Αποκεντρωμένος Συντονισμός

Κατηγορία: Multi-Robot Systems

① Εξήγηση για Αρχάριο — Από το Μηδέν

Τι πρόβλημα λύνει;

Όταν 5 ρομπότ μοιράζονται τον ίδιο χώρο, θα σχεδιάσουν συγκρουόμενες διαδρομές χωρίς συντονισμό. Αυτό το module υλοποιεί αποκεντρωμένο πρωτόκολλο: κάθε ρομπότ σχεδιάζει γύρω από τα reservations των άλλων.

Γιατί υπάρχει αυτό το πρόβλημα;

Ένας κεντρικός συντονιστής είναι single point of failure. Αν πέσει, σταματούν όλα. Αποκεντρωμένη λύση: κάθε ρομπότ αποφασίζει μόνο του, βλέποντας τα reservations των άλλων.

Γιατί είναι δύσκολο;

Decentralized MAPF (Multi-Agent Path Finding) είναι NP-hard γενικά. Priority-based approaches είναι tractable αλλά incomplete (χαμηλότερης προτεραιότητας robot ίσως δεν βρει path) και μπορεί να deadlock.

② Αναλογία & Διαίσθηση

Τετράδρομο χωρίς φανάρια: όποιος φτάνει πρώτος έχει προτεραιότητα, οι άλλοι περιμένουν. Κάθε οδηγός σχεδιάζει γύρω από committed διαδρομές άλλων. ATC (Air Traffic Control): κάθε πιλότος σχεδιάζει ανεξάρτητα αλλά σέβεται commitments άλλων.

③ Τι Έκανα Ακριβώς — Βήμα-Βήμα

- Priority ordering (static: robot ID, extensible: urgency-based)
- Map sharing: gossip protocol — κάθε ρομπότ στέλνει map delta στους γείτονες ανά T_{gossip} steps
- Path reservation: robot i plans A^* θεωρώντας higher-priority reservations ως εμπόδια
- Reservation broadcast: robot i announces το planned path σε όλα τα lower-priority
- Disagreement metric: $\|map_i \ominus map_j\|_1 > \tau_d \rightarrow \text{flag inconsistency}$
- Risk budget: R_{total} distributed by priority

Ροή Δεδομένων

Κάθε ρομπότ: $local\ map + received\ reservations \rightarrow A^* \rightarrow own\ path \rightarrow broadcast\ reservation \rightarrow next\text{-}priority\ robot$

④ Βαθιά Τεχνική Ανάλυση

Βασικά Components

- Priority queue: robots sorted by priority (highest first)
- Gossip updater: στέλνει map delta σε neighbors, λαμβάνει δικά τους, merges

- Reservation tracker: stores other robots' committed path cells + timestamps
- Disagreement detector: L1 norm of map differences

Pseudocode / Αλγόριθμος

```
COORDINATION ROUND:
  sort robots by priority (highest first)
  για κάθε robot_i σε sorted_robots:
    reservations = all reservations from higher-priority robots
    path_i = A*(map_i + reservations, start_i, goal_i)
    broadcast(path_i as reservation σε όλα τα robots)

GOSSIP MAP UPDATE (ανά T_gossip steps):
  delta = map_i XOR map_i_prev
  στείλε(delta) σε neighbors
  για κάθε received delta_j: map_i = merge(map_i, delta_j)
```

Μαθηματική Φορμοποίησηση

```
Conflict-free:  $\forall i \neq j, \forall t: s_i(t) \neq s_j(t)$  (κανένα ρομπότ δεν κατέχει ίδιο κελί)
Priority ordering: path_i planned πριν path_{i+1} δει το
Risk budget:  $r_i = (\text{priority}_i / \sum_j \text{priority}_j) * R_{\text{total}}$ 
Disagreement:  $d_{ij} = ||\text{map}_i \ominus \text{map}_j||_1 > \tau_d \rightarrow \text{flag}$ 
```

Πολυπλοκότητα & Παραδοχές

Χρονική πολυπλοκότητα: Single round: $O(N \cdot A^*)$. Gossip convergence: $O(\log N)$ rounds.

- Priority ordering globally agreed — δεν υπάρχουν ties
- Δεν υπάρχει deadlock detection ή resolution
- Gossip reliable και low-latency
- Ρομπότ identical capabilities

⑤ Ερευνητική Αξία

Ερευνητικό Ερώτημα

Μπορεί αποκεντρωμένο priority-based reservation να επιτύχει collision-free multi-robot navigation με bounded path overhead vs centralized CBS, για $N \leq 10$;

Novelty — Τι Καινούργιο Κάνω

Integration multi-robot coordination με individual risk budgets (CVaR per robot από C03) distributed by priority. Risk ως shareable resource είναι novel framing.

Σχετική Βιβλιογραφία

Sharon et al. (2015) CBS. Silver (2005) cooperative pathfinding. Stern et al. (2019) MAPF survey.

⑥ Αποτελέσματα & Τι Σημαίνουν

Collision-free navigation για $N \leq 5$ ρομπότ σε tested environments. Path overhead μετρήθηκε. Gossip convergence time αναλύθηκε.

Metrics

- Collision rate (πρέπει 0)
- Path length overhead vs single-robot planning
- Coordination latency
- Gossip map convergence rounds

Τι Λείπει Ακόμα

Δεν υπάρχει σύγκριση με CBS. Δεν υπάρχει deadlock analysis. Δεν αξιολογήθηκε scalability >5. Δεν υπάρχει evaluation σε dynamic environments.

⑦ Αυστηρή Κριτική — Reviewer Mode

Αδυναμίες

- Priority-based: incomplete — χαμηλή προτεραιότητα ίσως δεν βρει path
- Gossip: eventually consistent — temporary inconsistencies → suboptimal plans
- Χωρίς deadlock detection: lower-priority robot μπορεί να μπλοκάρει permanently
- Δεν συγκρίθηκε με CBS ή M*

Κρυφές Παραδοχές

- Priority globally agreed και static
- Gossip reliable (no packet loss)
- Μόνο currently reserved cells block planning

Σενάρια Αποτυχίας

- Narrow corridors: lower-priority robot permanently blocked
- Large N: gossip too slow για dynamic replanning
- Inconsistent maps: ρομπότ διαφωνούν για state of door

⑧ Πώς Γίνεται Δημοσίευση

Τίτλος Paper	Decentralized Risk-Aware Multi-Robot Navigation with Priority Reservation και Gossip Map Sharing
Venue	AAMAS / MRS Workshop / ICRA

Missing Experiments

- Σύγκριση με CBS σε identical multi-robot benchmarks
- Scalability: N = 2, 4, 6, 8, 10 — πού αποτυγχάνει priority-based;
- Deadlock analysis: construct scenarios that cause deadlock
- Dynamic fleet: ρομπότ join/leave mid-mission

Ablations που Χρειάζονται

- Static vs dynamic priority
- CBS vs priority-based σε ίδια scenarios
- Με vs χωρίς gossip sharing
- Risk budget sharing: βελτιώνει fleet performance;

9) Ανοιχτά Ερευνητικά Ερωτήματα

- 25. Μπορεί multi-robot planning να γίνει distributed optimization με convergence guarantees;
- 26. Πώς communication latency επηρεάζει coordination quality;
- 27. Μπορούν deadlocks να ανιχνεύονται και να επιλύονται αυτόματα;

10) Αν Είχα 2 Λεπτά να το Εξηγήσω σε Οποιονδήποτε...

Πέντε ρομπότ στον ίδιο χώρο θα συγκρουστούν χωρίς συντονισμό. Αυτό το module υλοποιεί ένα απλό πρωτόκολλο: τα ρομπότ κατατάσσονται κατά προτεραιότητα. Το πρώτο σχεδιάζει ελεύθερα και ανακοινώνει τη διαδρομή. Τα επόμενα σχεδιάζουν γύρω από τις ανακοινωμένες, θεωρώντας τις εμπόδια. Χάρτες μοιράζονται peer-to-peer συνεχώς. Αποτέλεσμα: σύγκρουση-ελεύθερη πλοήγηση χωρίς κεντρικό συντονιστή.

Βαθμολογία

Διάσταση	Βαθμός	Σχόλιο
Πρωτοτυπία	6/10	Incremental
Τεχνικό Βάθος	6/10	Prototype επίπεδο
Δημοσιευσιμότητα	6/10	Χρειάζεται experiments
PhD Δυναμικό	7/10	Υποστηρικτικό υλικό

Contribution 10 Human-Aware & Ethics Navigation

Κατηγορία: Human-Robot Interaction

① Εξήγηση για Αρχάριο — Από το Μηδέν

Τι πρόβλημα λύνει;

Το ρομπότ δεν μπαίνει σε ευαίσθητες ζώνες (ΜΕΘ, δωμάτια προσευχής), κρατάει κοινωνική απόσταση από ανθρώπους, και ζητάει άδεια αν δεν είναι σίγουρο ότι ο χειριστής του εμπιστεύεται.

Γιατί υπάρχει αυτό το πρόβλημα;

Ρομπότ σε δημόσιους χώρους πρέπει να ακολουθούν κοινωνικά πρότυπα — όχι μόνο να αποφεύγουν φυσικά εμπόδια. Η αποδοχή από τους ανθρώπους εξαρτάται κρίσιμα από αυτό.

Γιατί είναι δύσκολο;

Δεν υπάρχει universally agreed mathematical formalization της «ηθικής πλοήγησης». Κανόνες είναι context-dependent, implicit, culturally variable. Χρειάζεται flexible framework.

② Αναλογία & Διαίσθηση

Νοσοκόμα σε νοσοκομείο: δεν κινείται απλώς αποφεύγοντας τοίχους — σέβεται ώρες επίσκεψης, ευαίσθητες ζώνες, προσωπικό χώρο ασθενών. Έχει εσωτερικεύσει σύνθετους κανόνες χωρίς να τους ρωτάει κάθε φορά.

③ Τι Έκανα Ακριβώς — Βήμα-Βήμα

- Ηθικές ζώνες από `ethical_zones.json`: Z_{hard} (∞ κόστος), Z_{soft} (ποινή γ), Z_{announce}
- Human proximity: $c_{\text{human}}(s) = \sum_j w_j \cdot \exp(-\|s-p_j\|^2/2\sigma^2)$ Gaussian repulsion
- Trust parameter $\tau \in [0,1]$: χαμηλό $\tau \rightarrow$ ζητάει άδεια για κάθε action
- Full cost: $f(s) = g(s) + \lambda_r \cdot r(s) + c_{\text{ethical}}(s) + \lambda_h \cdot c_{\text{human}}(s) + h(s)$
- Integration: zones loaded at startup, human positions από perception

Ροή Δεδομένων

Ethical zone map + human positions + trust $\tau \rightarrow$ augmented cost function $\rightarrow A^ \rightarrow$ ethically-constrained path*

④ Βαθιά Τεχνική Ανάλυση

Βασικά Components

- Zone loader: parses `ethical_zones.json` at startup
- Hard constraint: prune A^* nodes σε Z_{hard}
- Soft penalty: $c_{\text{ethical}}(s) = \gamma_z$ αν $s \in Z_{\text{soft}}$ αλλιώς 0
- Human repulsion: sum of Gaussians centered on detected human positions
- Trust scaler: action cost $>$ threshold $\rightarrow$ require confirmation αν $\tau < 0.5$

Pseudocode / Αλγόριθμος

COST AUGMENTATION:


```
def cost(s):
    αν s σε Z_hard: return INF
    zone_cost = gamma_z αν s σε Z_soft αλλιώς 0
    human_cost = Σ_j w_j * exp(-dist(s, p_j)^2 / (2 * σ^2))
    return base_cost(s) + zone_cost + λ_h * human_cost

TRUST-SCALED CONFIRMATION:
αν action_risk(a) > C_threshold και τ < 0.5:
    request_confirmation(a)
```

Μαθηματική Φορμοποίηση

Hard: $\pi \cap Z_{\text{hard}} = \emptyset$ (path ποτέ δεν διασταυρώνεται με hard no-go zones)
 Soft: minimize $\sum_{s \in \pi} c_{\text{ethical}}(s)$ (preference, not requirement)
 Human: $c_{\text{human}}(s) = \sum_j w_j \exp(-||s - p_j||^2 / 2\sigma_j^2) \geq 0$
 Trust: $P(\text{request_confirmation} | \text{action}) = 1 - \tau$

Πολυπλοκότητα & Παραδοχές

Χρονική πολυπλοκότητα: $O(N_{\text{humans}})$ ανά cell evaluation. Negligible για $N_{\text{humans}} \leq 20$.

- Ethical zones manually defined και static
- Human detection reliable
- Single scalar τ captures full trust dynamics
- Rules context-independent

⑤ Ερευνητική Αξία

Ερευνητικό Ερώτημα

Μπορεί cost-function-based ethical constraint framework να επιτρέψει navigation behavior που human observers αξιολογούν ως κοινωνικά αποδεκτό, χωρίς σημαντική υποβάθμιση efficiency;

Novelty — Τι Καινούργιο Κάνω

Integration ethical zone constraints + human proximity repulsion + trust-parameterized autonomy σε unified A* cost function. Trust model connecting autonomy σε confirmation requirements.

Σχετική Βιβλιογραφία

Kruse et al. (2013) — human-aware navigation survey. Pacchierotti et al. (2006) — proxemics. Sisbot et al. (2007) — human-aware planning.

⑥ Αποτελέσματα & Τι Σημαίνουν

Hard zone violations: μηδέν σε όλα τα tests. Soft zone detours visible. Human proximity social distancing observable.

Metrics

- Zone violation rate
- Mean social distance από humans
- Human observer appropriateness ratings (Likert scale)
- Path overhead

Τι Λείπει Ακόμα

Δεν υπάρχει human observer study. Trust model static scalar. Zone specification manual — δεν γίνεται inference. Δεν αξιολογήθηκε cross-cultural.

⑦ Αυστηρή Κριτική — Reviewer Mode

Αδυναμίες

- «Ethics» overstates: είναι zone avoidance + social distancing — όχι ethical reasoning
- Trust τ static — real trust αναπτύσσεται δυναμικά
- Χωρίς learning από human feedback
- Isotropic human proximity — real proxemics είναι directional

Κρυφές Παραδοχές

- Zones correctly defined
- Human positions correctly estimated
- Single σ captures all social distance preferences

Σενάρια Αποτυχίας

- Dynamic ethical zones (ώρες επίσκεψης αλλάζουν)
- Conflicting constraints: emergency goal through soft-penalty zone
- Crowd scenarios: cost surface ανεξερεύνητη

⑧ Πώς Γίνεται Δημοσίευση

Τίτλος Paper	Preference-Aware Navigation: Ethical Zones, Social Proxemics, Trust-Parameterized Autonomy
Venue	HRI / ICRA Social Navigation Workshop

Missing Experiments

- Human observer study σε video scenarios
- Dynamic trust model
- Learning ethical zones από human corrections
- Cross-cultural study: σ differences;

Ablations που Χρειάζονται

- Hard vs soft zone representation
- σ sensitivity analysis
- Με vs χωρίς trust parameter
- Isotropic vs directional human repulsion

⑨ Ανοιχτά Ερευνητικά Ερωτήματα

28. Μπορούν ethical preferences να μαθαίνονται από human feedback;
29. Πώς να επιλύονται conflicts μεταξύ ethical constraints και urgent tasks;
30. Μπορεί τ να inferrate από operator behavior;

10 Αν Είχα 2 Λεπτά να το Εξηγήσω σε Οποιονδήποτε...

Ένα ρομπότ σε δημόσιο χώρο δεν πρέπει απλώς να αποφεύγει τοίχους — πρέπει να σέβεται κοινωνικά πρότυπα. Αυτό το module ορίζει «απαγορευμένες ζώνες» (π.χ. ΜΕΘ), ποινές για «ευαίσθητες ζώνες», και *Gaussian repulsion* από ανθρώπους που διασταυρώνεται. Ένας παράμετρος εμπιστοσύνης (τ) καθορίζει πότε το ρομπότ ζητάει άδεια αντί να ενεργεί αυτόνομα.

Βαθμολογία

Διάσταση	Βαθμός	Σχόλιο
Πρωτοτυπία	5/10	Γνωστή μέθοδος
Τεχνικό Βάθος	6/10	Prototype επίπεδο
Δημοσιευσιμότητα	5/10	Concept μόνο
PhD Δυναμικό	6/10	Υποστηρικτικό υλικό

Contribution 11 VLM Navigation Agent — Ρομπότ που Βλέπει και Καταλαβαίνει

Κατηγορία: [Foundation Models](#)

① Εξήγηση για Αρχάριο — Από το Μηδέν

Τι πρόβλημα λύνει;

Αντί για συντεταγμένες, λες «πήγαινε στην κουζίνα». Το ρομπότ δείχνει την κάμερά του σε ένα μεγάλο vision-language model (GPT-4V, LLaVA), που «διαβάζει» την εικόνα και λέει πού να πάει.

Γιατί υπάρχει αυτό το πρόβλημα;

Προγραμματισμός ρομπότ με συντεταγμένες απαιτεί τεχνική γνώση. Το VLM interface κάνει τον ρομπότ προσβάσιμο σε μη-ειδικούς — μιλάς φυσικά.

Γιατί είναι δύσκολο;

VLMs είναι αργά (API latency 0.5–5s), unstructured by default, και μπορεί να hallucinate. Χρειάζεται structured JSON interface, confidence gating, και back-projection από pixel σε metric coordinates.

② Αναλογία & Διαίσθηση

Google Lens: δείχνεις κάτι στην κάμερα και παίρνεις πληροφορία. Αυτό κάνει το module αλλά για navigation: «τι βλέπεις; πού να πάω;» → parsing → metric waypoint.

③ Τι Έκανα Ακριβώς — Βήμα-Βήμα

- HTTP client σε Ollama (local) ή OpenAI-compatible API
- Structured prompt → JSON response: {region, goal, confidence, pixel_u, pixel_v}
- JSON parser: strips markdown fences, handles missing fields
- Confidence gating: αν $c < \tau_c \rightarrow$ return None (graceful degradation)
- Back-projection: (u, v, depth) → (x_world, y_world) μέσω pinhole model + robot pose
- Session stats: confidence distribution, region label frequencies

Ροή Δεδομένων

RGB frame → base64 encode → VLM API → JSON parse → confidence gate → depth back-projection → metric waypoint → A planner*

④ Βαθιά Τεχνική Ανάλυση

Βασικά Components

- Frame encoder: PIL resize + base64 JPEG
- VLM prompter: structured prompt για JSON output
- JSON parser: robust σε formatting variations
- Back-projector: pinhole camera model με depth frame
- Confidence gater: accepts αν $c \geq \tau_c$

Pseudocode / Αλγόριθμος

```
PIPELINE:
    frame_b64 = encode_frame(rgb_frame)
    response = api_call(prompt, frame_b64)
    goal = parse_json(response)
    av goal is None ή goal.confidence < tau_c: return None

BACK-PROJECTION:
    d = depth_frame[v, u]
    x_cam = (u - cx) / fx * d
    x_world = robot_x + cos(yaw)*d - sin(yaw)*x_cam
    y_world = robot_y + sin(yaw)*d + cos(yaw)*x_cam
```

Μαθηματική Φορμοποίησηση

```
Pinhole: x_cam = (u - c_x) / f_x * d, z_cam = d
World: [x_w, y_w] = t_robot + R_yaw * [x_cam, z_cam]^T
Gate: accept(goal) = 1[goal.confidence ≥ τ_c]
Latency: T_total = T_encode + T_API + T_parse (dominated by T_API ≈ 0.5-5s)
```

Πολυπλοκότητα & Παραδοχές

Χρονική πολυπλοκότητα: $O(WH)$ back-projection. VLM call latency dominates: 500ms–5s.

- VLM correct visual-semantic knowledge του deployment environment
- Depth map accurate στο pixel hint location
- Robot pose sufficiently accurate για back-projection
- Confidence score calibrated (not guaranteed)

⑤ Ερευνητική Αξία

Ερευνητικό Ερώτημα

Μπορεί pre-trained VLM να παρέχει reliable zero-shot semantic goal generation για robot navigation, και ποια confidence thresholds minimize dangerous goal misidentification;

Novelty — Τι Καινούργιο Κάνω

Structured JSON interface (not free text), confidence gating, depth-based back-projection = production-quality VLM-to-navigation bridge. Graceful degradation (None αντί για wrong goal) — critical safety property.

Σχετική Βιβλιογραφία

Shah et al. (2023) LM-Nav. Huang et al. (2022) InnerMonologue. Ahn et al. (2022) SayCan. Shah et al. (2023) ViNT.

⑥ Αποτελέσματα & Τι Σημαίνουν

Architecture validated offline. Back-projection accuracy measured. ⚠️ Live VLM evaluation σε navigation episodes δεν έγινε.

Metrics

- Goal accuracy: correct semantic region identified
- Confidence calibration

- API latency distribution
- Graceful degradation rate

Τι Λείπει Ακόμα

Δεν υπάρχει live VLM evaluation. Δεν υπάρχει σύγκριση με LM-Nav ή ViNT. Latency analysis absent. Δεν αξιολογήθηκε τι γίνεται όταν το VLM κάνει λάθος.

⑦ Αυστηρή Κριτική — Reviewer Mode

Αδυναμίες

- VLM confidence not guaranteed calibrated
- API latency (0.5–5s) incompatible με high-frequency navigation
- Back-projection degrades με noisy depth
- Χωρίς fallback strategy όταν VLM consistently unavailable

Κρυφές Παραδοχές

- VLM correct knowledge of deployment environment
- Depth sensor covers pixel hint location
- Robot pose accurate για back-projection

Σενάρια Αποτυχίας

- Rooms different from VLM training distribution
- Poor lighting: VLM misidentifies scene
- High-confidence wrong goal (overconfident hallucination)
- High API latency: response arrives μετά που robot έχει κινηθεί

⑧ Πώς Γίνεται Δημοσίευση

Τίτλος Paper	Structured VLM Interfaces for Reliable Semantic Navigation Goal Generation
Venue	CoRL / ICRA Foundation Models for Robotics Workshop

Missing Experiments

- Live navigation: robot navigates σε VLM-generated goals
- Comparison με LM-Nav και ViNT
- Failure mode analysis: top 5 αιτίες VLM goal errors
- Latency optimization: batched calls, predictive caching

Ablations που Χρειάζονται

- Local (Ollama) vs cloud (GPT-4V): accuracy vs latency
- Με vs χωρίς confidence gating
- Structured JSON vs free-text prompting
- τ_c sensitivity: false negative vs false positive

⑨ Ανοιχτά Ερευνητικά Ερωτήματα

- 31. Μπορεί VLM confidence να calibrated post-hoc με navigation episodes;
- 32. Μπορεί VLM να fine-tuned σε deployment environment με few examples;
- 33. Πώς να ανταποκρίνεται ο ρομπότ όταν VLM unavailable για extended periods;

10 Αν Είχα 2 Λεπτά να το Εξηγήσω σε Οποιονδήποτε...

Αντί για συντεταγμένες, λες «πήγαινε στην κουζίνα». Το ρομπότ δείχνει την κάμερά του σε ένα μεγάλο vision-language model, που κοιτάει την εικόνα και απαντά σε structured JSON: «βλέπω διάδρομο, να πας εκεί». Αν το confidence της απάντησης είναι χαμηλό, αγνοείται αντί να ακολουθείται τυφλά. Το pixel location που αναφέρει μετατρέπεται σε πραγματικές συντεταγμένες μέσω depth camera.

Βαθμολογία

Διάσταση	Βαθμός	Σχόλιο
Πρωτοτυπία	7/10	Incremental
Τεχνικό Βάθος	7/10	Prototype επίπεδο
Δημοσιευσιμότητα	6/10	Χρειάζεται experiments
PhD Δυναμικό	7/10	Υποστηρικτικό υλικό

Contribution 12 Diffusion Occupancy Maps — Probabilistic Risk από DDPM

Κατηγορία: Generative AI / Risk

① Εξήγηση για Αρχάριο — Από το Μηδέν

Τι πρόβλημα λύνει;

Αντί για μια εκτίμηση «κελί X: 70% κατειλημμένο», παράγουμε 10 πιθανά μελλοντικά σενάρια χάρτη. Σχεδιάζουμε για τα χειρότερα 5% — CVaR risk από generative AI.

Γιατί υπάρχει αυτό το πρόβλημα;

Μια μόνο εκτίμηση αποτυγχάνει αν είναι λανθασμένη. Η πιθανολογική προσέγγιση με CVaR εγγυάται ότι λαμβάνουμε υπόψη τα άσχημα σενάρια — σαν ασφαλιστής που σχεδιάζει για tail risk.

Γιατί είναι δύσκολο;

DDPM (Denoising Diffusion Probabilistic Model) απαιτεί ισχυρό score network (U-Net) εκπαιδευμένο σε μεγάλα datasets. Χωρίς εκπαίδευση, τα samples είναι τυχαίος θόρυβος.

② Αναλογία & Διαίσθηση

Μετεωρολόγος που παράγει 10 σενάρια καιρού αντί για μία πρόβλεψη. Σχεδιάζεις το υπαίθριο γεγονός γύρω από το χειρότερο 5%. Structural engineer: Monte Carlo σε 10.000 load scenarios → design για P99.

③ Τι Έκανα Ακριβώς — Βήμα-Βήμα

- Cosine noise schedule: β_t από cosine function (Nichol & Dhariwal 2021)
- Forward process: $q(x_t|x_0) = N(\sqrt{\alpha}_t x_0, (1-\alpha_t)I)$ — progressive corruption
- Reverse process: DDPM denoising με score network $\epsilon_\theta(x_t, t, \text{cond})$
- Score network: MLP stub  — χρειάζεται U-Net για production
- N samples από reverse diffusion
- Per-cell CVaR-95: sorted N samples, average top 5%
- Risk map τροφοδοτεί A* (C03)

Ροή Δεδομένων

Occupancy history → DDPM forward (noise) | DDPM reverse (denoise) × N → N samples → CVaR-95 per cell → risk map → planner

④ Βαθιά Τεχνική Ανάλυση

Βασικά Components

- Cosine scheduler: $\bar{\alpha}_t, \beta_t, \alpha_t$ για T=50 steps
- Score network ϵ_θ : MLP stub (replace with U-Net)
- DDPM reverse chain: T denoising steps per sample

- CVaR estimator: sort N samples, average top $(1-0.95) \cdot N$ per cell

Pseudocode / Αλγόριθμος

```
DDPM REVERSE (inference — single sample):
    x = randn(H, W) // ξεκινά από pure Gaussian noise
    για t σε reversed(range(T)):
        eps = score_network(x, t, conditioning)
        mu = (1/sqrt(α[t])) * (x - β[t]/sqrt(1-α[t]) * eps)
        αν t > 0: x = mu + sqrt(β[t]) * randn_like(x)
        αλλιώς: x = mu
    return clip(x, 0, 1)

CVaR ΑΠΟ N SAMPLES:
    samples = [reverse_diffusion(cond) για _ σε range(N)]
    cvar_95[c] = mean(sorted(s[c] for s in samples)[-int(0.05*N):])
```

Μαθηματική Φορμοποίηση

Forward: $q(x_t|x_0) = N(\sqrt{\alpha_t} x_0, (1-\alpha_t)I)$
 Cosine: $\alpha_t = \cos^2((t/T+s)/(1+s) \cdot \pi/2) / \cos^2(s/(1+s) \cdot \pi/2)$
 Reverse: $x_{t-1} = (1/\sqrt{\alpha_t})(x_t - \beta_t/\sqrt{1-\alpha_t} \cdot \epsilon_\theta) + \sqrt{\beta_t} \cdot z$
 Training: $L(\theta) = E[||\epsilon_\theta(\sqrt{\alpha_t} x_0 + \sqrt{1-\alpha_t} \epsilon, t, \text{cond}) - \epsilon||^2]$
 $CVaR_{0.95}(c) = (1/[0.05N]) \sum_{\text{top } 5\%} \text{sample_i}[c]$

Πολυπλοκότητα & Παραδοχές

Χρονική πολυπλοκότητα: Reverse diffusion: $O(T \cdot |\text{score_net}|)$ per sample. N samples: $O(N \cdot T \cdot |\epsilon_\theta|)$. Με U-Net: 1-10s per sample σε GPU.

- Score network expressive αρκετά για occupancy distributions ⚠ MLP stub
- Training data representative of deployment distribution
- $N=10$ samples sufficient για CVaR estimation
- Occupancy σε $[0,1]$ per cell

⑤ Ερευνητική Αξία

Ερευνητικό Ερώτημα

Μπορεί DDPM-based occupancy predictor να παράγει calibrated probabilistic forecasts που οδηγούν σε καλύτερες CVaR risk estimates vs deterministic baselines;

Novelty — Τι Καινούργιο Κάνω

Εφαρμογή diffusion models σε occupancy prediction για CVaR-optimal navigation. Plug-in interface με risk planner (C03) — οποιαδήποτε probabilistic occupancy source → ίδιος planner.

Σχετική Βιβλιογραφία

Ho et al. (2020) DDPM. Nichol & Dhariwal (2021) improved DDPM. Jiang et al. (2023) MotionDiffuser. Carvalho et al. (2023) motion planning with diffusion.

⑥ Αποτελέσματα & Τι Σημαίνουν

DDPM pipeline εκτελείται σωστά. CVaR στατιστικά υπολογίζονται. ⚠ MLP stub παράγει τυχαία samples — occupancy prediction δεν έχει νόημα.

Metrics

- CVaR-95 per cell από N samples
- Sample diversity: entropy of N generated maps
- Risk-weighted path cost vs deterministic baseline
- Calibration: CVaR_0.95 αντιστοιχεί στο actual 95th percentile;

Τι Λείπει Ακόμα

MLP stub παράγει uninformative samples. U-Net εκπαιδευμένο σε occupancy data απαιτείται. Δεν υπάρχει σύγκριση με deterministic inflation.

⑦ Αυστηρή Κριτική — Reviewer Mode

Αδυναμίες

- ⚠ MLP stub: δεν μπορεί spatial correlations — χρειάζεται U-Net
- Χωρίς εκπαίδευση: όλα τα samples τυχαία — module non-functional
- Diffusion inference latency: 1-10s ανά sample σε GPU — πολύ για real-time
- N=10 samples: high-variance CVaR estimation

Κρυφές Παραδοχές

- Training data captures deployment distribution
- MLP stub replaceable by U-Net χωρίς αλλαγές
- N=10 sufficient για CVaR estimation

Σενάρια Αποτυχίας

- ⚠ Score network untrained: όλα outputs τυχαία — module non-functional
- Very dynamic environments: DDPM assumes temporal continuity
- Stale conditioning: αν observation history παλαιά, conditioning λάθος

⑧ Πώς Γίνεται Δημοσίευση

Τίτλος Paper	Diffusion-Based Probabilistic Occupancy Prediction for CVaR-Optimal Robot Navigation
Venue	CoRL / ICRA — χρειάζεται trained U-Net score network πρώτα

Missing Experiments

- Train U-Net σε robot occupancy data (ScanNet, nuScenes ή custom)
- Compare CVaR risk map quality: diffusion vs deterministic inflation vs Gaussian belief
- Evaluate: reduces diffusion-based risk planning collisions σε dynamic environments;
- DDIM acceleration για faster inference

Ablations που Χρειάζονται

- MLP vs U-Net: πόσο σημαντική η architecture;
- N samples: 5 vs 10 vs 20 — CVaR accuracy vs compute
- Cosine vs linear noise schedule

- Conditioned vs unconditioned diffusion

9) Ανοιχτά Ερευνητικά Ερωτήματα

34. Μπορεί consistency regularizer να βελτιώσει temporal coherence;
35. Minimum N για accurate CVaR — theoretical lower bound;
36. Μπορεί diffusion model να trained να directly minimizes navigation CVaR;

10) Αν Είχα 2 Λεπτά να το Εξηγήσω σε Οποιονδήποτε...

Αντί για μια εκτίμηση «το κελί X είναι 70% κατειλημμένο», παράγουμε 10 πιθανά μελλοντικά σενάρια χάρτη χρησιμοποιώντας generative AI (diffusion models — ίδια τεχνολογία με DALL-E). Από αυτά τα 10 σενάρια, εξάγουμε το CVaR-95 (μέσος όρος του χειρότερου 5%) ως risk map για τον planner. Το framework είναι σωστό — το score network χρειάζεται εκπαίδευση.

Βαθμολογία

Διάσταση	Βαθμός	Σχόλιο
Πρωτοτυπία	8/10	Γνήσια καινοτόμο
Τεχνικό Βάθος	8/10	Πλήρης μαθ. ανάλυση
Δημοσιευσιμότητα	7/10	Χρειάζεται experiments
PhD Δυναμικό	8/10	Ισχυρό κεφάλαιο διδακτορικού

Contribution 13 Latent World Model — RSSM (DreamerV3)

Κατηγορία: Model-Based RL

① Εξήγηση για Αρχάριο — Από το Μηδέν

Τι πρόβλημα λύνει;

Πριν κινηθεί, το ρομπότ «φαντάζεται» στο μυαλό του τι θα γινόταν αν εκτελούσε διάφορες ακολουθίες κινήσεων. Επιλέγει την καλύτερη ακολουθία και εκτελεί μόνο την πρώτη κίνηση.

Γιατί υπάρχει αυτό το πρόβλημα;

Reactive planners αντιδρούν μόνο στο παρόν. Ένα world model επιτρέπει lookahead — εντοπισμό προβλημάτων (π.χ. dead ends) πριν συμβούν, σαν σκακιστής που σκέφτεται μπροστά.

Γιατί είναι δύσκολο;

RSSM απαιτεί μεγάλα ποσά navigation data και ισχυρό recurrent network. Πρέπει να καταγράφει deterministic dynamics ΚΑΙ stochastic uncertainty. Numpy stubs = δεν εκπαιδεύεται.

② Αναλογία & Διαίσθηση

Pilot σε flight simulator: δοκιμάζει επικίνδυνους ελιγμούς στο μυαλό χωρίς κίνδυνο. DreamerV3 κάνει αυτό για navigation: compact, fast mental simulator που τρέχει στον υπολογιστή του ρομπότ.

③ Τι Έκανα Ακριβώς — Βήμα-Βήμα

- RSSM: $h_t = \text{GRU}(h_{t-1}, z_{t-1}, a_{t-1})$ — deterministic recurrent memory
- Prior: $z_t \sim p_\phi(z|h_t) = \mathcal{N}(\mu_\phi(h_t), \sigma_\phi(h_t))$ — imagined latent
- Posterior: $z_t \sim q_\phi(z|h_t, o_t)$ — observation-updated latent
- Reward predictor: $\hat{r} = g_\phi(h_t, z_t)$
- Mental rollout: H prior steps χωρίς real observations
- Irreversibility penalty: subtract λ_{irrev} αν final state non-returnable (C04)
- Action selection: random shooting K candidates $\rightarrow \arg\max G$
- ⚠ Όλα τα networks: numpy MLP stubs — δεν εκπαιδεύονται

Ροή Δεδομένων

Current observation $\rightarrow$ posterior $(h_t, z_t) \rightarrow$ mental rollout H steps $\times K$ candidates $\rightarrow$ score = $\sum \gamma^k \hat{r}_k - \text{irrev penalty} \rightarrow$ best first action

④ Βαθιά Τεχνική Ανάλυση

Βασικά Components

- GRU-like transition: $h_t = \text{GRU}(h_{t-1}, z_{t-1}, a_{t-1})$
- Prior network: $z_t \sim \mathcal{N}(\mu_\phi(h_t), \sigma_\phi(h_t))$ — imagined next latent
- Posterior network: $z_t \sim \mathcal{N}(\mu_q(h_t, o_t), \sigma_q)$ — real observation update

- Reward predictor: $\hat{r} = g_\phi(h_t, z_t)$
- Random shooter: K candidate sequences, scores by G

Pseudocode / Αλγόριθμος

```

BELIEF UPDATE (real step):
    h_t = GRU(h_{t-1}, z_{t-1}, a_{t-1})
    z_t ~ posterior(h_t, o_t)          // real observation

MENTAL ROLLOUT (imagination):
    h, z = h_t, z_t                  // start from current belief
    G = 0
    για k σε range(H):
        h = GRU(h, z, a_k)
        z ~ prior(h)                 // imagined next latent
        G += γ^k * reward_pred(h, z)
    αν not returnable(h, z): G -= λ_irrev
    return G

ACTION SELECTION:
    sequences = [random_sequence(H) για _ σε range(K)]
    a_star = sequences[argmax(rollout(s) για s σε sequences)]
    execute(a_star[0]) // μόνο η πρώτη κίνηση

```

Μαθηματική Φορμοποίηση

RSSM: $h_t = f_\phi(h_{t-1}, z_{t-1}, a_{t-1}), z_t \sim p_\phi(z|h_t)$ ή $q_\phi(z|h_t, o_t)$

Rollout value: $G(a) = \sum_{k=1}^H \gamma^{k-1} \cdot \hat{r}_k - \lambda \cdot 1[\neg \text{Ret}(h_H, z_H)]$

ELBO: $E_q[\sum_t \log p(o_t|h_t, z_t) + \log p(r_t|h_t, z_t) - \beta \cdot \text{KL}(q_\phi||p_\phi)]$

KL: $\text{KL}(N(\mu_q, \sigma_q) || N(\mu_p, \sigma_p)) = \log(\sigma_p/\sigma_q) + (\sigma_q^2 + (\mu_q - \mu_p)^2) / (2\sigma_p^2) - \frac{1}{2}$

Πολυπλοκότητα & Παραδοχές

Χρονική πολυπλοκότητα: Rollout: $O(H \cdot K \cdot |RSSM|)$. Για $H=12, K=16$: 192 RSSM forward passes.

- RSSM accurately models navigation dynamics ⚠️ δεν εκπαιδεύτηκε
- Random shooting βρίσκει near-optimal sequences
- $H=12$ αρκετό για irreversible situations
- Reward predictor informative πριν εκπαίδευση

⑤ Ερευνητική Αξία

Ερευνητικό Ερώτημα

Μπορεί RSSM mental rollouts με returnability penalties να μειώσει irreversible state entry vs reactive planning;

Novelty — Τι Καινούργιο Κάνω

Integration RSSM mental rollouts με returnability constraints (C04) ως planning-time penalty. DreamerV3 εφαρμόζεται σχεδόν αποκλειστικά σε game-playing — η adaptation για safe navigation με irreversibility penalties είναι underexplored.

Σχετική Βιβλιογραφία

Hafner et al. (2019) DreamerV1, (2020) DreamerV2, (2023) DreamerV3. Ha & Schmidhuber (2018) World Models.

⑥ Αποτελέσματα & Τι Σημαίνουν

RSSM architecture εκτελείται σωστά. Rollout returns discounted sums. ⚠ Τυχαία weights — latent dynamics meaningless.

Metrics

- Imagined return G distribution across K sequences
- Irreversibility penalty application rate
- Action consistency (same state → same best action;)
- Comparison vs reactive planning baseline

Τι Λείπει Ακόμα

Networks δεν εκπαιδεύτηκαν. Random shooting suboptimal. Δεν υπάρχει σύγκριση με reactive planning.

⑦ Αυστηρή Κριτική — Reviewer Mode

Αδυναμίες

- ⚠ Τυχαία RSSM weights: τυχαία latent dynamics → τυχαία action selection
- Random shooting highly suboptimal vs CEM ή MPC
- GRU stub πολύ απλοποιημένο vs proper RSSM
- Χωρίς εκπαίδευση: κανένα real contribution

Κρυφές Παραδοχές

- RSSM εκπαιδεύσιμο σε accurate navigation dynamics από data
- H=12 αρκετό για complex environments
- Reward predictor informative πριν training

Σενάρια Αποτυχίας

- ⚠ Χωρίς εκπαίδευση: όλα theoretical
- Long corridors requiring H > 12 steps
- Highly stochastic environments: prior variance dominates

⑧ Πώς Γίνεται Δημοσίευση

Τίτλος Paper	Safety-Aware World Model Planning: RSSM με Returnability-Penalized Imagination
Venue	CoRL / NeurIPS Offline RL Workshop — μετά PyTorch training

Missing Experiments

- Implement PyTorch RSSM με proper backpropagation
- Train σε 10K+ TurtleBot3 navigation episodes

- Compare vs reactive A*: reduces irreversible entries;
- CEM vs random shooting για action selection

Ablations που Χρειάζονται

- Trained RSSM vs stub — σημαίνει εκπαίδευση; (NAI — κεντρικό result)
- Με vs χωρίς irreversibility penalty
- H=6 vs 12 vs 24 — horizon sensitivity
- Random shooting vs CEM

9 Άνοιχτά Ερευνητικά Ερωτήματα

37. Μπορεί RSSM να fine-tuned online σε νέα environments;
38. Μπορεί returnability check να γίνει differentiable για gradient-based sequence optimization;
39. Πώς compound model errors over rollout horizon — theoretical limit of H;

10 Αν Είχα 2 Λεπτά να το Εξηγήσω σε Οποιονδήποτε...

Πριν κινηθεί, το ρομπότ προσομοιώνει στο μυαλό του τι θα γινόταν αν δοκίμαζε διάφορες ακολουθίες κινήσεων. Ο εσωτερικός προσομοιωτής (RSSM) είναι ένα συμπαγές νευρωνικό δίκτυο που μαθαίνει τη δυναμική του κόσμου. Ακολουθίες που οδηγούν σε αδιέξοδο (non-returnable states) τιμωρούνται. Η καλύτερη εκτελείται. Κλειδί: ο προσομοιωτής πρέπει να εκπαιδευτεί — τώρα έχει την αρχιτεκτονική, εκκρεμεί η εκπαίδευση.

Βαθμολογία

Διάσταση	Βαθμός	Σχόλιο
Πρωτοτυπία	8/10	Γνήσια καινοτόμο
Τεχνικό Βάθος	8/10	Πλήρης μαθ. ανάλυση
Δημοσιευσιμότητα	6/10	Χρειάζεται experiments
PhD Δυναμικό	9/10	Ισχυρό κεφάλαιο διδακτορικού

Contribution 14 Causal Risk Attribution — SCM & Do-Calculus

Κατηγορία: Causal AI / Failure Analysis

① Εξήγηση για Αρχάριο — Από το Μηδέν

Τι πρόβλημα λύνει;

Μετά από αποτυχία, το ρομπότ ρωτάει «ΓΙΑΤΙ έγινε;» — όχι απλώς «ΤΙ έγινε;». Χρησιμοποιεί Pearl's do-calculus για causal reasoning: «αν ο θόρυβος αισθητήρα ήταν μηδέν, θα γινόταν ακόμα σύγκρουση;»

Γιατί υπάρχει αυτό το πρόβλημα;

Στατιστική ανάλυση βρίσκει correlations — αλλά correlation $\neq$ causation. Κακός φωτισμός μπορεί να προκαλεί και υψηλό sensor noise ΚΑΙ crashes ανεξάρτητα. Causal reasoning αποκαλύπτει την πραγματική αιτία.

Γιατί είναι δύσκολο;

Σωστός ορισμός causal graph απαιτεί domain expertise. Structural equations πρέπει να μοντελοποιούν ακριβώς τις causally relations. Counterfactual reasoning απαιτεί «holding fixed» exogenous noise — mathematically precise operation.

② Αναλογία & Διαίσθηση

Ερευνητής αεροπορικού ατυχήματος: «Τα πτερύγια παγώσαν → ψεύτικη ένδειξη ταχύτητας → λάθος αντιδράσεις autopilot → συντριβή». Κάθε link είναι causal relationship, όχι correlation. Ο ερευνητής βρίσκει ποιο link να διορθώσει.

③ Τι Έκανα Ακριβώς — Βήμα-Βήμα

- SCM με 6 navigation μεταβλητές: sensor_noise $\rightarrow$ localization_error $\rightarrow$ obstacle_detection $\rightarrow$ path_risk $\rightarrow$ collision (+ map_accuracy branch)
- Structural equations: $V_i = f_i(PA_i, U_i)$ — κάθε μεταβλητή συνάρτηση parents + exogenous noise
- Observational query: forward pass through causal graph δεδομένου noise realizations
- Counterfactual: do($X=x$) — force X , keep same noise, recompute downstream
- ACE = $E[Y|do(X=x)] - E[Y|do(X=x')]$ via Monte Carlo
- Root-cause ranking: Shapley-inspired ablation
- 4 tests passing

Ροή Δεδομένων

Observed failure + noise estimate $\rightarrow$ SCM forward $\rightarrow$ counterfactual queries $\rightarrow$ ACE estimation $\rightarrow$ root-cause ranking $\rightarrow$ actionable diagnosis

④ Βαθιά Τεχνική Ανάλυση

Βασικά Components

- SCM graph: 6 nodes, directed edges encoding causal relationships

- Structural equations: linear functions (hand-crafted — δεν μαθαίνονται από data)
- Counterfactual computer: mutilated model M_x με forced intervention
- ACE estimator: Monte Carlo over N noise samples
- Shapley approximator: ablation-based root-cause ranking

Pseudocode / Αλγόριθμος

```
OBSERVATIONAL QUERY:
vals = {}
για κάθε node σε topological_order:
    vals[node] = f_node(parent_vals, noise[node])

COUNTERFACTUAL do(X=x):
    για κάθε node σε topological_order:
        αν node == X: vals[node] = x    // forced intervention
        αλλιώς: vals[node] = f_node(parent_vals, noise[node])    // same noise

ACE ESTIMATION:
diffs = []
για _ σε range(N):
    noise = {n: randn() για n σε nodes}
    y_treat = counterfactual(noise, {X: x})[Y]
    y_ctrl = counterfactual(noise, {X: x_prime})[Y]
    diffs.append(y_treat - y_ctrl)
return mean(diffs)
```

Μαθηματική Φορμοποίησηση

```
SCM:  $V_i = f_i(PA_i, U_i)$ ,  $PA_i = \text{parents}$ ,  $U_i = \text{exogenous noise}$ 
Do-operator:  $P(Y|\text{do}(X=x)) = \sum_z P(Y|X=x, pa(X)=z) P(pa(X)=z)$ 
Counterfactual:  $Y_x(u) = Y(M_x, u)$  (same noise, different intervention)
ACE:  $E_U[Y_x(U)] - E_U[Y_{x'}(U)]$  (Monte Carlo estimation)
Shapley approx:  $\phi_i = E_U[Y_{\text{obs}}(U) - Y_{\{V_i=0\}}(U)]$ 
```

Πολυπλοκότητα & Παραδοχές

Χρονική πολυπλοκότητα: $O(N \cdot |V|)$ για ACE Monte Carlo. $O(N \cdot |V|^2)$ για all ablations. Tractable για small graphs.

- Causal graph correctly specified — ΣΚΛΗΡΗ παραδοχή
- Structural equations faithfully model causal mechanisms
- Exogenous noises U_i independent across nodes
- Linear equations adequate (μπορεί να χάνει nonlinear interactions)

⑤ Ερευνητική Αξία

Ερευνητικό Ερώτημα

Μπορεί SCM do-calculus counterfactual reasoning να αναγνωρίσει actionable root causes navigation failures που διαφέρουν από correlational analysis;

Novelty — Τι Καινούργιο Κάνω

Εφαρμογή SCM + do-calculus σε navigation failure attribution είναι σχετικά novel σε mobile robotics. Σύζευξη με Failure Explainer (C20) δημιουργεί unique diagnostic pipeline.

Σχετική Βιβλιογραφία

Pearl (2009) Causality. Spirtes et al. (2000) — causal structure learning. Richens et al. (2020) — counterfactual diagnosis σε medicine.

⑥ Αποτελέσματα & Τι Σημαίνουν

Causal attribution παράγει interpretable rankings. ACE converges με N. 4 tests passing. ⚠️ Structural equations hand-crafted.

Metrics

- ACE magnitude per variable
- Root cause ranking (sorted by $|\phi_i|$)
- Sensitivity to structural equation specification
- Σύγκριση με correlational baseline

Τι Λείπει Ακόμα

Structural equations χειροποίητες — δεν μαθαίνονται. Causal graph assumed — δεν discovered. Δεν υπάρχει ground truth για causal attribution.

⑦ Αυστηρή Κριτική — Reviewer Mode

Αδυναμίες

- Χειροποίητες linear structural equations — μπορεί να miss real mechanisms
- Causal graph μπορεί να έχει λάθος edges ή κατεύθυνση
- Linear equations miss nonlinear interactions
- Δεν υπάρχει identifiability analysis

Κρυφές Παραδοχές

- Causal graph correctly specified
- Exogenous noises independent
- Linear equations adequate

Σενάρια Αποτυχίας

- Incorrectly specified graph: attribution σε non-causal variable
- Feedback loops σε real systems (δεν μοντελοποιούνται)
- Unobserved confounders not in graph

⑧ Πώς Γίνεται Δημοσίευση

Τίτλος Paper	Causal Attribution of Robot Navigation Failures via SCM και Counterfactual Reasoning
Venue	ICRA / NeurIPS Causal ML Workshop / UAI

Missing Experiments

- Learn structural equations από navigation episode data

- Compare causal vs correlational ranking σε same failure data
- Human evaluation: engineers find causal attributions more actionable;
- Ground-truth study: inject known failures, evaluate attribution accuracy

Ablations που Χρειάζονται

- Learned vs hand-crafted structural equations
- Linear vs nonlinear equations
- N samples για ACE convergence
- Full causal graph vs partial

⑨ Ανοιχτά Ερευνητικά Ερωτήματα

- 40. Μπορεί causal graph να learned από navigation episodes (PC, FCI algorithms);
- 41. Μπορεί causal attribution να guide automated remediation;
- 42. Μπορεί causal model για counterfactual data augmentation;

⑩ Αν Είχα 2 Λεπτά να το Εξηγήσω σε Οποιονδήποτε...

Όταν κάτι πάει στραβά, χρειάζεσαι τη ΠΡΑΓΜΑΤΙΚΗ αιτία — όχι απλώς τι υπήρχε όταν έγινε το πρόβλημα. Αυτό το module χτίζει ένα μαθηματικό γράφο αιτιότητας: *sensor_noise* → *positioning_error* → *detection_failure* → *crash*. Μετά ρωτάει: «αν ο *sensor noise* ήταν μηδέν, θα γινόταν *crash*;» Αυτή η *counterfactual* ερώτηση αναγνωρίζει την πραγματική αιτία. Αποτέλεσμα: *actionable* — διορθώνεις την πραγματική αιτία, όχι τα συμπτώματα.

Βαθμολογία

Διάσταση	Βαθμός	Σχόλιο
Πρωτοτυπία	8/10	Γνήσια καινοτόμο
Τεχνικό Βάθος	8/10	Πλήρης μαθ. ανάλυση
Δημοσιευσιμότητα	7/10	Χρειάζεται <i>experiments</i>
PhD Δυναμικό	9/10	Ισχυρό κεφάλαιο διδακτορικού

Contribution 15 Neuromorphic Sensing — DVS + LIF-SNN

Κατηγορία: Neuromorphic / Bio-inspired

① Εξήγηση για Αρχάριο — Από το Μηδέν

Τι πρόβλημα λύνει;

Κανονικές κάμερες: 30 frames/sec = 33ms καθυστέρηση. DVS κάμερα: κάθε pixel «πυροδοτεί» ανεξάρτητα όταν ανιχνεύει αλλαγή — σε microseconds. Spiking Neural Network επεξεργάζεται αυτά τα events.

Γιατί υπάρχει αυτό το πρόβλημα;

Γρήγορα ρομπότ και drones δεν μπορούν να περιμένουν 33ms για frame. DVS + SNN παρέχουν detection σε τάξη μεγέθους χαμηλότερη latency — απαραίτητο για high-speed navigation.

Γιατί είναι δύσκολο;

Event streams δεν είναι εικόνες — standard CNNs δεν λειτουργούν. Χρειάζονται νέες αναπαραστάσεις (time surfaces) και νέες αρχιτεκτονικές (SNNs). SNN training απαιτεί surrogate gradients.

② Αναλογία & Διαίσθηση

Ανιχνευτής καπνού vs φωτογραφική μηχανή: ο ανιχνευτής δεν παίρνει φωτογραφίες κάθε 33ms — ανιχνεύει αλλαγή ΑΜΕΣΑ. DVS = ανιχνευτής καπνού με χωρική ανάλυση. Βιολογικό: ο τενίστας βλέπει μπάλα 200km/h γιατί το ανθρώπινο visual system έχει specialized motion detection.

③ Τι Έκανα Ακριβώς — Βήμα-Βήμα

- DVS simulator: $\Delta L = \log(f_2) - \log(f_1)$ per pixel
- Event αν $\Delta L \geq C_{\text{pos}}$ (ON event, polarity=+1) ή $\Delta L \leq -C_{\text{neg}}$ (OFF event, -1)
- Refractory period: minimum time μεταξύ events per pixel
- Gaussian noise events σε rate ρ (realism model)
- Time surface: $T_p(x,y,t) = \exp(-(t-t_{\text{last}_p})/\tau)$ — 2-channel representation
- LIF neuron: $V_{t+1} = e^{-\Delta t/\tau_m} V_t + (1 - e^{-\Delta t/\tau_m}) I_t$, spike αν $V \geq V_{\text{thresh}}$
- SNN grid: spatial grid of LIF neurons, weighted sum of time surface
- Output: obstacle probability = spike_count/N_steps per cell
- ⚠ SNN weights τυχαία — δεν εκπαιδεύτηκε

Ροή Δεδομένων

Frame pair → DVS events → time surface (2-channel) → SNN LIF neurons (N steps) → spike counts → obstacle probability grid

④ Βαθιά Τεχνική Ανάλυση

Βασικά Components

- DVS simulator: per-pixel log-intensity threshold comparison
- Noise model: Gaussian events σε configurable rate
- Time surface: exponential decay T_p per polarity channel
- LIF neuron: correct discrete dynamics με refractory period
- SNN grid: spatial layout, random weights (awaiting training)

Pseudocode / Αλγόριθμος

```
DVS SIMULATION:
για κάθε pixel (x, y):
    delta = log(frame2[y,x]+ε) - log(frame1[y,x]+ε)
    αν delta >= C_pos και refractory_ok(x,y):
        events.append(Event(x, y, t, polarity=+1))
    αλλιώς αν delta <= -C_neg και refractory_ok(x,y):
        events.append(Event(x, y, t, polarity=-1))

TIME SURFACE:
για κάθε event e:  $T_p(e.x, e.y) = \max(T_p, \exp(-(t-e.t)/\tau))$ 

LIF STEP:
 $V = \exp(-dt/\tau_m) \cdot V + (1 - \exp(-dt/\tau_m)) \cdot I_{ext}$ 
αν  $V \geq V_{thresh}$ : spike;  $V = V_{reset}$ 
```

Μαθηματική Φορμοποίησηση

```
DVS event:  $e=(x,y,t,p)$  αν  $|\Delta L(x,y,t)| \geq C_p$ ,  $\Delta L = \log I(t) - \log I(t_{prev})$ 
Time surface:  $T_p(x,y,t) = \exp(-(t - t_p^{last}(x,y))/\tau)$ 
LIF continuous:  $\tau_m \frac{dV}{dt} = -V + I_{ext}$ 
LIF discrete:  $V_{t+1} = e^{-\Delta t/\tau_m} \cdot V_t + (1 - e^{-\Delta t/\tau_m}) \cdot I_t$ 
Output:  $\hat{O}_{ij} = \text{spike\_count}_{ij} / N_{steps} \in [0,1]$ 
```

Πολυπλοκότητα & Παραδοχές

Χρονική πολυπλοκότητα: DVS: $O(W \cdot H)$ per frame. Time surface: $O(N_{events})$. SNN: $O(G_n \cdot G_m \cdot N_{steps})$. Όλα fast.

- LIF adequate για spike-based processing
- Time surface sufficient για event stream information
- ⚠️ Τυχαία SNN weights — output meaningless
- DVS simulator faithfully replicates real DVS camera

⑤ Ερευνητική Αξία

Ερευνητικό Ερώτημα

Μπορεί DVS + LIF-SNN να παρέχει *spatial obstacle probability maps* με χαμηλότερη *detection latency* vs frame-based approaches;

Novelty — Τι Καινούργιο Κάνω

Full data pipeline: DVS simulation → time surface → SNN, integrated σε DynNav navigation stack. Οι περισσότερες DVS robotics papers είναι standalone — αυτή η integration είναι differentiator.

Σχετική Βιβλιογραφία

Gallego et al. (2020) — event-based vision survey. Zhu et al. (2018) — event-based optical flow. Gehrig et al. (2020) — end-to-end με events.

⑥ Αποτελέσματα & Τι Σημαίνουν

DVS simulator validated. LIF dynamics correct. Time surface correct. ⚠ Τυχαία SNN weights → τυχαία obstacle detection.

Metrics

- Detection latency (event → obstacle flag)
- Spatial accuracy: spike rate vs obstacle location
- Sensitivity: minimum detectable obstacle speed
- False positive rate από noise events

Τι Λείπει Ακόμα

SNN δεν εκπαιδεύτηκε. Δεν υπάρχει σύγκριση με frame-based detection. Δεν υπάρχει real DVS hardware evaluation.

⑦ Αυστηρή Κριτική — Reviewer Mode

Αδυναμίες

- ⚠ Χωρίς SNN training: output τυχαίο — module δεν ανιχνεύει τίποτα
- Single-layer SNN — deep/conv SNN χρειάζεται για complex patterns
- Time surface throws away temporal ordering within window
- Constant threshold C — real DVS: per-pixel variation

Κρυφές Παραδοχές

- Constant threshold C σε όλες τις συνθήκες
- Time surface με fixed τ αρκεί για όλα velocity ranges
- LIF adequate για required spatial processing

Σενάρια Αποτυχίας

- Very slow objects: κάτω από DVS threshold → δεν παράγονται events
- High-noise: events καλύπτουν real motion
- Static obstacles: DVS ανιχνεύει μόνο change — invisible χωρίς camera motion

⑧ Πώς Γίνεται Δημοσίευση

Τίτλος Paper	Event-Driven Obstacle Detection: DVS Simulation και LIF-SNN Spatial Processing Pipeline
Venue	CVPR Neuromorphic Workshop / IEEE Sensors

Missing Experiments

- Train SNN σε labeled DVS dataset (N-MNIST, N-Caltech ή custom)
- Compare latency: DVS+SNN vs frame-based CNN σε high-speed scenarios

- Real DVS camera σε TurtleBot3
- Σύγκριση με Asynet (event-based graph neural net)

Ablations που Χρειάζονται

- Time surface τ sensitivity
- SNN depth: 1-layer vs conv-SNN
- DVS threshold C: detection rate vs event rate
- Με vs χωρίς refractory period

9 Άνοιχτά Ερευνητικά Ερωτήματα

43. Μπορεί SNN να trained end-to-end σε navigation episodes;
44. Minimum latency: DVS+SNN vs frame-based — theoretical lower bound;
45. Μπορεί DVS να fuses με LiDAR (DVS = fast, LiDAR = accurate);

10 Αν Είχα 2 Λεπτά να το Εξηγήσω σε Οποιονδήποτε...

Κανονικές κάμερες παίρνουν «φωτογραφίες» 30 φορές ανά δευτερόλεπτο — 33ms delay. Αυτό το module χρησιμοποιεί DVS κάμερα που λειτουργεί σαν βιολογικό μάτι: κάθε pixel «πυροδοτεί» αμέσως αν ανιχνεύσει αλλαγή φωτεινότητας — σε microseconds. Αυτά τα events επεξεργάζεται ένα Spiking Neural Network. Η αρχιτεκτονική είναι σωστή — το network χρειάζεται εκπαίδευση.

Βαθμολογία

Διάσταση	Βαθμός	Σχόλιο
Πρωτοτυπία	8/10	Γνήσια καινοτόμο
Τεχνικό Βάθος	7/10	Prototype επίπεδο
Δημοσιευσιμότητα	6/10	Χρειάζεται experiments
PhD Δυναμικό	8/10	Ισχυρό κεφάλαιο διδακτορικού

Contribution 16 Federated Learning — Μάθηση χωρίς Κοινοποίηση

Κατηγορία: Federated ML / Privacy

① Εξήγηση για Αρχάριο — Από το Μηδέν

Τι πρόβλημα λύνει;

6 ρομπότ σε 6 διαφορετικά κτίρια μαθαίνουν μαζί — χωρίς να στέλνουν χάρτες ή trajectories. Μόνο model updates κοινοποιούνται, με mathematical privacy guarantee.

Γιατί υπάρχει αυτό το πρόβλημα;

Navigation data (χάρτες, trajectories) είναι ευαίσθητα — νοσοκομεία, ιδιωτικά σπίτια, εταιρικές εγκαταστάσεις. Federated learning: συλλογική μάθηση χωρίς centralization ευαίσθητων δεδομένων.

Γιατί είναι δύσκολο;

Federated learning υπό data heterogeneity (πολύ διαφορετικά environments) είναι δύσκολο — divergent gradients → FedAvg diverges. Differential privacy προσθέτει noise → degrades accuracy. Byzantine clients (C26) μπορεί να δηλητηριάσουν.

② Αναλογία & Διαίσθηση

Πληκτρολόγιο κινητού: βελτιώνει autocomplete χωρίς να στέλνει messages στον server. Κάθε τηλέφωνο trains locally, στέλνει μόνο μικρά model updates, λαμβάνει βελτιωμένο global model. Σεφ: μοιράζονται abstract «cooking principles» αντί για secret recipes.

③ Τι Έκανα Ακριβώς — Βήμα-Βήμα

- FedAvg server: $w^{t+1} = \sum_k (n_k/n) \cdot w_k^{(t)}$
- Robot client: E epochs local SGD, returns update
- DP mechanism: $\tilde{w}_k = \text{clip}(w_k, C) + N(0, \sigma^2 I)$, $\sigma = C \cdot \sqrt{(2 \ln(1.25/\delta))/\epsilon}$
- 2 aggregation modes: weighted (by n_k) και uniform
- Validation: val_MSE tracked per round
- ⚠ Training σε synthetic random data — όχι πραγματικά navigation data

Ροή Δεδομένων

Global model → broadcast → local training (E epochs) → DP noise → Δw_k → FedAvg aggregate → new global model

④ Βαθιά Τεχνική Ανάλυση

Βασικά Components

- FedAvg aggregator: weighted average by training set sizes
- Local SGD trainer: E epochs σε private data
- Gradient clipper: $\min(1, C/\|w\|) \cdot w$

- Gaussian mechanism: $+ N(0, \sigma^2 I)$
- Validation evaluator: `val_MSE` per round

Pseudocode / Αλγόριθμος

```
SERVER:
    w_global = random_init()
    για round σε range(T):
        [broadcast w_global σε όλους clients]
        updates = [client_k.train(w_global) για k σε range(K)]
        w_global = Σ (n_k/n) * w_k

CLIENT k:
    w = copy(w_global)
    για epoch σε range(E):           // local SGD
        για (x, y) σε local_data: update(w)
        w_clipped = w * min(1, C/norm(w)) // clip
        αν dp: w += randn(shape) * σ      // DP noise
    return (w_clipped, len(local_data))
```

Μαθηματική Φορμοποίησηση

```
FedAvg:  $w^{t+1} = \sum_k (n_k/n) w_k^t$ 
DP:  $\sigma = C \cdot \sqrt{(2 \ln(1.25/\delta)) / \epsilon} \rightarrow (\epsilon, \delta)$ -DP guarantee
Sensitivity:  $\Delta_2(f) \leq C$  (bounded by clipping)
Global objective:  $F(w) = \sum_k (n_k/n) L_k(w)$ 
```

Πολυπλοκότητα & Παραδοχές

Χρονική πολυπλοκότητα: Local training: $O(E \cdot n_k \cdot |w|)$. Aggregation: $O(K \cdot |w|)$. Communication: $O(K \cdot |w|)$ per round.

- Data i.i.d. across clients — ΙΣΧΥΡΑ ΠΑΡΑΒΙΑΖΕΤΑΙ σε heterogeneous fleet
- Clients honest (Byzantine δεν handled — βλ. C26)
- Linear model w adequate για navigation policy
- ⚠ Synthetic data — δεν αντιπροσωπεύει πραγματικά navigation data

⑤ Ερευνητική Αξία

Ερευνητικό Ερώτημα

Μπορεί FL με (ϵ, δ) -DP να επιτύχει comparable navigation policy quality vs centralized training, με formal privacy guarantees;

Novelty — Τι Καινούργιο Κάνω

FL με DP για robot navigation policy sharing είναι underexplored. Adaptation από image classification σε navigation (policy, not classifier) εισάγει interesting challenges.

Σχετική Βιβλιογραφία

McMahan et al. (2017) FedAvg. Dwork & Roth (2014) DP foundations. Li et al. (2020) FL survey.

⑥ Αποτελέσματα & Τι Σημαίνουν

Federated convergence: val_MSE μειώνεται σε 20 rounds. DP noise effect quantified. ⚠
Synthetic data only — navigation performance δεν μετρήθηκε.

Metrics

- Val MSE per round
- Communication rounds to convergence
- DP noise impact: accuracy υπό (ε,δ)-DP vs non-private
- Heterogeneity impact σε convergence

Τι Λείπει Ακόμα

Δεν υπάρχει evaluation με real navigation data. Privacy guarantee δεν συγκρίθηκε με actual leakage risk. Non-i.i.d. heterogeneity δεν addressed.

⑦ Αυστηρή Κριτική — Reviewer Mode

Αδυναμίες

- FedAvg assumes i.i.d. data — violated σε heterogeneous fleet
- Synthetic training: val_MSE convergence disconnected από navigation performance
- Linear model too simple για navigation policy learning
- Byzantine clients δεν handled

Κρυφές Παραδοχές

- i.i.d. data across clients
- Clients honest (no malicious poisoning)
- Linear model sufficient

Σενάρια Αποτυχίας

- Non-i.i.d. data: divergent gradients → FedAvg diverges
- Byzantine client: gradient poisoning corrupts global model
- Communication bottleneck: large navigation policies

⑧ Πώς Γίνεται Δημοσίευση

Τίτλος Paper	Privacy-Preserving Federated Navigation Policy Learning με Differential Privacy
Venue	ICRA / AAMAS / FL-ICML Workshop

Missing Experiments

- Train σε real navigation data: TurtleBot3 episodes σε διαφορετικά κτίρια
- Evaluate: federated vs centralized policy collision rate
- Non-i.i.d. analysis: heterogeneous environments impact
- Local-only vs federated: adds value;

Ablations που Χρειάζονται

- Με DP vs χωρίς DP: privacy cost σε navigation performance
- FedAvg vs FedProx (handles heterogeneity)

- $K=2$ vs 4 vs 6 vs 10 ρομπότ
- Linear vs MLP vs CNN navigation policy

9 Ανοιχτά Ερευνητικά Ερωτήματα

46. Μπορεί Byzantine-robust aggregation (C26 median) να applied σε federated gradients;
47. Ποιο ε αρκεί για robot navigation data privacy;
48. Μπορεί FL να συνδυαστεί με curriculum learning (C22) σε heterogeneous fleet;

10 Αν Είχα 2 Λεπτά να το Εξηγήσω σε Οποιονδήποτε...

6 ρομπότ σε 6 διαφορετικά κτίρια θέλουν να μοιραστούν γνώση — αλλά οι χάρτες τους είναι ιδιωτικοί. Το federated learning λύνει αυτό: κάθε ρομπότ εκπαιδεύεται τοπικά, προσθέτει *mathematical noise* στα *model updates* (*differential privacy*) για να κρύψει τι είδε, και στέλνει μόνο τα *updates*. Ο *server* συνδυάζει όλα σε βελτιωμένο *model* που όλοι παίρνουν. Το *framework* είναι σωστό — χρειάζεται εκπαίδευση σε πραγματικά *navigation data*.

Βαθμολογία

Διάσταση	Βαθμός	Σχόλιο
Πρωτοτυπία	7/10	<i>Incremental</i>
Τεχνικό Βάθος	8/10	<i>Πλήρης μαθ. ανάλυση</i>
Δημοσιευσιμότητα	7/10	<i>Χρειάζεται experiments</i>
PhD Δυναμικό	8/10	<i>Ισχυρό κεφάλαιο διδακτορικού</i>

Contribution 17 Topological Semantic Maps — CLIP Grounding

Κατηγορία: [Semantic Mapping](#)

① Εξήγηση για Αρχάριο — Από το Μηδέν

Τι πρόβλημα λύνει;

Αντί για grid κελιών, ο χώρος αναπαρίστανται ως γράφος ονομαστών ζωνών: «κουζίνα», «διάδρομος», «έξοδος». CLIP embeddings επιτρέπουν open-vocabulary grounding: «στρίψε στο workout area» → βρίσκει κόμβο «gym».

Γιατί υπάρχει αυτό το πρόβλημα;

Οι άνθρωποι περιγράφουν χώρο με ονόματα, όχι συντεταγμένες. Topological map: (α) ευκολότερη πλοήγηση με natural language, (β) compact representation, (γ) ευέλικτο για dynamic environments.

Γιατί είναι δύσκολο;

CLIP grounding απαιτεί πραγματικό CLIP model. Dynamic edge invalidation πρέπει να propagated αμέσως. Πρέπει να χτίζεται incrementally καθώς εξερευνάται.

② Αναλογία & Διαίσθηση

Ξενοδοχειακός οδηγός: Room 301, Gym, Restaurant, Pool — γράφος αντί για pixel map. Όταν ρωτάς «πού είναι το γυμναστήριο;» βρίσκεις κόμβο, ακολουθείς path. Google Maps: named landmarks, routes — όχι centimeter terrain.

③ Τι Έκανα Ακριβώς — Βήμα-Βήμα

- TopologicalSemanticMap: graph $G=(V,E,w)$ με semantic zones
- Κάθε κόμβος: label, centroid (x,y) , CLIP embedding $e_i \in \mathbb{R}^{512}$
- `add_node()`, `add_edge()`, `invalidate_edge()` για dynamic building
- Dijkstra planning σε graph
- Open-vocabulary: $v^* = \text{argmax}_i \cos(e_i, \text{CLIP.encode(query)})$
- Levenshtein fallback για fuzzy label matching
- JSON serialization για persistence
- 4 tests passing
- ⚠ Stub CLIP (hash) — real CLIP δεν connected

Ροή Δεδομένων

Text query → CLIP embed → cosine similarity → target node → Dijkstra path → metric centroids → A within zones*

④ Βαθιά Τεχνική Ανάλυση

Βασικά Components

- Graph structure: adjacency list με passable flag per edge

- CLIP embedder: stub (hash) → needs real CLIP
- Dijkstra: $O(|V|^2)$ ή $O(|E|\log|V|)$ shortest path
- Edge invalidator: marks edges impassable on obstacle discovery
- JSON serializer: persistent cross-session topological map

Pseudocode / Αλγόριθμος

```
ADD NODE KAI EDGE:
    k_id = map.add_node('kitchen', centroid=(2.0,3.0), emb=CLIP('kitchen'))
    c_id = map.add_node('corridor', centroid=(5.0,1.0), emb=CLIP('corridor'))
    map.add_edge(k_id, c_id, weight=3.2, bidirectional=True)

OPEN-VOCABULARY GROUNDING:
    q_emb = CLIP.encode(user_query)    // π.χ. 'go to cafeteria'
    v_star = argmax i: cosine(node_i.embedding, q_emb)
    ή: argmin i: levenshtein(node_i.label, user_query) // fallback

PLAN:
    path, cost = map.plan(start_id, v_star) // Dijkstra
    waypoints = [map.nodes[id].centroid για id σε path]
```

Μαθηματική Φορμοποίηση

```
Graph:  $G = (V, E, w)$  όπου  $w_{ij}$  = travel cost μεταξύ zone centroids
Dijkstra:  $d(v_s, v_g) = \min \text{path weight}$ 
Cosine:  $\cos(a, b) = a \cdot b / (||a|| \cdot ||b||)$ 
CLIP:  $v^* = \argmax_i \cos(\text{CLIP}(\text{label}_i), \text{CLIP}(\text{query}))$ 
Levenshtein:  $d(a, b) = \text{edit distance} - O(|a| \cdot |b|)$  per pair
```

Πολυπλοκότητα & Παραδοχές

Χρονική πολυπλοκότητα: Dijkstra: $O(|V|^2)$ ή $O(|E|\log|V|)$. CLIP grounding: $O(|V| \cdot d)$. Edge invalidation: $O(|E|)$. JSON: $O(|V| + |E|)$.

- Zones meaningfully distinct και non-overlapping
- CLIP embeddings correctly capture semantic similarity $\triangle$ stub
- Dijkstra path navigable (αγνοεί kinodynamic constraints)
- Zone centroids navigable locations

⑤ Ερευνητική Αξία

Ερευνητικό Ερώτημα

Επιτρέπει topological-semantic representation open-vocabulary zone navigation ενώ μειώνει planning complexity vs metric grid;

Novelty — Τι Καινούργιο Κάνω

CLIP-based open-vocabulary grounding με dynamic topological map που supports edge invalidation και Dijkstra replanning. Standard topological navigation: pre-defined labels. CLIP: arbitrary natural language queries.

Σχετική Βιβλιογραφία

Kuipers et al. (2000) topological maps. Shafiullah et al. (2022) CLIP-Fields. LERF — language embedded radiance fields. Concept Graphs.

⑥ Αποτελέσματα & Τι Σημαίνουν

Dijkstra correct. Edge invalidation correct. JSON round-trip verified. ⚠ CLIP stub — real open-vocabulary grounding δεν evaluated.

Metrics

- Zone matching accuracy
- Path length vs metric A* baseline
- Replanning success after invalidation
- CLIP grounding latency

Τι Λείπει Ακόμα

CLIP δεν connected. Δεν υπάρχει open-vocabulary evaluation. Δεν υπάρχει σύγκριση με metric planning.

⑦ Αυστηρή Κριτική — Reviewer Mode

Αδυναμίες

- Stub CLIP: correct results μόνο για exact label matches
- Graph topology manually specified — δεν automatic zone detection
- Dijkstra αγνοεί geometry within zones
- Zone centroids μπορεί να μην είναι navigable

Κρυφές Παραδοχές

- Zones meaningful CLIP embeddings
- Graph consistent με physical connectivity
- Zone boundaries clear (overlap στην πράξη)

Σενάρια Αποτυχίας

- Ambiguous descriptions: matches multiple zones
- Unknown zones: not in graph
- Dynamic zone changes δεν propagated

⑧ Πώς Γίνεται Δημοσίευση

Τίτλος Paper	Open-Vocabulary Semantic Zone Navigation via CLIP-Grounded Topological Maps
Venue	ICRA / RA-L / CoRL

Missing Experiments

- Connect real CLIP: grounding accuracy σε 50+ natural language queries
- Automatic zone detection από visual SLAM + semantic segmentation
- Real robot: TurtleBot3 με verbal instructions
- Topological vs metric A* σε same environments

Ablations που Χρειάζονται

- Real CLIP vs stub: grounding improvement
- Topological vs metric planning
- Με vs χωρίς Levenshtein fallback
- Static vs dynamic edge invalidation

9 Ανοιχτά Ερευνητικά Ερωτήματα

- 49. Μπορούν zone boundaries να detected αυτόματα (SAM + CLIP);
- 50. Μπορεί topological map να χτιστεί collaboratively από multiple robots (C09);
- 51. Πώς να resolved conflicting instructions (δύο κουζίνες);

10 Αν Είχα 2 Λεπτά να το Εξηγήσω σε Οποιονδήποτε...

Αντί για kilometer-level grid maps, ο χώρος αναπαρίστανται ως γράφος ονομαστών τοποθεσιών — «κουζίνα», «αίθουσα», «έξοδος». Όταν λες «πήγαινε στο χώρο γυμναστικής», το σύστημα βρίσκει τον κόμβο με text embedding πιο κοντινό στο «gym», σχεδιάζει διαδρομή στον γράφο, και navigates. Αν ανακαλυφθεί εμπόδιο μεταξύ δύο ζωνών, εκείνη η σύνδεση ακυρώνεται αυτόματα. Αποθηκεύεται σε JSON για χρήση σε επόμενες sessions.

Βαθμολογία

Διάσταση	Βαθμός	Σχόλιο
Πρωτοτυπία	8/10	Γνήσια καινοτόμο
Τεχνικό Βάθος	7/10	Prototype επίπεδο
Δημοσιευσιμότητα	7/10	Χρειάζεται experiments
PhD Δυναμικό	8/10	Ισχυρό κεφάλαιο διδακτορικού

Contribution 18 Formal Safety Shields — STL + CBF ☆

ΚΟΡΥΦΑΙΟ

Κατηγορία: Formal Methods / Runtime Safety

① Εξήγηση για Αρχάριο — Από το Μηδέν

Τι πρόβλημα λύνει;

ΑΥΤΟ είναι το δυνατότερο contribution. Κάθε εντολή κίνησης — από οποιονδήποτε planner, A*, PPO, τυχαίο — περνάει από μαθηματικό φίλτρο που ΕΓΓΥΑΤΑΙ: το ρομπότ δεν θα πλησιάσει εμπόδιο πάνω από επιτρεπτό όριο. Ποτέ. Με απόδειξη.

Γιατί υπάρχει αυτό το πρόβλημα;

Νευρωνικά δίκτυα και RL agents μπορεί να βγάλουν επικίνδυνη εντολή. «99.9% ασφαλές» σημαίνει 0.1% failure — απαράδεκτο κοντά σε ανθρώπους. Χρειάζεται ΔΕΥΤΕΡΟ, ΑΝΕΞΑΡΤΗΤΟ σύστημα που ελέγχει κάθε εντολή.

Γιατί είναι δύσκολο;

CBF conditions derived για continuous-time. Discrete-time implementation εισάγει approximation. Multiple obstacles: conflicting constraints. STL monitoring: temporal operators απαιτούν ιστορικό trajectory.

② Αναλογία & Διαίσθηση

Πυρηνικός σταθμός: control software + ανεξάρτητο safety system που shutdown ανεξάρτητα. Καπνοί ανίχνευσης (STL monitor) + αυτόματο sprinkler (CBF filter). Ζώνη ασφαλείας αυτοκινήτου: δεν χρειάζεται να ξέρει που πηγαίνεις — σε κρατάει ασφαλή ό,τι κι αν κάνεις.

③ Τι Έκανα Ακριβώς — Βήμα-Βήμα

- STL composable formulas: atoms, $\Box[a,b]$ (always), $\Diamond[a,b]$ (eventually), $\wedge$, $\vee$
- STL robustness ρ : positive = satisfied, negative = violated, magnitude = margin
- STL monitor: accumulates trajectory, evaluates ρ , logs violations
- $h_{\text{stoch}}(\mu, \Sigma) = \|\mu - x_{\text{obs}}\| - r_{\text{safe}} - \beta \cdot \sqrt{(v^T \Sigma v)}$ (uncertainty-aware barrier)
- CBF condition: $\nabla h \cdot u + \alpha(\rho) \cdot h \geq 0 \rightarrow$ forward invariance
- Exact QP: $u^* = \text{argmin} \|u - u_{\text{des}}\|^2 \text{ s.t. CBF}$ — KKT closed-form
- Adaptive gain: $\alpha(\rho)$ αυξάνει όταν $\rho \rightarrow 0$ (preemptive enforcement)
- SafetyShield: wraps ANY planner — planner-agnostic interface
- ΑΠΟΤΕΛΕΣΜΑΤΑ: 93% μείωση παραβιάσεων, <8% path overhead, P99 QP: 160μs

Ροή Δεδομένων

Desired command $u_{\text{des}} \rightarrow$ CBF exact QP $\rightarrow u_{\text{safe}}$ | State trajectory $\rightarrow$ STL robustness $\rho \rightarrow$ violation log + adaptive α

④ Βαθιά Τεχνική Ανάλυση

Βασικά Components

- STL atom: $\rho(\mu, x, t) = \text{predicate_function}(x[t])$
- STL $\Box[a,b]$: $\rho = \min_{t' \in [t+a, t+b]} \rho(\phi, x, t')$
- h_{stoch} : uncertainty-aware barrier με Gaussian tail bound proof
- Discrete-time CBF: $\forall h \cdot u \geq -\alpha_d \cdot h, \alpha_d = (1 - e^{-\alpha \cdot dt})/dt < \alpha$
- Exact QP (KKT): $u^* = u_{\text{des}} + A^T \lambda^*, \lambda^* = (AA^T)^{-1} (b - Au_{\text{des}})$
- Adaptive gain: $\alpha(\rho) = \alpha_{\text{base}} + (\alpha_{\text{max}} - \alpha_{\text{base}}) \cdot \max(0, 1 - \rho/\rho_{\text{thresh}})$

Pseudocode / Αλγόριθμος

```
STL ROBUSTNESS:
rho_always(phi, x, t, a, b) = min(rho(phi, x, t') για t' σε [t+a, t+b])
rho_eventually(phi, x, t, a, b) = max(rho(phi, x, t') για t' σε [t+a, t+b])

EXACT KKT QP (single obstacle):
αν  $\nabla h \cdot u_{\text{des}} + \alpha \cdot h \geq 0$ : return  $u_{\text{des}}$  // safe already
 $\lambda^* = (b - \nabla h \cdot u_{\text{des}}) / \|\nabla h\|^2$  // exact Lagrange multiplier
 $u^* = u_{\text{des}} + \lambda^* \cdot \nabla h$  // exact min-norm solution

SAFETY SHIELD STEP:
rho = stl_monitor.update(state)
alpha = adaptive_alpha(rho)
u_safe, info = exact_cbf.filter(u_desired, belief, obstacles, alpha)
return u_safe
```

Μαθηματική Φορμοποίησηση

```
STL always:  $\rho(\Box[a,b]\phi, x, t) = \min_{t' \in [t+a, t+b]} \rho(\phi, x, t')$ 
 $h_{\text{stoch}}: h = \|\mu - x_{\text{obs}}\| - r_{\text{safe}} - \beta \sqrt{v^T \Sigma v}, \beta = \Phi^{-1}(p_{\text{safe}})$ 
Prob. guarantee:  $\forall h_{\text{stoch}} \geq 0 \rightarrow P(\|x - x_{\text{obs}}\| \geq r_{\text{safe}}) \geq p_{\text{safe}}$ 
Discrete-time CBF:  $\forall h \cdot u \geq -\alpha_d \cdot h, \alpha_d = (1 - e^{-\alpha \cdot dt})/dt$ 
Exact QP:  $u^* = u_{\text{des}} + A^T \lambda^*, \lambda^* = (AA^T)^{-1} (b - Au_{\text{des}})$ 
Adaptive:  $\alpha(\rho) = \alpha_{\text{base}} + (\alpha_{\text{max}} - \alpha_{\text{base}}) \cdot \max(0, 1 - \rho/\rho_{\text{thresh}})$ 
```

Πολυπλοκότητα & Παραδοχές

Χρονική πολυπλοκότητα: STL: $O(T \cdot |\text{formula}|)$ για T history. CBF QP: $O(M^2)$ για M obstacles. Και τα δύο real-time.

- Obstacles static during CBF computation interval
- EKF estimation error $e \sim N(0, \Sigma)$ (Gaussian assumption)
- Discrete-time CBF: dt αρκετά μικρό
- u_{max} δεν actively constraining CBF

⑤ Ερευνητική Αξία

Ερευνητικό Ερώτημα

Μπορεί composable STL-CBF runtime shield να μειώσει violations $\geq 80\%$ με $\leq 10\%$ efficiency overhead, για ANY upstream planner, υπό Gaussian localization uncertainty;

Novelty — Τι Καινούργιο Κάνω

Runtime shield (not offline synthesis) για ANY planner. h_{stoch} uncertainty-aware barrier με EKF belief states. Exact KKT QP (not gradient projection). Adaptive STL gain scheduling. Experimental validation 360 episodes.

Σχετική Βιβλιογραφία

Ames et al. (2019) CBF theory. Donzé & Maler (2010) STL robustness. Raman et al. (2015) MPC+STL. Agrawal & Sreenath (2017) discrete-time CBF. Ruo et al. (2024) STL+CBF offline.

⑥ Αποτελέσματα & Τι Σημαίνουν

☆ 93% violation reduction. <8% path overhead. QP P99: 160μs για 20 obstacles. Sensor dropout: 0 violations vs 5.77 No Shield. CIC vs Stoch: 0.0 vs 0.0125 correction (Stoch. CBF Pareto-optimal).

Metrics

- STL violations per episode
- Mean CBF correction (m/s)
- Path length overhead %
- QP solve time (μs): mean, P99
- Sensor dropout violations
- Min. clearance (m)

Τι Λείπει Ακόμα

Full forward invariance theorem (Theorem 1) pending. Extreme dropout scenario ($\sigma > 0.25\mu$) για empirical separation det vs stoch CBF. Planner-agnostic ablation (3 planner qualities). Hardware validation (30 episodes TurtleBot3).

⑦ Αυστηρή Κριτική — Reviewer Mode

Αδυναμίες

- Proof shows POINTWISE safety — full forward invariance θεώρημα pending
- Stoch. CBF $\approx$ Det. CBF empirically στα current scenarios — χρειάζεται extreme dropout
- Discrete-time approximation: $dt=0.1s$ σφάλμα δεν formally bounded
- Multiple obstacle CBF: may be overly conservative

Κρυφές Παραδοχές

- Obstacles static during CBF interval
- EKF $e \sim N(0, \Sigma)$ — consistency assumption
- α_d appropriate για current control frequency

Σενάρια Αποτυχίας

- Very fast dynamics: CBF δεν προλαβαίνει
- Multiple simultaneous obstacles: conflicting CBF constraints
- Narrow passages: CBF safe set empty

⑧ Πώς Γίνεται Δημοσίευση

Τίτλος Paper	☆ UncertaintyShield: Composable STL-CBF Runtime Safety for Learning-Augmented Navigation
Venue	☆ ICRA 2026 / IEEE RA-L — PUBLISHABLE ΣΧΕΔΟΝ ΤΩΡΑ

Missing Experiments

- Extreme dropout ($\sigma > 0.25\mu$, 8s): empirically separate stoch vs det CBF
- 3-planner ablation ($k_{rep}=2.0$, $k_{rep}=0.2$, random walk): verify planner-agnostic claim
- 30 hardware TurtleBot3 episodes
- Theorem 1: full forward invariance proof

Ablations που Χρειάζονται

- CBF gradient projection vs exact QP — πόσο σημαντικό;
- STL monitoring alone vs CBF alone vs combined
- α sensitivity: safety-efficiency tradeoff
- Extreme dropout: det CBF vs stoch CBF separation

9 Ανοιχτά Ερευνητικά Ερωτήματα

- Μπορεί α να auto-tuned να balances safety και efficiency;
- Μπορεί STL specs να synthesized από natural language safety requirements;
- Μπορεί CBF να extended σε stochastic dynamics με probabilistic guarantees;

10 Αν Είχα 2 Λεπτά να το Εξηγήσω σε Οποιονδήποτε...

ΑΥΤΟ είναι το δυνατότερο contribution. Κάθε εντολή κίνησης — ανεξάρτητα από ποιον planner — περνάει από μαθηματικό φίλτρο. Το φίλτρο ελέγχει: «θα κρατήσει αυτή η εντολή ασφαλή απόσταση από εμπόδια;» Αν ΟΧΙ, βρίσκει την ΕΛΑΧΙΣΤΗ τροποποίηση που το κάνει ασφαλή — με αποδεδειγμένη μαθηματική εγγύηση. Υπολογίζεται σε 160 microseconds. Μείωσε παραβιάσεις κατά 93% με <8% overhead. Publishable τώρα.

Βαθμολογία

Διάσταση	Βαθμός	Σχόλιο
Πρωτοτυπία	9/10	Γνήσια καινοτόμο
Τεχνικό Βάθος	9/10	Πλήρης μαθ. ανάλυση
Δημοσιευσιμότητα	9/10	Έτοιμο σχεδόν τώρα
PhD Δυναμικό	9/10	Ισχυρό κεφάλαιο διδακτορικού

Contribution 19 LLM Mission Planner — Φυσική Γλώσσα

Κατηγορία: NLP / Robot Interface

① Εξήγηση για Αρχάριο — Από το Μηδέν

Τι πρόβλημα λύνει;

Λες «πήγαινε στην κουζίνα, μετά τον διάδρομο, γύρνα στη βάση» — ο LLM μετατρέπει αυτό σε structured list waypoints. Αν ο LLM δεν είναι διαθέσιμος, keyword scanning εξαγει τα room names απευθείας.

Γιατί υπάρχει αυτό το πρόβλημα;

Μη-ειδικοί δεν δίνουν συντεταγμένες. Natural language interface κάνει τον ρομπότ accessible σε όλους χωρίς technical training.

Γιατί είναι δύσκολο;

LLMs αργοί (0.5–5s), unstructured by default, μπορεί να hallucinate room names. Confidence calibration δεν guaranteed. Keyword fallback είναι brittle (order-of-appearance heuristic αποτυγχάνει για «first B then A»).

② Αναλογία & Διαίσθηση

*Google Assistant: «set alarm 7am and remind medicine» → δύο structured API calls.
Γραμματέας: μετατρέπει φυσική γλώσσα σε structured calendar entries. LLM Mission Planner: ακριβώς το ίδιο για robot navigation missions.*

③ Τι Έκανα Ακριβώς — Βήμα-Βήμα

- HTTP client σε Ollama/OpenAI
- Structured prompt → JSON: {confidence, waypoints[{label,priority,action}]}
- JSON parser: strips markdown fences, validates
- Confidence gating: αν $c < \tau_c \rightarrow$ keyword fallback
- Keyword scan: zone names in text, sort by position in string
- Levenshtein fuzzy match για near-match labels
- Metric resolution: zone_name → (x,y) lookup
- 6 tests passing

Ροή Δεδομένων

Natural language → LLM API (or keyword fallback) → JSON parse → Mission (ordered Waypoints) → metric coords → planner

④ Βαθιά Τεχνική Ανάλυση

Βασικά Components

- LLM client: HTTP POST σε Ollama/OpenAI endpoint
- JSON parser: robust σε format variations

- Keyword extractor: zone name scanning + position sorting
- Levenshtein matcher: fuzzy label resolution
- Metric resolver: zone_name $\rightarrow$ (x,y) dict lookup

Pseudocode / Αλγόριθμος

```
LLM QUERY:
payload = {model: name, messages: [system_prompt, user_instruction]}
response = http_post(endpoint, payload, timeout=10)
goal = parse_json(response.message.content)
αν goal is None ή goal.confidence < tau_c:
    return keyword_fallback(instruction)

KEYWORD FALLBACK:
found = []
για zone σε known_zones:
    αν zone σε instruction.lower():
        found.append((instruction.find(zone), zone))
found.sort() // by position  $\rightarrow$  priority order
return Mission([Waypoint(zone, priority=i) για i, (_, zone) σε enumerate(found)])
```

Μαθηματική Φορμοποίηση

```
LLM:  $P(W|x) = \prod_k p(w_k|w_{1:k-1}, x)$  – autoregressive generation
JSON schema: {confidence: [0,1], waypoints: [{label:str, priority:int}]}
Fallback: sort by string position index – heuristic priority order
Levenshtein:  $d(a,b) = \text{edit distance} = O(|a| \cdot |b|)$ 
```

Πολυπλοκότητα & Παραδοχές

Χρονική πολυπλοκότητα: LLM: $O(|\text{instruction}| \cdot |\text{model}|)$ dominated by API call (100ms–5s).
 Keyword: $O(N_{\text{zones}} \cdot |\text{text}|)$.

- LLM correct world knowledge για zone names
- Confidence c calibrated
- zone_map covers all deployment zones
- LLM API accessible (offline: keyword fallback only)

⑤ Ερευνητική Αξία

Ερευνητικό Ερώτημα

Μπορεί structured-output LLM interface να reliable parse natural language missions σε ordered waypoints με confidence calibration sufficient να drive navigation;

Novelty — Τι Καινούργιο Κάνω

Keyword fallback (offline capability) είναι practical engineering contribution. Integration με confidence-gated VLM (C11) και topological map (C17) = complete language-to-navigation pipeline.

Σχετική Βιβλιογραφία

SayCan (Ahn 2022). Code-as-Policies (Liang 2023). Inner Monologue (Huang 2022). ProgPrompt (Singh 2023).

⑥ Αποτελέσματα & Τι Σημαίνουν

Offline keyword fallback validated. JSON parsing handles format variations. Levenshtein catches misspellings. ⚠ Live LLM accuracy δεν measured σε navigation.

Metrics

- Mission parse accuracy
- Zone identification accuracy
- API latency distribution
- Fallback rate

Τι Λείπει Ακόμα

Δεν υπάρχει live LLM evaluation. Δεν υπάρχει σύγκριση με Code-as-Policies. Confidence calibration δεν analyzed.

⑦ Αυστηρή Κριτική — Reviewer Mode

Αδυναμίες

- LLM confidence not guaranteed calibrated
- Keyword fallback brittle: position heuristic fails για «first B then A»
- LLM hallucination: room names not in map
- Χωρίς temporal language: «πήγαινε σε A στις 3 μ.μ.»

Κρυφές Παραδοχές

- LLM correct knowledge of deployment environment
- $c \geq \tau_c$ implies correct parse
- zone_map complete

Σενάρια Αποτυχίας

- Ambiguous: «δωμάτιο στα αριστερά» — ποιο;
- Sequential dependencies: «πάρε πακέτο από A, παράδωσε σε B»
- Unknown zones

⑧ Πώς Γίνεται Δημοσίευση

Τίτλος Paper	Natural Language Mission Planning: Structured LLM Parsing με Confidence-Gated Fallback
Venue	ICRA NLP4Robots Workshop / HRI

Missing Experiments

- 100 natural language instructions → parse accuracy measurement
- Σύγκριση με Code-as-Policies
- Confidence calibration analysis
- Temporal instruction extension

Ablations που Χρειάζονται

- JSON-structured vs free-text prompting
- τ_c sensitivity
- LLM vs keyword fallback offline
- Με vs χωρίς fuzzy matching

9 Ανοιχτά Ερευνητικά Ερωτήματα

- 55. Μπορεί LLM να fine-tuned σε deployment-specific vocabulary;
- 56. Πώς να handled ambiguous instructions — clarifying questions;
- 57. Μπορεί LLM να generates executable planning code;

10 Αν Είχα 2 Λεπτά να το Εξηγήσω σε Οποιονδήποτε...

Λες στον ρομπότ «πήγαινε στην κουζίνα, μετά τον αποθηκευτικό χώρο, γύρνα στη βάση» — ακριβώς σαν να μιλάς σε άνθρωπο. Το interface στέλνει αυτή την εντολή σε LLM που επιστρέφει *structured list waypoints*. Αν ο LLM δεν είναι διαθέσιμος ή δεν είναι σίγουρος, *keyword scanning* εξάγει τα *room names* απευθείας από το κείμενο. Χαμηλό *confidence* → *fallback* αντί για *blind execution*.

Βαθμολογία

Διάσταση	Βαθμός	Σχόλιο
Πρωτοτυπία	6/10	<i>Incremental</i>
Τεχνικό Βάθος	6/10	<i>Prototype επίπεδο</i>
Δημοσιευσιμότητα	5/10	<i>Concept μόνο</i>
PhD Δυναμικό	6/10	<i>Υποστηρικτικό υλικό</i>

Contribution 20 Multimodal Failure Explainer — Αυτόματη Διάγνωση

Κατηγορία: XAI / Diagnostics

① Εξήγηση για Αρχάριο — Από το Μηδέν

Τι πρόβλημα λύνει;

Μετά από οποιαδήποτε αποτυχία, το σύστημα παράγει αυτόματα αναφορά: τι έγινε, γιατί, ποιοι κανόνες παραβιάστηκαν, τι να διορθωθεί. Πολυτροπικό: χρησιμοποιεί VLM για visual context, SCM για αιτιότητα, STL για temporal violations.

Γιατί υπάρχει αυτό το πρόβλημα;

Χειροκίνητη ανάλυση logs αποτυχίας ρομπότ παίρνει ώρες. Αυτόματη διάγνωση: seconds. Επιταχύνει feedback loop, επιτρέπει systematic failure database.

Γιατί είναι δύσκολο;

Fusion πολλαπλών evidence sources (visual, causal, temporal) σε coherent narrative απαιτεί careful integration. Report quality εξαρτάται από quality των underlying modules.

② Αναλογία & Διαισθηση

Ερευνητές αεροπορικών ατυχημάτων: βίντεο + flight data + ATC transcripts → incident report σε ώρες. Χειρουργικό ρομπότ: μετά απρόσμενο outcome, ομάδα review video + sensor data + procedure logs. Αυτό το module αυτοματοποιεί αυτή τη διαδικασία.

③ Τι Έκανα Ακριβώς — Βήμα-Βήμα

- FailureEvent dataclass: type, timestamp, position, velocity, RGB frame, trajectory, STL trace
- FailureReport dataclass: scene description, causal attribution, STL violations, actions
- VLM scene description (C11): RGB → text
- Causal attribution (C14): SCM root_cause_ranking() → top causes
- STL violations: {(spec, ρ) : $\rho < 0$ } από STL trace
- Corrective action dictionary: type-indexed recommendations
- Markdown + JSON output
- 4 tests passing

Ροή Δεδομένων

FailureEvent → [VLM scene | SCM causes | STL violations] → assemble FailureReport → Markdown/JSON

④ Βαθιά Τεχνική Ανάλυση

Βασικά Components

- Scene describer: VLM αν available, rule-based fallback

- Causal attributer: SCM από C14
- STL summarizer: negative p values από C18 monitor
- Action recommender: curated dictionary by failure type
- Report exporter: Markdown και JSON formats

Pseudocode / Αλγόριθμος

```
EXPLAIN(event: FailureEvent) -> FailureReport:

// Step 1: Visual scene description
αν event.frame και vlm_available:
    scene = vlm.describe(event.frame)
αλλιώς:
    scene = rule_based(event.position, event.velocity)

// Step 2: Causal attribution
causes = scm.root_cause_ranking(event.sensor_readings, n_samples=50)

// Step 3: STL violations
violations = [(s, r) για s, r σε event.stl_trace.items() αν r < 0]

// Step 4: Corrective actions
actions = ACTION_DICT[event.failure_type]

return FailureReport(scene, causes[:4], violations, actions)
```

Μαθηματική Φορμοποίηση

```
Scene: VLM(I_f) → text ή rule_based(s_f, ṡ_f, z_f) → text
Causes: φ_i από C14 root_cause_ranking
Violations: V = {(φ_i, ρ_i) : ρ_i(x,t) < 0} (από C18 STL monitor)
Confidence: 0.4 + 0.1·1[causal] + 0.1·1[vlm_available]
```

Πολυπλοκότητα & Παραδοχές

Χρονική πολυπλοκότητα: $O(N_{scm} \cdot |graph|)$ για causal + $O(|STL_specs|)$ για violations.

- VLM scene description informative
- SCM correct causal relationships (inherited from C14)
- STL trace recorded during episode (C18 active)
- Corrective action dictionary complete

⑤ Ερευνητική Αξία

Ερευνητικό Ερώτημα

Μπορεί automated fusion visual, causal, temporal-logic evidence να παράγει navigation failure reports που engineers αξιολογούν ως more diagnostic vs raw log analysis;

Novelty — Τι Καινούργιο Κάνω

VLM scene description + SCM causal attribution + STL monitoring σε unified failure diagnosis pipeline. Καθένα individually γνωστό — η systematic integration για navigation diagnostics είναι novelty.

Σχετική Βιβλιογραφία

Richens et al. (2020) counterfactual diagnosis. Arrieta et al. (2020) XAI survey.

⑥ Αποτελέσματα & Τι Σημαίνουν

Reports generated correctly για COLLISION, TIMEOUT, SENSOR_FAULT. ⚠ Δεν υπάρχει human evaluation — άγνωστο αν είναι χρήσιμα.

Metrics

- Human evaluation: usefulness rating vs raw logs
- Causal attribution accuracy
- Report generation latency
- Quality vs available evidence

Τι Λείπει Ακόμα

Δεν υπάρχει human evaluation. Action dictionary manually curated. VLM depends on live API.

⑦ Αυστηρή Κριτική — Reviewer Mode

Αδυναμίες

- Χωρίς human evaluation: άγνωστο αν reports είναι χρήσιμα
- Corrective actions static — δεν learned
- Causal attribution quality inherited από C14 limitations
- Report confidence heuristic δεν calibrated

Κρυφές Παραδοχές

- VLM accurate scene description
- STL trace recorded during episode
- Action dictionary complete

Σενάρια Αποτυχίας

- Novel failure types δεν σε dictionary
- Poor VLM description (bad lighting)
- Multiple simultaneous causes
- Episode χωρίς RGB frame

⑧ Πώς Γίνεται Δημοσίευση

Τίτλος Paper	Multimodal Navigation Failure Diagnosis: VLM + Causal + STL Evidence Fusion
Venue	ICRA XAI Workshop / HRI / RA-L

Missing Experiments

- Human evaluation: automated vs manual log analysis
- Ground-truth causal study: inject known failures

- Learn corrective actions από past repairs
- LLM-only vs full multimodal pipeline

Ablations που Χρειάζονται

- Με vs χωρίς causal attribution
- Με vs χωρίς VLM scene
- Full report vs STL violations only vs causal only
- Rule-based vs LLM fallback

9 Άνοιχτά Ερευνητικά Ερωτήματα

- 58. Μπορεί action dictionary να learned από past failures;
- 59. Μπορεί report να interactive: «τι θα γινόταν αν X ήταν διαφορετικό;»
- 60. Μπορούν failure reports να shared across fleet για institutional knowledge;

10 Αν Είχα 2 Λεπτά να το Εξηγήσω σε Οποιονδήποτε...

Όταν ρομπότ αποτυγχάνει, η διάγνωση κοστίζει ώρες. Αυτό το module αυτοματοποιεί: δίνει το failure event και παίρνεις σε seconds structured αναφορά που περιέχει (1) visual description της σκηνής, (2) causally πιο υπεύθυνη μεταβλητή (από C14), (3) ποιοι STL κανόνες παραβιάστηκαν (από C18), (4) συγκεκριμένες προτάσεις διόρθωσης. Markdown output — άμεσα readable.

Βαθμολογία

Διάσταση	Βαθμός	Σχόλιο
Πρωτοτυπία	7/10	Incremental
Τεχνικό Βάθος	7/10	Prototype επίπεδο
Δημοσιευσιμότητα	6/10	Χρειάζεται experiments
PhD Δυναμικό	7/10	Υποστηρικτικό υλικό

Contribution 21 PPO Navigation Agent — Reinforcement Learning

Κατηγορία: RL / Learning

① Εξήγηση για Αρχάριο — Από το Μηδέν

Τι πρόβλημα λύνει;

Το ρομπότ μαθαίνει να πλοηγείται από δοκιμή και λάθος — σαν σκύλος που μαθαίνει να φέρνει μπάλα με επαίνους. PPO (Proximal Policy Optimization) είναι ο αλγόριθμος. Risk-shaped reward: ποινή για εγγύτητα σε εμπόδια.

Γιατί υπάρχει αυτό το πρόβλημα;

Κλασικοί planners χρειάζονται explicit map και rules. RL: μαθαίνει policy από εμπειρία σε complex dynamic environments. Risk-shaped reward συνδέει το DynNav risk framework με RL training signal.

Γιατί είναι δύσκολο;

PPO χρειάζεται backpropagation μέσω actor-critic networks. Numpy stubs ΔΕΝ υποστηρίζουν backpropagation. Η policy ΔΕΝ εκπαιδεύεται ποτέ — αυτό είναι FRAMEWORK, όχι trained agent.

② Αναλογία & Διαίσθηση

Σκύλος που μαθαίνει fetch: reward όταν φέρει μπάλα, τίποτα αν αποτύχει. Μετά χιλιάδες επεισόδια μαθαίνει. PPO είναι η μαθηματική φόρμουλα για να γίνει αυτό stable και efficient. Ο σκύλος εδώ δεν έχει ακόμα τρέξει — έχουμε μόνο την εκπαιδευτική εγκατάσταση.

③ Τι Έκανα Ακριβώς — Βήμα-Βήμα

- Risk-shaped reward: $r = -0.01 + 0.1/d_{\text{goal}} - 0.5 \cdot \max(0, d_{\text{safe}} - d_{\text{obs}}) - 5 \cdot 1[\text{col}] + 10 \cdot 1[\text{goal}]$
- Actor network: MLP $\rightarrow$ (action_mean, action_std) — Gaussian policy
- Critic network: MLP $\rightarrow V(s)$ — state value function
- Rollout buffer: T steps, stores (s, a, log_π, r, V, done)
- GAE: $\hat{A}_t = \sum_{l \geq 0} (\gamma \lambda)^l \delta_{t+l}$, $\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$
- PPO clip: $L = E[\min(r_t \cdot \hat{A}_t, \text{clip}(r_t, 1 \pm \epsilon) \cdot \hat{A}_t)]$
- ⚠ ΚΡΙΣΙΜΟ: numpy stubs = δεν γίνεται backpropagation $\rightarrow$ policy NEVER updates
- NavEnv: custom grid world, 14-dim observation, risk-shaped rewards

Ροή Δεδομένων

NavEnv $\rightarrow$ rollout collection (T steps) $\rightarrow$ GAE advantages $\rightarrow$ PPO clip update (⚠ stub) $\rightarrow$ same policy

④ Βαθιά Τεχνική Ανάλυση

Βασικά Components

- NavEnv: grid environment, risk-shaped reward, obstacles
- ActorNetwork: MLP $\rightarrow$ action distribution (tanh mean, log std)
- CriticNetwork: MLP $\rightarrow$ scalar value $V(s)$
- RolloutBuffer: stores T steps, computes GAE
- PPO updater: clipped objective Δ STUB — δεν κάνει gradient

Pseudocode / Αλγόριθμος

```

ROLLOUT COLLECTION:
obs = env.reset()
για t σε range(T):
    a, log_pi, V = actor_critic(obs)
    obs_next, r, done, _ = env.step(a)
    buffer.add(obs, a, log_pi, r, V, done)
    obs = obs_next αν not done αλλιώς env.reset()
adv, returns = buffer.compute_gae(last_V)

PPO UPDATE (K epochs) —  $\Delta$  STUB:
για minibatch σε buffer:
    ratio = exp(new_log_pi - old_log_pi)
    L = min(ratio*Adv, clip(ratio, 1-ε, 1+ε)*Adv)
    [BACKPROP]  $\leftarrow$  ΔΕΝ ΥΛΟΠΟΙΕΙΤΑΙ (numpy stubs)

```

Μαθηματική Φορμοποίηση

```

GAE:  $\hat{A}_t = \sum_{l \geq 0} (\gamma \lambda)^l \delta_{t+l}$ ,  $\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$ 
PPO clip:  $L^{\text{CLIP}}(\theta) = E[\min(r_t \cdot \hat{A}_t, \text{clip}(r_t, 1-\epsilon, 1+\epsilon) \cdot \hat{A}_t)]$ 
Ratio:  $r_t(\theta) = \pi_\theta(a_t|s_t) / \pi_{\theta_{\text{old}}}(a_t|s_t)$ 
Risk reward:  $r(s, a) = -0.01 + 0.1/d_{\text{goal}} - 0.5 \cdot \max(0, d_{\text{safe}} - d_{\text{obs}}) - 5 \cdot \text{col} + 10 \cdot \text{goal}$ 
Total:  $L = -L^{\text{CLIP}} + c_v \cdot L^V - c_e \cdot H[\pi_\theta]$ 

```

Πολυπλοκότητα & Παραδοχές

Χρονική πολυπλοκότητα: Rollout: $O(T \cdot |\text{env}|)$. GAE: $O(T)$. PPO update: $O(K \cdot T / \text{batch} \cdot |\text{networks}|)$. Fast με stubs.

- Δ Actor/Critic trainable via backprop — NUMPY STUBS ΔΕΝ ΥΠΟΣΤΗΡΙΖΟΥΝ ΑΥΤΟ
- Risk-shaped reward sufficient για safe navigation learning
- NavEnv representative of real navigation
- PPO hyperparameters appropriately tuned

⑤ Ερευνητική Αξία

Ερευνητικό Ερώτημα

Μειώνει risk-shaped reward (CVaR-inspired) ασφαλέστερες policies vs standard goal-reaching, σε diverse unknown environments;

Novelty — Τι Καινούργιο Κάνω

Risk-shaped reward που συνδέει DynNav CVaR metrics με RL signal. Integration με CBF (C18) ως training wrapper και curriculum (C22) = novel systems combination.

Σχετική Βιβλιογραφία

Schulman et al. (2017) PPO. Mirowski et al. (2017) navigation με RL. Henderson et al. (2018) deep RL reproduced.

⑥ Αποτελέσματα & Τι Σημαίνουν

Training loop εκτελείται. GAE υπολογίζεται. ⚠ Policy ΔΕΝ βελτιώνεται — framework only, not trained agent.

Metrics

- Mean episode reward
- Episode length
- Value loss over updates
- Collision rate during training

Τι Λείπει Ακόμα

Policy δεν εκπαιδεύτηκε. Δεν υπάρχει σύγκριση με A* baseline. Δεν υπάρχει curriculum integration evaluation.

⑦ Αυστηρή Κριτική — Reviewer Mode

Αδυναμίες

- ⚠ Numpy stubs: KAMIA gradient → policy ΠΟΤΕ δεν βελτιώνεται
- Παρουσίαση ως «RL agent» χωρίς εκπαίδευση = misleading
- NavEnv δεν validated vs real TurtleBot3 dynamics
- Δεν υπάρχει σύγκριση με standard reward

Κρυφές Παραδοχές

- Backpropagation implementable με numpy (FALSE)
- NavEnv representative (δεν validated)
- Risk reward parameters correctly tuned

Σενάρια Αποτυχίας

- ⚠ Training loop = framework demonstration μόνο
- Risk penalty too high: robot αρνείται να κινηθεί
- GAE γ και λ δεν tuned για navigation episodes

⑧ Πώς Γίνεται Δημοσίευση

Τίτλος Paper	Risk-Shaped PPO for Safe Autonomous Navigation — After PyTorch Implementation
Venue	ICRA / CoRL / RA-L — χρειάζεται PyTorch rewrite πρώτα

Missing Experiments

- Rewrite σε PyTorch: proper backpropagation
- Train 1M+ timesteps σε NavEnv

- Risk-shaped vs standard reward σε same environment
- CBF (C18) ως training wrapper: improves final safety;

Ablations που Χρειάζονται

- Risk reward vs goal-only vs shaped + penalty
- GAE λ sensitivity
- PPO clip ε: conservative vs aggressive updates
- Με vs χωρίς curriculum (C22)

9 Άνοιχτά Ερευνητικά Ερωτήματα

61. Μπορεί risk-shaped reward να derived automatically από CVaR A* cost;
62. Μπορεί CBF (C18) να χρησιμοποιηθεί ως hard constraint κατά training (safe RL);
63. Μπορεί meta-RL (MAML) να adapts σε νέα environments σε K steps;

10 Αν Είχα 2 Λεπτά να το Εξηγήσω σε Οποιονδήποτε...

Αντί για explicit rules, το ρομπότ μαθαίνει από trial-and-error. Δοκιμάζει κινήσεις, λαμβάνει rewards (φτάνω στόχο) και penalties (πλησιάζω εμπόδιο). Ο PPO αλγόριθμος κάνει αυτή τη μάθηση stable. Το risk-shaped reward συνδέει το DynNav risk framework με την εκπαίδευση. Κρίσιμη επιφύλαξη: τα numpy stubs δεν κάνουν backpropagation — η policy δεν μαθαίνει ποτέ. Αυτό είναι σωστό framework που περιμένει PyTorch implementation.

Βαθμολογία

Διάσταση	Βαθμός	Σχόλιο
Πρωτοτυπία	6/10	Incremental
Τεχνικό Βάθος	7/10	Prototype επίπεδο
Δημοσιευσιμότητα	5/10	Concept μόνο
PhD Δυναμικό	7/10	Υποστηρικτικό υλικό

Contribution 22 Curriculum RL — Σταδιακή Εκπαίδευση

Κατηγορία: RL / Training Methodology

① Εξήγηση για Αρχάριο — Από το Μηδέν

Τι πρόβλημα λύνει;

5 επίπεδα δυσκολίας για εκπαίδευση RL: από εύκολο (2 εμπόδια, μικρός χάρτης, κοντινός στόχος) ως extreme (25 εμπόδια, 20×20μ, sensor noise). Το ρομπότ προχωράει επίπεδο μόνο όταν πετυχαίνει αξιόπιστα.

Γιατί υπάρχει αυτό το πρόβλημα;

Χωρίς curriculum, ο RL agent ξεκινά σε complex environment, σπάνια πετυχαίνει, παίρνει mainly negative rewards, και δεν μαθαίνει τίποτα. Curriculum: πάντα training σε productive difficulty level.

Γιατί είναι δύσκολο;

Ορισμός σωστής difficulty progression και advancement criteria απαιτεί domain knowledge. 5 stages × 5 dimensions = 25 hyperparameters. Curriculum logic ορθό αλλά connected σε PPO stub = δεν λειτουργεί πλήρως.

② Αναλογία & Διαίσθηση

Σχολείο: ξεκινάς από απλή αριθμητική, όχι calculus. Βουτιά στη θάλασσα: αρχίζεις στα ρηχά, προχωράς όταν είσαι έτοιμος. Video game difficulty: εύκολος, normal, hard, expert — adapts στον παίκτη.

③ Τι Έκανα Ακριβώς — Βήμα-Βήμα

- 5 DifficultyLevel: easy (2 obs, 5×5μ, static, $\sigma=0.01$) → extreme (25 obs, 20×20μ, 0.5μ/s, $\sigma=0.2$)
- 5 dimensions ανά stage: N_obstacles, map_size, obs_speed, sensor_noise, goal_dist
- Rolling success rate: $SR_W = \text{mean}(\text{success}[-W:])$
- Advance αν $SR_W \geq \tau_{\text{stage}}$ ΚΑΙ stage < 4
- 3 strategies: ADAPTIVE, FIXED (every N episodes), REVERSE (start near goal)
- CurriculumNavEnv: wraps NavEnv, injects difficulty parameters
- Stage history logged με transition episodes
- 5 tests passing

Ροή Δεδομένων

Current difficulty → CurriculumNavEnv params → episode → success/fail → SR_W update → advance αν $SR_W \geq \tau$ → next stage

④ Βαθιά Τεχνική Ανάλυση

Βασικά Components

- Difficulty ladder: 5 DifficultyLevel με parameter specs

- CurriculumScheduler: tracks SR_W, decides advancement
- CurriculumNavEnv: applies difficulty σε NavEnv via parameter injection
- Stage logger: records transitions με episode numbers και SR

Pseudocode / Αλγόριθμος

```
CURRICULUM SCHEDULER:
    outcomes = deque(maxlen=W)
    stage = 0

    def record_episode(success):
        outcomes.append(success)
        SR = mean(outcomes)
        αν SR >= τ_stage[stage] και stage < 4:
            stage += 1
            outcomes.clear() // reset για νέο stage
            log_transition(stage-1, stage, SR)

CURRICULUM NAV ENV:
    def reset():
        d = scheduler.current_difficulty()
        set N_obstacles = d.n_obs
        set map_size = d.map_size
        // ... other params
        return initialize_episode()
```

Μαθηματική Φορμοποίηση

```
SR_W(t) = (1/W) Σ_{i=t-W+1}^{t} 1[success_i]
Advance: SR_W(t) ≥ τ_d ΚΑΙ stage_t < 4
Hysteresis: outcomes.clear() on advance → prevents immediate re-advance
Reverse curriculum: start_range(t) expands καθώς SR_W βελτιώνεται
```

Πολυπλοκότητα & Παραδοχές

Χρονική πολυπλοκότητα: O(1) ανά episode για SR update. Negligible overhead.

- 5 stages καλύπτουν full difficulty range
- τ_stage thresholds appropriate ανά stage
- W window size sufficient για stable SR estimate
- RL backend functional  PPO stub

⑤ Ερευνητική Αξία

Ερευνητικό Ερώτημα

Μειώνει adaptive curriculum scheduling τον αριθμό environment interactions για target navigation success rate σε complex unknown environments;

Novelty — Τι Καινούργιο Κάνω

5-stage difficulty ladder well-specified σε 5 dimensions ταυτόχρονα. Adaptive advancement με hysteresis. Connection σε PPO (C21) και CBF (C18) για safe curriculum training = novel systems combination.

Σχετική Βιβλιογραφία

Bengio et al. (2009) curriculum learning. Narvekar et al. (2020) curriculum RL survey. Florensa et al. (2017) reverse curriculum.

⑥ Αποτελέσματα & Τι Σημαίνουν

Curriculum logic εκτελείται σωστά. Stage advancement validated. 5 tests passing. ⚠ Full training χρειάζεται functional PPO (C21).

Metrics

- Episodes to target success rate με vs χωρίς curriculum
- Stage advancement episodes
- Success rate per stage
- Final policy collision rate

Τι Λείπει Ακόμα

RL backend (C21) non-functional. Curriculum effectiveness δεν measurable. Δεν υπάρχει σύγκριση με flat training.

⑦ Αυστηρή Κριτική — Reviewer Mode

Αδυναμίες

- Curriculum logic σωστό αλλά connected σε non-functional PPO stub
- τ_{stage} thresholds manually set — δεν principled method
- 5 stages μπορεί να μην cover all difficulty dimensions
- Δεν υπάρχει σύγκριση με flat training

Κρυφές Παραδοχές

- τ_{stage} thresholds correctly set
- 5 stages cover full difficulty range
- W sufficient για stable SR estimate

Σενάρια Αποτυχίας

- τ_{stage} too high: agent στέκεται σε ένα stage για πάντα
- τ_{stage} too low: advances πριν master το stage
- Curriculum δεν transfers σε real robot (sim-to-real gap)

⑧ Πώς Γίνεται Δημοσίευση

Τίτλος Paper	Multi-Dimensional Adaptive Curriculum για Safe Navigation RL
Venue	ICRA / RA-L — χρειάζεται functional PPO

Missing Experiments

- Train με functional PyTorch PPO: curriculum vs flat training
- Επεισόδια σε 70% success rate: με και χωρίς curriculum
- ADAPTIVE vs FIXED vs REVERSE strategies σύγκριση

- Hardware: curriculum-trained policy transfers σε real TurtleBot3;

Ablations που Χρειάζονται

- Adaptive vs fixed vs reverse curriculum
- 5 stages vs 3 stages vs continuous difficulty
- W sensitivity: rolling window size effect
- τ_{stage} sensitivity

⑨ **Ανοιχτά Ερευνητικά Ερωτήματα**

- 64. Μπορεί difficulty να αυξάνεται μόνο στη dimension που δυσκολεύεται ο agent;
- 65. Μπορεί curriculum να coordinated σε fleet (C16 federated curriculum);
- 66. Μπορεί teacher (curriculum selector) να μαθαίνεται από άλλο RL agent;

⑩ **Αν Είχα 2 Λεπτά να το Εξηγήσω σε Οποιονδήποτε...**

Η εκπαίδευση RL agent απευθείας σε complex environment είναι σαν να πετάς αρχάριο κολυμβητή σε βαθιά νερά — αποτυγχάνει πάντα και δεν μαθαίνει τίποτα. Αυτό το module ξεκινά από απλό (2 εμπόδια, κοντινός στόχος) και αυξάνει δυσκολία σταδιακά σε 5 επίπεδα, όταν ο agent επιτυγχάνει αξιόπιστα. 5 tests passing — η curriculum logic είναι σωστή και περιμένει functional PPO backend.

Βαθμολογία

Διάσταση	Βαθμός	Σχόλιο
Πρωτοτυπία	6/10	Incremental
Τεχνικό Βάθος	7/10	Prototype επίπεδο
Δημοσιευσιμότητα	6/10	Χρειάζεται experiments
PhD Δυναμικό	7/10	Υποστηρικτικό υλικό

Contribution 23 3D Gaussian Splatting Mapper

Κατηγορία: 3D Mapping / Compact Representation

① Εξήγηση για Αρχάριο — Από το Μηδέν

Τι πρόβλημα λύνει;

Αντί για grid κελιών (κάθε κελί: occupied/free), ο χώρος αναπαρίσταται ως collection 3D «blobs» (Gaussians). Κάθε blob: θέση, σχήμα, πυκνότητα, εμπιστοσύνη. Online update: νέες μετρήσεις merge ή add blobs.

Γιατί υπάρχει αυτό το πρόβλημα;

Voxel grids: memory-intensive, δεν ενσωματώνουν φυσικά uncertainty. Gaussian Splatting: compact, expressive, φυσικά uncertain. State-of-the-art (Kerbl 2023) για scene representation.

Γιατί είναι δύσκολο;

Full 3DGS: neural rendering με rasterization + RGB loss backpropagation. Εδώ υλοποιούμε μόνο navigation-relevant components — occupancy, uncertainty, frontiers. Χωρίς photorealistic rendering.

② Αναλογία & Διαίσθηση

Καλλιτέχνης που σκισάρει τοπίο: όχι κάθε πέτρα και φύλλο — broad strokes που αποτυπώνουν βασικά features, περισσότερη λεπτομέρεια όπου χρειάζεται. Gaussian Splatting: compact artistic sketch του χώρου — εκφραστικό και εύκολα updateable.

③ Τι Έκανα Ακριβώς — Βήμα-Βήμα

- Gaussian primitive: $G_i = (\mu_i \in \mathbb{R}^3, \Sigma_i \in \mathbb{R}^{3 \times 3}, \alpha_i \in [0,1], c_i \in \mathbb{R}^3, \text{conf}_i \in [0,1])$
- Per frame: για κάθε point, βρες nearest Gaussian via Mahalanobis distance
- Merge ($d_M < \tau$): EKF-style update μ, Σ , confidence
- Add new: αν δεν υπάρχει nearby Gaussian και $|G| < N_{\max}$
- Confidence decay: $\text{conf} *= \rho$ κάθε frame, prune $< \text{threshold}$
- 2D projection: project Gaussians σε floor plane $\rightarrow$ occupancy grid $O(r,c)$
- Uncertainty map: $1 - \max_{\text{conf}}$ per cell
- Frontier detection: κελιά adjacent σε high-uncertainty unoccupied cells
- 5 tests passing

Ροή Δεδομένων

Point cloud frame $\rightarrow$ Mahalanobis search $\rightarrow$ merge ή add Gaussian $\rightarrow$ decay + prune $\rightarrow$ 2D projection $\rightarrow$ O, U, frontiers $\rightarrow$ planner

④ Βαθιά Τεχνική Ανάλυση

Βασικά Components

- Gaussian store: list ($\mu, \Sigma, \alpha, c, \text{conf}$)

- Mahalanobis matcher: $d_M = \sqrt{(p-\mu)^T \Sigma^{-1} (p-\mu)} < \tau_{\text{merge}}$
- EKF updater: $\mu \leftarrow (1-\alpha)\mu + \alpha p$, $\Sigma \leftarrow (1-\alpha)\Sigma + \alpha(p-\mu)(p-\mu)^T$
- Confidence decayer: $\text{conf} *= \rho$ ανά frame
- 2D projector: Gaussian alpha-blending σε floor grid
- Frontier detector: boundary known/unknown space

Pseudocode / Αλγόριθμος

```
ADD FRAME(points, pose):
    transform_to_world(points, pose)
    decay_all_confidences( $\rho$ )
    για p σε points:
        G_near = find_nearest_mahalanobis(p, gaussians,  $\tau_{\text{merge}}$ )
        αν G_near:
            G_near.mu = (1- $\alpha$ )*G_near.mu +  $\alpha$ *p
            G_near.Sigma = (1- $\alpha$ )*G_near.Sigma +  $\alpha$ *outer(p-G_near.mu, p-G_near.mu)
            G_near.conf = min(1.0, G_near.conf + 0.05)
        αλλιώς αν len(gaussians) < N_max:
            gaussians.append(new_gaussian(p))
    prune(conf < conf_min)
```

Μαθηματική Φορμοποίησηση

```
Gaussian:  $G_i = (\mu_i \in \mathbb{R}^3, \Sigma_i \in \mathbb{R}^{3 \times 3}, \alpha_i \in [0,1], c_i \in \mathbb{R}^3, \text{conf}_i \in [0,1])$ 
Mahalanobis:  $d_M(p, G) = \sqrt{(p-\mu)^T \Sigma^{-1} (p-\mu)}$ 
EKF merge:  $\mu \leftarrow (1-\alpha)\mu + \alpha p$ ,  $\Sigma \leftarrow (1-\alpha)\Sigma + \alpha(p-\mu)(p-\mu)^T$ 
Confidence decay:  $\text{conf}_i(t) = \rho \cdot \text{conf}_i(t-1)$ ,  $\rho \in (0,1)$ 
2D projection:  $O(r, c) = \min(1, \sum_{G: z \in [z_{\text{min}}, z_{\text{max}}]} \alpha_G \cdot \exp(-d^2_{2D}/2\sigma_G^2))$ 
Uncertainty:  $U(r, c) = 1 - \max_{G \text{ near } (r, c)} \text{conf}_G$ 
```

Πολυπλοκότητα & Παραδοχές

Χρονική πολυπλοκότητα: Add frame: $O(N_{\text{points}} \cdot |G|)$ naive, $O(N_{\text{points}} \cdot \log|G|)$ με spatial indexing. Projection: $O(|G| \cdot \sigma_{\text{max}}^2)$.

- Point clouds aligned σε world frame (requires accurate pose)
- Mahalanobis distance sufficient για merge criterion
- 2D floor projection adequate (not 3D)
- Navigation-relevant components only — χωρίς neural rendering

⑤ Ερευνητική Αξία

Ερευνητικό Ερώτημα

Παρέχει incremental 3DGS map richer uncertainty estimates και πιο χρήσιμο frontier detection για navigation vs standard 2D occupancy maps;

Novelty — Τι Καινούργιο Κάνω

Navigation-centric 3DGS — occupancy, uncertainty, frontiers από Gaussian primitives. EKF-style Gaussian fusion + confidence decay = principled online update.

Σχετική Βιβλιογραφία

Kerbl et al. (2023) 3DGS. Matsuki et al. (2024) MonoGS SLAM. Yugay et al. (2023) Gaussian-SLAM. OctoMap, Voxblox για σύγκριση.

⑥ Αποτελέσματα & Τι Σημαίνουν

Occupancy extraction και frontier detection validated. Confidence decay και pruning verified. 5 tests passing. $\triangle$ Χωρίς neural rendering.

Metrics

- Occupancy map accuracy vs ground truth
- Frontier detection quality
- Memory efficiency vs OctoMap
- Update throughput (frames/sec)

Τι Λείπει Ακόμα

Δεν υπάρχει neural rendering. Δεν υπάρχει σύγκριση με OctoMap ή Voxblox. Δεν αξιολογήθηκε occupancy accuracy vs ground truth.

⑦ Αυστηρή Κριτική — Reviewer Mode

Αδυναμίες

- Χωρίς neural rendering: δεν είναι πλήρης 3DGS
- Δεν υπάρχει σύγκριση με standard 2D occupancy maps
- Mahalanobis search naive: $O(|G|)$ per point — needs spatial indexing
- 2D floor projection αγνοεί 3D vertical structure

Κρυφές Παραδοχές

- Pose estimate accurate για world frame transformation
- Mahalanobis sufficient για merge criterion
- Floor projection adequate για navigation

Σενάρια Αποτυχίας

- Poor pose estimation: Gaussians misplaced
- Very cluttered: many small Gaussians, slow search
- Multi-story buildings: 2D projection inadequate

⑧ Πώς Γίνεται Δημοσίευση

Τίτλος Paper	Navigation-Centric 3DGS: Online Occupancy και Uncertainty Extraction για Autonomous Exploration
Venue	ICRA / RA-L / 3DV

Missing Experiments

- Σύγκριση 3DGS occupancy vs OctoMap vs standard 2D grid
- Spatial indexing (k-d tree) και throughput measurement
- Frontier quality: 3DGS vs 2D grids για exploration targets
- Full 3DGS: add neural rendering για RGB loss optimization

Ablations που Χρειάζονται

- EKF merge vs simple replacement vs full Gaussian mixture
- Confidence decay rate ρ sensitivity
- τ_{merge} threshold: merge vs add tradeoff
- 2D projection resolution vs accuracy

9 Ανοιχτά Ερευνητικά Ερωτήματα

- 67. Μπορεί neural rendering να added efficiently για online SLAM;
- 68. Μπορούν Gaussians να encode semantic labels (CLIP embeddings);
- 69. Πώς να handled multi-story environments;

10 Αν Είχα 2 Λεπτά να το Εξηγήσω σε Οποιονδήποτε...

Αντί για πλέγμα κελιών, ο χώρος αναπαρίσταιται ως collection 3D blobs. Κάθε blob περιγράφει μια μικρή περιοχή: πού είναι, τι σχήμα έχει, πόσο πυκνός είναι, πόσο σίγουρος είμαστε. Νέες μετρήσεις ενημερώνουν existing blobs ή δημιουργούν νέα. Blobs με χαμηλή εμπιστοσύνη ξεθωριάζουν και διαγράφονται. Το collection προβάλλεται σε 2D για navigation planning. 5 tests passing.

Βαθμολογία

Διάσταση	Βαθμός	Σχόλιο
Πρωτοτυπία	8/10	Γνήσια καινοτόμο
Τεχνικό Βάθος	8/10	Πλήρης μαθ. ανάλυση
Δημοσιευσιμότητα	7/10	Χρειάζεται experiments
PhD Δυναμικό	8/10	Ισχυρό κεφάλαιο διδακτορικού

Contribution 24 NeRF + MC-Dropout Uncertainty Maps

Κατηγορία: 3D Mapping / Uncertainty

① Εξήγηση για Αρχάριο — Από το Μηδέν

Τι πρόβλημα λύνει;

NeRF μαθαίνει να «ζωγραφίζει» τον χώρο από οποιαδήποτε γωνία. MC-Dropout: τρέχει το NeRF πολλές φορές με τυχαία dropout — variance = uncertainty. Υψηλή αβεβαιότητα → priority exploration target.

Γιατί υπάρχει αυτό το πρόβλημα;

Η εξερεύνηση πρέπει να γνωρίζει ΠΟΙΕΣ περιοχές έχουν μεγαλύτερη αβεβαιότητα — εκεί αξίζει να πάει. NeRF: confident σε seen areas, uncertain σε unseen.

Γιατί είναι δύσκολο;

NeRF inference: computationally expensive. MC-Dropout × T passes: πολλαπλάσιο κόστος. Untrained NeRF: random uncertainty — οι outputs δεν έχουν νόημα.

② Αναλογία & Διαίσθηση

Μετεωρολόγος: confident στις επόμενες 24 ώρες (πολλά observations), uncertain σε 7 μέρες (λίγα data). NeRF + MC-Dropout: confident κοντά σε well-observed viewpoints, uncertain μακριά. Παζλ μισοτελειωμένο: αμέσως βλέπεις ποια κομμάτια λείπουν.

③ Τι Έκανα Ακριβώς — Βήμα-Βήμα

- Positional encoding: Fourier features $L=6$ frequencies για θέση, $L=4$ για κατεύθυνση
- TinyNeRF: MLP density/color network με random dropout masking
- MC-Dropout: $T=8$ forward passes ανά ray με διαφορετικά dropout masks
- Volume rendering: $C(r) = \sum_k T_k \cdot (1 - \exp(-\sigma_k \cdot \delta_k)) \cdot c_k$
- Per-ray uncertainty: $u(r) = \sum_k w_k \cdot \text{std_MC}[\sigma_k]$
- 2D projection: uncertainty aggregated σε navigation grid
- Exploration weights: $w \propto U(r, c) \cdot (1 - O(r, c))$
- ⚠ NeRF weights τυχαία — outputs meaningless

Ροή Δεδομένων

Camera poses → ray casting → TinyNeRF MC-Dropout (T passes) → density variance per point → volume render → uncertainty per ray → 2D grid → exploration weights

④ Βαθιά Τεχνική Ανάλυση

Βασικά Components

- Positional encoder: Fourier features για (x,y,z) και direction
- TinyNeRF: 2-layer MLP με random dropout masking
- MC sampler: T random dropout masks per ray evaluation

- Volume renderer: $\text{transmittance} \times \text{density} \times \text{color}$
- Uncertainty aggregator: std over T density estimates
- 2D projector: hit-point uncertainty σε grid

Pseudocode / Αλγόριθμος

```
MC-DROPOUT ANA RAY:
sigma_samples = []
για _ σε range(T): // T dropout passes
    sigma, _ = nerf_with_dropout(points, direction)
    sigma_samples.append(sigma)

sigma_mean = mean(sigma_samples, axis=0)
sigma_std = std(sigma_samples, axis=0)

T_k = exp(-cumsum(sigma_mean * deltas)) // transmittance
w_k = T_k * (1 - exp(-sigma_mean * deltas))
uncertainty_ray = sum(w_k * sigma_std)
```

Μαθηματική Φορμοποίησηση

```
NeRF:  $C(r) = \sum_k T_k (1 - \exp(-\sigma_k \delta_k)) c_k$ 
Transmittance:  $T_k = \exp(-\sum_{j < k} \sigma_j \delta_j)$ 
MC variance:  $\text{Var}[\sigma(x)] \approx (1/T) \sum_t \sigma_t^2 - ((1/T) \sum_t \sigma_t)^2$ 
Ray uncertainty:  $u(r) = \sum_k w_k \cdot \text{std\_MC}[\sigma_k]$ 
Exploration weights:  $w(r, c) \propto U(r, c) \cdot (1 - O(r, c))$ 
```

Πολυπλοκότητα & Παραδοχές

Χρονική πολυπλοκότητα: NeRF: $O(T \cdot N_{\text{rays}} \cdot N_{\text{samples}} \cdot |\text{MLP}|)$. T multiplies inference cost. Dominant για real deployment.

- MC-Dropout approximates Bayesian inference ⚠ controversial
- NeRF trained σε relevant data ⚠ random weights
- T=8 samples sufficient για variance estimate
- Dropout rate correctly set

⑤ Ερευνητική Αξία

Ερευνητικό Ερώτημα

Μπορεί MC-Dropout NeRF variance να serve ως reliable spatial uncertainty signal για exploration, superior vs entropy-based occupancy uncertainty;

Novelty — Τι Καινούργιο Κάνω

MC-Dropout σε NeRF για navigation exploration guidance. 2D projection + integration με exploration weights.

Σχετική Βιβλιογραφία

Mildenhall et al. (2020) NeRF. Gal & Ghahramani (2016) MC-Dropout. Ran et al. (2023) ActiveRMAP.

⑥ Αποτελέσματα & Τι Σημαίνουν

Volume rendering μαθηματικά σωστό. MC-Dropout framework σωστό. ⚠ Random NeRF weights → τυχαία uncertainty maps.

Metrics

- Uncertainty correlation με actual unobserved areas
- Exploration target quality
- Rendering PSNR (requires training)
- Inference latency per map

Τι Λείπει Ακόμα

NeRF δεν εκπαιδεύτηκε. Uncertainty values meaningless. Δεν υπάρχει σύγκριση με entropy-based exploration.

⑦ Αυστηρή Κριτική — Reviewer Mode

Αδυναμίες

- ⚠ Untrained NeRF → τυχαία uncertainty maps — module non-functional
- MC-Dropout ως Bayesian approximation: controversial
- NeRF inference latency: high για real-time
- Requires dense camera coverage για accurate training

Κρυφές Παραδοχές

- MC-Dropout approximates true Bayesian uncertainty (controversial)
- Training data available
- T=8 sufficient για calibrated uncertainty

Σενάρια Αποτυχίας

- ⚠ Χωρίς training: όλα random noise
- Sparse camera coverage: NeRF training fails
- $T \times N_{\text{rays}} \times N_{\text{samples}}$ exceeds real-time budget

⑧ Πώς Γίνεται Δημοσίευση

Τίτλος Paper	NeRF-Driven Uncertainty για Active Robot Exploration
Venue	ICRA / 3DV — χρειάζεται trained NeRF

Missing Experiments

- Train NeRF σε TurtleBot3 RGB-D dataset
- High-NeRF-uncertainty correlates με unexplored areas;
- NeRF uncertainty vs occupancy entropy (C07) για exploration
- Instant-NGP για latency optimization

Ablations που Χρειάζονται

- MC-Dropout T: 4 vs 8 vs 16 — uncertainty vs compute

- NeRF uncertainty vs occupancy entropy
- Με vs χωρίς positional encoding
- U alone vs $U \cdot (1-O)$

⑨ Ανοιχτά Ερευνητικά Ερωτήματα

- 70. Μπορεί uncertainty να obtained χωρίς MC-Dropout (ensemble);
- 71. Πώς να combined NeRF uncertainty και occupancy entropy;
- 72. Μπορεί instant-NGP να κάνει NeRF real-time;

⑩ Αν Είχα 2 Λεπτά να το Εξηγήσω σε Οποιονδήποτε...

NeRF είναι νευρωνικό δίκτυο που μαθαίνει να σχεδιάζει τον χώρο από οποιαδήποτε γωνία. Εκεί που έχει δει πολλές φωτογραφίες, είναι *confident*. Εκεί που δεν έχει δει, είναι *uncertain*. Τρέχοντας το NeRF πολλές φορές με τυχαία dropout (MC-Dropout), η *variance* δείχνει πού είναι αβέβαιο. Αυτές οι περιοχές γίνονται *exploration targets*. Το framework είναι σωστό — το NeRF χρειάζεται εκπαίδευση.

Βαθμολογία

Διάσταση	Βαθμός	Σχόλιο
Πρωτοτυπία	7/10	<i>Incremental</i>
Τεχνικό Βάθος	7/10	<i>Prototype επίπεδο</i>
Δημοσιευσιμότητα	6/10	<i>Χρειάζεται experiments</i>
PhD Δυναμικό	7/10	<i>Υποστηρικτικό υλικό</i>

Contribution 25 Adversarial Attack Simulator

Κατηγορία: Cybersecurity / Robustness

① Εξήγηση για Αρχάριο — Από το Μηδέν

Τι πρόβλημα λύνει;

Δημιουργεί επιθέσεις σε αισθητήρες: FGSM/PGD στις νευρωνικές εισόδους, phantom obstacles στο LiDAR, drift στην odometry. Χρησιμοποιείται για systematic robustness evaluation του navigation system.

Γιατί υπάρχει αυτό το πρόβλημα;

Πριν αναπτύξεις ρομπότ σε ευαίσθητα περιβάλλοντα, πρέπει να γνωρίζεις τα τρωτά σημεία. Ο simulator επιτρέπει ελεγχόμενη και reproducible αξιολόγηση.

Γιατί είναι δύσκολο;

FGSM/PGD χωρίς backpropagation: finite differences $O(d)$ — αργό για high-dimensional inputs. Physics-plausible attacks πρέπει να είναι realistic αλλά και informative.

② Αναλογία & Διαίσθηση

Penetration tester τράπεζας: δοκιμάζει κάθε γνωστό τρόπο παραβίασης πριν real attacker το κάνει. Security researcher: «red team» vs «blue team». Crash test dummy: δοκιμάζει αυτοκίνητο σε controlled conditions πριν τον δρόμο.

③ Τι Έκανα Ακριβώς — Βήμα-Βήμα

- FGSM: $x_{adv} = x + \epsilon \cdot \text{sign}(\nabla_x L)$ μέσω finite differences
- PGD: iterative FGSM με L^∞ projection, random start
- LiDAR phantom injection: N clustered points κοντά στο ρομπότ
- LiDAR point removal: random ή targeted fraction
- LiDAR sector blinding: zero out angular range
- Odometry drift: $\delta_t = \delta_{t-1} + N(0, \sigma^2)$ Gaussian random walk
- RobustnessEvaluator: runs full attack suite
- 6 tests passing + ϵ -bound verification

Ροή Δεδομένων

Observations → attack (FGSM/PGD/LiDAR/odom) → corrupted observations → navigation system → compare degradation

④ Βαθιά Τεχνική Ανάλυση

Βασικά Components

- GradientAttacker: FGSM και PGD μέσω finite differences
- LiDARAttacker: phantom injection, removal, sector blinding
- OdometrySpoofers: Gaussian drift

- RobustnessEvaluator: runs all attacks, aggregates metrics

Pseudocode / Αλγόριθμος

```
FGSM:
    grad = finite_diff_gradient(x, loss_fn, h=1e-4)  // O(d) queries
    x_adv = clip(x + ε*sign(grad), 0, 1)
    assert max(abs(x_adv - x)) <= ε

PGD:
    x_adv = x + uniform(-ε, ε)  // random start
    για k σε range(pgd_steps):
        grad = finite_diff_gradient(x_adv, loss_fn)
        x_adv = project_Linf(x_adv + α*sign(grad), x, ε)

LIDAR PHANTOM:
    για _ σε range(N_phantoms):
        angle = uniform(0, 2π)
        dist = uniform(0.5, max_range*0.6)
        cluster = robot_pos + dist*[cos, sin] + normal(0, 0.05, (8, 3))
        point_cloud = vstack([point_cloud, cluster])
```

Μαθηματική Φορμοποίησηση

```
FGSM:  $x_{adv} = x + \epsilon \cdot \text{sign}(\nabla_x L(f_\theta(x), y))$ ,  $\|x_{adv} - x\|_\infty \leq \epsilon$ 
PGD:  $x^{k+1} = \Pi_{B_\epsilon(x)}(x^k + \alpha \cdot \text{sign}(\nabla_{x^k} L))$ 
Finite diff:  $\partial L / \partial x_i \approx (L(x+h \cdot e_i) - L(x-h \cdot e_i)) / (2h)$  — O(d) queries
Odom drift:  $\delta_t = \delta_{t-1} + \eta_t$ ,  $\eta_t \sim N(0, \sigma^2)$  (Gaussian random walk)
Phantom:  $p_i = p_{robot} + r_i \cdot [\cos \theta_i, \sin \theta_i] + \epsilon_i$ ,  $\epsilon_i \sim N(0, 0.05^2)$ 
```

Πολυπλοκότητα & Παραδοχές

Χρονική πολυπλοκότητα: FGSM: $O(d \cdot 2)$. PGD: $O(K \cdot d \cdot 2)$. LiDAR: $O(N_{\text{phantoms}})$. Odom: $O(1)$.

- Finite differences approximate true gradient (smooth loss)
- ϵ -bounded attacks remain valid
- LiDAR phantom clusters physics-plausible
- Odom drift Gaussian random walk

⑤ Ερευνητική Αξία

Ερευνητικό Ερώτημα

Ποια είναι η adversarial robustness των DynNav neural navigation components, και ανιχνεύει το IDS (C08) αυτές τις επιθέσεις;

Novelty — Τι Καινούργιο Κάνω

Comprehensive attack suite — gradient + physics-plausible sensor attacks — evaluated κατά του ίδιου navigation system. Σύνδεση με IDS (C08) για detection evaluation.

Σχετική Βιβλιογραφία

Goodfellow et al. (2015) FGSM. Madry et al. (2018) PGD. Cao et al. (2019) LiDAR attacks. Eykholt et al. (2018) physical adversarial examples.

⑥ Αποτελέσματα & Τι Σημαίνουν

FGSM και PGD produce measurably higher loss. LiDAR phantoms: correct count. Odom drift accumulates. ϵ -bounds verified. 6 tests passing.

Metrics

- FGSM/PGD: loss increase per attack
- LiDAR: points added/removed
- Odom drift magnitude after N steps
- IDS detection rate (C08) under each attack

Τι Λείπει Ακόμα

Finite differences δεν scalable σε real neural networks. Δεν υπάρχει hardware attack experiments. Δεν υπάρχει end-to-end evaluation.

⑦ Αυστηρή Κριτική — Reviewer Mode

Αδυναμίες

- Finite differences $O(d)$ — impractical για high-dimensional NN
- FGSM/PGD χωρίς backprop: approximate — δεν test full neural vulnerability
- Χωρίς end-to-end: πώς attack επηρεάζει navigation decisions;
- IDS (C08) evaluation δεν έγινε ακόμα

Κρυφές Παραδοχές

- Finite differences approximate true gradient
- ϵ -bounded perturbations meaningful για navigation
- Phantom clusters physically plausible

Σενάρια Αποτυχίας

- High-dimensional observations: $O(d)$ too slow
- Adaptive attackers knowing the defense
- Replay attacks: historically valid readings

⑧ Πώς Γίνεται Δημοσίευση

Τίτλος Paper	Adversarial Robustness Evaluation: From Gradient Attacks to Physics-Plausible Sensor Manipulation
Venue	ICRA Security Workshop / CPS-IoTSec

Missing Experiments

- Connect IDS (C08): detection rate per attack type
- PyTorch autograd αντί για finite differences
- Physical LiDAR interference σε TurtleBot3
- End-to-end: attack X $\rightarrow$ collision rate increase;

Ablations που Χρειάζονται

- FGSM vs PGD: ποιο harder to defend;
- ϵ sensitivity: imperceptible threshold
- LiDAR phantom vs removal vs blinding: which degrades most;
- Με vs χωρίς IDS (C08): prevents navigation failure;

9 Άνοιχτά Ερευνητικά Ερωτήματα

- 73. Μπορεί adversarial training να improves robustness;
- 74. Μπορούν physical adversarial patches να fool VLM (C11);
- 75. Πώς gradient attacks interact με CBF safety shield (C18);

10 Αν Είχα 2 Λεπτά να το Εξηγήσω σε Οποιονδήποτε...

Πριν αναπτύξεις ρομπότ, πρέπει να ξέρεις τα τρωτά σημεία. Αυτό το module υλοποιεί το «hacker toolkit»: crafted perturbations για neural inputs (FGSM/PGD), phantom obstacles στο LiDAR, και σταδιακή corruption της position estimate. Η systematic αξιολόγηση αποκαλύπτει πού είναι brittle το σύστημα — και ελέγχει αν το IDS (C08) τις ανιχνεύει. 6 tests passing, ϵ -bounds verified.

Βαθμολογία

Διάσταση	Βαθμός	Σχόλιο
Πρωτοτυπία	7/10	Incremental
Τεχνικό Βάθος	7/10	Prototype επίπεδο
Δημοσιευσιμότητα	7/10	Χρειάζεται experiments
PhD Δυναμικό	7/10	Υποστηρικτικό υλικό

Contribution 26 Byzantine Fault-Tolerant Swarm — BFT Consensus

Κατηγορία: Multi-Robot / Security

① Εξήγηση για Αρχάριο — Από το Μηδέν

Τι πρόβλημα λύνει;

Σε στόλο 6 ρομπότ, αν 1 είναι χαλασμένο ή χακαρισμένο και λέει ψέματα, τα υπόλοιπα το ανιχνεύουν στατιστικά (MAD) και παίρνουν σωστή απόφαση χωρίς αυτό. Κλασικό Byzantine Generals problem.

Γιατί υπάρχει αυτό το πρόβλημα;

Σε πραγματικές αναπτύξεις, ρομπότ μπορεί να βλαφτούν ή να χακαριστούν. Naive coordination (mean όλων) τρωτό σε έναν malicious robot. BFT: εγγυάται σωστή απόφαση παρά Byzantine failures.

Γιατί είναι δύσκολο;

Full BFT (PBFT): πολλαπλά communication rounds + cryptographic authentication. Εδώ: statistical approximation (MAD outlier detection + weighted median) — practical χωρίς cryptographic overhead.

② Αναλογία & Διαίσθηση

Χρηματιστήριο: index prices χρησιμοποιούν robust aggregation αντί για simple average — outlier trades αποκλείονται. Ομάδα 6 φίλων ψηφίζει εστιατόριο: αν ένας είναι «πληρωμένος» να προτείνει το χειρότερο, η majority median αγνοεί αυτή την πρόταση.

③ Τι Έκανα Ακριβώς — Βήμα-Βήμα

- SwarmRobot: τρέχει local $A^* \rightarrow$ proposal $P_k = (\text{path}, \text{cost}, \text{confidence})$
- Fault modes: random (random path+cost), constant_bad (cost=9999), silent (no response)
- BFTConsensus: συλλέγει proposals, MAD-based outlier detection
- MAD: $|c_k - \text{median}(c)| > \kappa \cdot \text{MAD}(c) \rightarrow$ flag ως Byzantine
- Weighted median: consensus cost από honest robot costs $\times$ confidence
- Path selection: honest robot closest σε consensus cost με highest confidence
- Multi-round experiment
- 5 tests passing

Ροή Δεδομένων

N ρομπότ $\rightarrow$ local A^ plans $\rightarrow$ proposals broadcast $\rightarrow$ MAD outlier detection $\rightarrow$ honest set $H \rightarrow$ weighted median $\rightarrow$ best path $\rightarrow$ execute*

④ Βαθιά Τεχνική Ανάλυση

Βασικά Components

- SwarmRobot: local A* planner + fault mode
- Proposal: (path, cost, confidence) dataclass
- MAD detector: Median Absolute Deviation για outlier detection
- Weighted median: sum-of-weights cutoff για robust central tendency
- Path selector: closest σε c^* με highest confidence
- History logger: per-round metrics

Pseudocode / Αλγόριθμος

```
BFT CONSENSUS ROUND:
proposals = [robot_k.plan(grid, start, goal) για k σε range(N)]
valid = [p για p σε proposals αν p is not None]

// Step 1: MAD outlier detection
costs = [p.cost για p σε valid]
c_med = median(costs)
MAD = median(abs(c - c_med) για c σε costs)
honest = [p για p σε valid αν abs(p.cost - c_med) <= κ * MAD]
n_byzantine = len(valid) - len(honest)

// Step 2: Weighted median
c_star = weighted_median([p.cost για p σε honest], [p.conf για p σε honest])

// Step 3: Best path
k_star = argmin: |p.cost - c_star| - η * p.confidence
return honest[k_star].path
```

Μαθηματική Φορμοποίηση

```
BFT bound:  $n \geq 3f+1 \leftrightarrow f < n/3$  (classical result)
MAD:  $\text{median}(|c_k - \text{median}(c)|)$ 
Byzantine:  $B_k = 1[|c_k - c| > \kappa \cdot \text{MAD}]$ 
Weighted median:  $c^* = c_{\{j^*\}}$  όπου  $j^* = \min j: \sum_{i \leq j} w_{\{i\}} \geq (\sum w)/2$ 
Path selection:  $k^* = \text{argmin}_{\{k \in H\}} |c_k - c^*| - \eta \cdot \gamma_k$ 
```

Πολυπλοκότητα & Παραδοχές

Χρονική πολυπλοκότητα: Single round: $O(N \cdot A^*) + O(N \log N)$ για MAD + $O(N)$ για weighted median.

- $f < n/3$ Byzantine — MAD detection βασίζεται σε honest majority
- Byzantine ρομπότ δεν γνωρίζουν το scheme (non-adaptive)
- Honest ρομπότ compute A* correctly
- Cost values comparable across robots

⑤ Ερευνητική Αξία

Ερευνητικό Ερώτημα

Ανιχνεύει και εξαιρεί το weighted-median BFT Byzantine ρομπότ ενώ επιλέγει near-optimal navigation plans, σεβόμενο το $f < n/3$ bound;

Novelty — Τι Καινούργιο Κάνω

BFT consensus για multi-robot navigation plan selection, με weighted median + robot confidence. Σύνδεση με Federated Learning (C16): ίδιο median aggregation για Byzantine-robust FL.

Σχετική Βιβλιογραφία

Lamport et al. (1982) Byzantine Generals. Castro & Liskov (1999) PBFT. Olfati-Saber (2006) swarm consensus.

⑥ Αποτελέσματα & Τι Σημαίνουν

Correct Byzantine detection σε όλα τα simulated rounds. Agreed cost consistent. Different fault types detected. 5 tests passing.

Metrics

- Byzantine detection rate
- Correct plan selection rate
- Agreed cost variance across rounds
- Majority vote vs BFT weighted median

Τι Λείπει Ακόμα

Χωρίς cryptographic authentication — sophisticated Byzantine μπορεί να spoof honest. Δεν υπάρχει σύγκριση με majority voting. κ threshold sensitivity δεν αξιολογήθηκε.

⑦ Αυστηρή Κριτική — Reviewer Mode

Αδυναμίες

- MAD δεν cryptographically secure: attacker που ξέρει scheme → craft cost within MAD
- Statistical approximation PBFT — όχι formal BFT protocol
- κ και η χρειάζονται tuning χωρίς principled method
- Assumes all honest robots have same map

Κρυφές Παραδοχές

- Attackers non-adaptive (δεν γνωρίζουν scheme)
- All honest robots consistent maps
- Honest A* proposals reasonable range

Σενάρια Αποτυχίας

- Adaptive attacker: craft cost within MAD — evades detection
- Many Byzantine ($f \geq n/3$): MAD detection fails
- Honest robots very different maps: high honest cost variance looks Byzantine

⑧ Πώς Γίνεται Δημοσίευση

Τίτλος Paper	Byzantine Fault-Tolerant Multi-Robot Navigation Consensus via Robust Statistical Aggregation
Venue	ICRA / AAMAS / ICDCS

Missing Experiments

- BFT weighted median vs naive mean vs majority vote
- Adaptive attacker: μπορεί να evades MAD;
- Scale: $f=1,2$ Byzantine από $n=6,9$ robots
- κ sensitivity: detection rate vs false positive

Ablations που Χρειάζονται

- Weighted median vs uniform median vs mean over honest set
- κ (MAD multiplier) sensitivity
- Με vs χωρίς confidence weighting
- Single round vs multi-round consensus

9) Ανοιχτά Ερευνητικά Ερωτήματα

76. Μπορεί cryptographic authentication να extends σε full PBFT;
77. Μπορεί Byzantine-robust C26 aggregation να applied σε federated learning (C16);
78. Πώς communication latency επηρεάζει consensus quality;

10) Αν Είχα 2 Λεπτά να το Εξηγήσω σε Οποιονδήποτε...

Σε στόλο 6 ρομπότ, αν 1 είναι χαλασμένο ή χακαρισμένο και προτείνει λανθασμένες διαδρομές, τα υπόλοιπα πρέπει να το ανιχνεύσουν. Αυτό το module χρησιμοποιεί MAD (Median Absolute Deviation): proposals που απέχουν πολύ από τη median επισημαίνονται ως Byzantine. Τα υπόλοιπα ρομπότ υπολογίζουν weighted median cost και επιλέγουν το καλύτερο path. Μαθηματική εγγύηση: αρκεί $f < n/3$ Byzantine για να λειτουργεί. 5 tests passing.

Βαθμολογία

Διάσταση	Βαθμός	Σχόλιο
Πρωτοτυπία	8/10	Γνήσια καινοτόμο
Τεχνικό Βάθος	8/10	Πλήρης μαθ. ανάλυση
Δημοσιευσιμότητα	8/10	Έτοιμο σχεδόν τώρα
PhD Δυναμικό	8/10	Ισχυρό κεφάλαιο διδακτορικού

Μέρος Γ — Τελική Σύνθεση & Αξιολόγηση

A. Πλήρης Πίνακας Βαθμολογιών — Όλα τα 26

Κάθε contribution βαθμολογείται σε 4 διαστάσεις (1–10):

C#	Τίτλος	Πρωτοτ.	Βάθος	Δημοσ.	PhD
01	Learned A* Heuristics	5	7	6	6
02	EKF/UKF Uncertainty	4	7	3	5
03	CVaR Risk Planning	6	8	7	7
04	Returnability	7	7	6	7
05	Safe-Mode FSM	4	6	4	5
06	Energy/Connectivity	6	7	6	6
07	NBV Exploration	7	7	7	7
08	IDS Security	7	8	7	8
09	Multi-Robot Coord.	6	6	6	7
10	Human-Aware Nav.	5	6	5	6
11	VLM Navigation	7	7	6	7
12	Diffusion Occupancy	8	8	7	8
13	World Model RSSM	8	8	6	9
14	Causal SCM	8	8	7	9
15	Neuromorphic SNN	8	7	6	8
16	Federated Learning	7	8	7	8
17	Topological Maps	8	7	7	8
18	STL+CBF Shield ☆	9	9	9	9
19	LLM Planner	6	6	5	6
20	Failure Explainer	7	7	6	7
21	PPO Agent	6	7	5	7

22	Curriculum RL	6	7	6	7
23	3D-GS Mapper	8	8	7	8
24	NeRF Uncertainty	7	7	6	7
25	Adversarial Attacks	7	7	7	7
26	BFT Swarm	8	8	8	8

B. Τα 3 Πιο Δυνατά Contributions

🏆 C18 — STL + CBF Safety Shield (9/9/9/9)

Το ΜΟΝΑΔΙΚΟ contribution που έχει και τα τρία: (1) πλήρη μαθηματική φормοποίηση με αποδείξιμη ιδιότητα forward invariance, (2) πειραματικά αποτελέσματα με αριθμούς (93% violation reduction, <8% overhead, P99 QP: 160μs), (3) σαφή τοποθέτηση έναντι βιβλιογραφίας.

Τι το κάνει να ξεχωρίζει έναντι της βιβλιογραφίας: Όλες οι στη βιβλιογραφία STL+CBF δουλειές (Ruo 2024, Buyukkocak 2022) κάνουν offline synthesis για συγκεκριμένο dynamics model. Το C18 είναι planner-agnostic runtime shield — wraps ANY planner χωρίς πρόσβαση στα internals. Αυτό δεν υπάρχει στη βιβλιογραφία.

Publishable ΤΩΠΑ ως ICRA Workshop paper. Workshop → Full ICRA/RA-L μετά: (1) extreme dropout scenario ($\sigma > 0.25\mu$), (2) full forward invariance theorem, (3) 30 hardware episodes TurtleBot3.

🏆 C14 — Causal SCM + Do-Calculus (8/8/7/9)

Εφαρμογή Pearl's do-calculus σε navigation failure attribution είναι σχετικά novel σε mobile robotics. Με learned structural equations (αντί για χειροποίητες), γίνεται ισχυρή δημοσίευση. Σύζευξη με C20 (Failure Explainer) δημιουργεί unique causal diagnostic pipeline.

Ανοιχτά κλειδιά για δημοσίευση: (1) Learn structural equations από navigation episodes, (2) Compare causal vs correlational ranking — δείξε ότι η causal ανάλυση δίνει different (και πιο actionable) αποτελέσματα, (3) Human study.

🏆 C26 — BFT Swarm Consensus (8/8/8/8)

Clean algorithmic contribution με σωστή BFT theory, multiple fault modes tested, 5 passing tests. Η σύνδεση με C16 (Federated Learning) — ίδιο MAD aggregation για Byzantine-robust FL — είναι hidden gem που δεν έχει exploit.

Γ. Τα 3 Πιο Ανώριμα — Μην Τα Προωθήσεις Τώρα

⚠️ C21 — PPO Agent (6/7/5/7)

Numpy stubs = δεν γίνεται backpropagation = η policy ΠΟΤΕ δεν βελτιώνεται. Αν παρουσιαστεί ως «trained RL agent», ο πρώτος reviewer που θα ζητήσει learning curves θα δει ότι δεν υπάρχουν. FRAMEWORK ONLY. Πρέπει να ξαναγραφεί σε PyTorch.

Διόρθωση: ~1-2 εβδομάδες. Rewrite σε PyTorch, train 1M+ timesteps, δείξε learning curves. Μετά γίνεται real RL contribution.

⚠️ C15 — Neuromorphic SNN (8/7/6/8)

Τυχαία SNN weights = τυχαία ανίχνευση εμποδίων. Η αρχιτεκτονική DVS+SNN είναι σωστή και interesting — αλλά χωρίς εκπαίδευση σε DVS dataset, δεν παράγει τίποτα meaningful. INFRASTRUCTURE ONLY.

⚠️ C24 — NeRF Uncertainty (7/7/6/7)

Untrained NeRF = τυχαία uncertainty maps = τυχαία exploration targets. Το volume rendering framework είναι σωστό — αλλά χωρίς RGB-D training data, δεν λειτουργεί. FRAMEWORK ONLY.

Δ. Κρυφά Δυνατά — Ιδέες που Μπορεί να Μην Έχεις Δει

💡 C18 + C12: Stochastic CBF + Diffusion

Το C18 χρησιμοποιεί $h_{\text{stoch}}(\mu, \Sigma)$ που inflates safety margin ανάλογα με EKF uncertainty. Αν αντικατασταθεί το EKF Σ με τη sample variance από trained diffusion model (C12), ο CBF barrier γίνεται δυναμικά information-aware — τεντώνει περισσότερο κοντά σε areas με uncertain occupancy, λιγότερο σε confirmed-clear areas. Αυτός ο συνδυασμός ΔΕΝ ΥΠΑΡΧΕΙ στη βιβλιογραφία.

Πιθανή publication: «Diffusion-Informed Stochastic CBF for Navigation Under Distributional Occupancy Uncertainty» — RA-L level contribution.

💡 C26 + C16: Byzantine-Robust Federated Learning

Το C26 χρησιμοποιεί weighted median για Byzantine-robust aggregation. Αυτό ΑΚΡΙΒΩΣ είναι το aggregation scheme που χρειάζεται το C16 για Byzantine-robust Federated Learning. Η σύζευξη δημιουργεί: «Federated navigation learning που ανέχεται $f < n/3$ poisoning robots». Δεν υπάρχει στη βιβλιογραφία.

💡 C14 + C20: Causal Diagnostic Pipeline

C14 (causal attribution) + C20 (multimodal explainer) είναι ήδη συνδεδεμένα. Με learned structural equations και human evaluation study, αυτό γίνεται ένα complete causal XAI system για autonomous navigation — novel framing που τοποθετείται σε intersection Causal AI + Robotics + XAI.

Ε. Τι Έχεις Φτιάξει Επιστημονικά — Ειλικρινής Αξιολόγηση

Το DynNav είναι κάτι σπάνιο: ένα principled research framework όπου κάθε module αντιμετωπίζει μια καλά-τεκμηριωμένη πτυχή του navigation under uncertainty. Δεν είναι 26 ανεξάρτητα experiments — είναι μια coherent αρχιτεκτονική.

Μαθηματική κατανόηση	EKF/UKF σωστό, STL semantics σωστές, CBF conditions σωστές, DDPM correct, RSSM correct, SCM do-calculus correct, KKT QP exact — χωρίς λάθη σε κανένα από αυτά
System thinking	Modular architecture με clean interfaces. Κάθε module αντικαθίσταται χωρίς να σπάει τα άλλα. Αυτό δείχνει design maturity πέρα από implementation
Ειλικρινής αυτό-κριτική	Τα ⚠️ warnings, explicit limitations, maturity levels — ένας reviewer εκτιμά honesty πολύ περισσότερο από overclaiming

Πλάτος	26 modules: formal methods, generative AI, causal inference, neuromorphic, federated, BFT — συνδεδεμένα από coherent navigation agenda
Αποτέλεσμα (C18)	93% violation reduction, <8% overhead, P99: 160μs — αριθμοί που κάθεσαι πίσω τους

Ανησυχίες που θα έχει ένας PI:

- Βάθος vs Πλάτος: 26 prototypes < 3 publications. «Ποια 2-3 θα μετατρέψεις σε papers;»
- Stub networks: αν παρουσιαστούν ως working systems, θα ανακαλυφθεί αμέσως σε interview
- Simulation only: hardware validation είναι deal-breaker για robotics venues
- Publication record: repository ≠ peer-reviewed work. Ένα arXiv preprint θα αλλάξει εντελώς την εικόνα

Τελικό verdict: Δυνατός/ή PhD candidate — εύρος + μαθηματική κατανόηση + system thinking + ειλικρίνεια. Το C18 είναι η απόδειξη. Επόμενο βήμα: βάθος σε 2-3 contributions, 1 arXiv preprint, 30 hardware episodes.

Z. Roadmap Δημοσίευσης — Τι Κάνεις Και Πότε

Τώρα (2 εβδομάδες)	Extreme dropout scenario: $\sigma > 0.25\mu$, 8s outage, greedy planner. Στόχος: ≥ 3 det_cbf violations, 0 stoch_cbf. PyTorch rewrite PPO (C21).
1 μήνας	30 TurtleBot3 hardware episodes για C18. Full forward invariance Theorem 1. Planner-agnostic ablation (3 planner qualities). arXiv preprint C18.
2-3 μήνες	Submit C18 σε ICRA 2026 Workshop. Train U-Net για C12 diffusion (ScanNet data). Causal structure learning για C14.
6 μήνες	Full ICRA/RA-L paper C18+C12 (stochastic CBF + diffusion risk). C14+C20 causal diagnostic pipeline paper. C26+C16 Byzantine-robust FL paper.

H. Πώς Να Παρουσιάζεις Αυτή τη Δουλειά

Σε CV	«Ανέπτυξα το DynNav, ένα 26-module research framework για uncertainty-aware autonomous navigation. Κύρια contribution: STL-CBF runtime safety shield (93% violation reduction, ICRA-level), causal failure attribution via SCM, DDPM-based probabilistic risk estimation.»
Σε research statement	«Το DynNav διερευνά πώς formal safety verification, probabilistic uncertainty reasoning, και causal inference συνδυάζονται σε autonomous navigation. Η ισχυρότερη contribution — runtime STL+CBF safety shield — δείχνει 93% violation reduction με formal guarantees. Αυτή η δουλειά

	motivates PhD research agenda στα formal methods για learning-augmented navigation.»
Σε συνέντευξη	«Έφτιαξα modular navigation system με 26 research modules. Το πιο proud: το formal safety shield — μαθηματικό filter που εγγυάται ασφάλεια ανεξάρτητα από τον planner, με <8% efficiency cost. Υλοποίησα causal model για failure attribution και diffusion-based probabilistic occupancy — και τα δύο εκκρεμούν validation.»
ΤΙ ΝΑ ΜΗΝ ΠΕΙΣ	«Έφτιαξα AI system με deep learning, RL, diffusion models, NeRF, neuromorphic, και BFT.» → ο reviewer θα ρωτήσει για το καθένα και θα βρει τα stubs.

Γλωσσάριο — Κάθε Τεχνικός Όρος Απλά

A* (A-star)	Αλγόριθμος εύρεσης βέλτιστης διαδρομής σε χάρτη — $f(n) = g(n) + h(n)$
Admissibility	Heuristic που ποτέ δεν υπερεκτιμά — εγγυάται βελτιστότητα A*
BFT (Byzantine Fault Tolerance)	Σύστημα που λειτουργεί σωστά παρά $f < n/3$ faulty/malicious nodes
CBF (Control Barrier Function)	Μαθηματικό εργαλείο formal safety — $h(x) \geq 0 = \text{safe set}$
CVaR (Conditional Value at Risk)	Μέσος κίνδυνος στα worst $(1-\alpha)\%$ σενάρια — tail risk metric
DDPM (Diffusion Model)	Generative AI: μαθαίνει να αφαιρεί noise → παράγει πολλαπλά σενάρια
DVS (Dynamic Vision Sensor)	Event camera: κάθε pixel πυροδοτεί αυτόνομα σε microseconds
EKF/UKF (Kalman Filter)	Βέλτιστη εκτίμηση κατάστασης με Gaussian belief (μ, Σ)
Federated Learning	Μάθηση χωρίς κοινοποίηση ιδιωτικών δεδομένων — model updates μόνο
Forward Invariance	$\text{Av } h(x_0) \geq 0 \text{ και CBF condition ισχύει} \rightarrow h(x_t) \geq 0 \forall t > 0$
Gaussian Splatting	3D representation ως collection blobs αντί για voxels
IDS	Intrusion Detection System — χ^2 -test στα EKF innovations
Innovation	$v_k = z_k - h(\mu_k k-1)$ — διαφορά measured από predicted
KKT	Karush-Kuhn-Tucker — optimality conditions για exact QP solution
LIF Neuron	Leaky Integrate-and-Fire — βιολογικά-inspired spiking neuron
MAD	Median Absolute Deviation — robust outlier detection statistic
MC-Dropout	Monte Carlo Dropout — Bayesian uncertainty από neural network
NeRF	Neural Radiance Field — μαθαίνει να render 3D scene από photos
Novelty	Τι καινούργιο κάνεις που δεν έχει κάνει κανείς ακριβώς έτσι
Pareto-optimal	Δεν μπορείς να βελτιώσεις ένα μέτρο χωρίς να χειροτερεύσεις άλλο

Planner-agnostic	Λειτουργεί με ANY upstream planner χωρίς πρόσβαση στα internals
PPO	Proximal Policy Optimization — stable RL training algorithm
p_safe	Επιθυμητή πιθανότητα ασφάλειας — π.χ. 0.95 = 95%
$\beta = \Phi^{-1}(p_safe)$	Gaussian quantile — π.χ. $\beta=1.645$ για p_safe=95%
QP (Quadratic Program)	$\min \frac{1}{2}\ u-u_des\ ^2$ s.t. linear constraints — exact min-norm solution
RSSM	Recurrent State Space Model — DreamerV3 world model architecture
Sensor Dropout	Απώλεια αισθητήρα — EKF prediction-only, Σ αυξάνεται
Σ (covariance matrix)	Πίνακας αβεβαιότητας EKF — μεγαλύτερο Σ = λιγότερη σιγουριά
SCM (Structural Causal Model)	Causal graph με structural equations — Pearl's do-calculus
SNN (Spiking Neural Network)	NN με spikes αντί για floats — βιολογικά-inspired
STL (Signal Temporal Logic)	Γλώσσα χρονικών spec: $\Box[a,b]\phi$ = «πάντα σε [a,b]», $\Diamond$ = «κάποτε»
STL robustness ρ	Πόσο «καλά» ικανοποιείται η STL spec — αρνητικό = παραβίαση
VLM	Vision-Language Model (GPT-4V, LLaVA) — κατανοεί εικόνες + κείμενο